Traview 旅言

基于 8 个实例数据的实操指南

(Version 0.5.2)

2026 年 4 月 6 日

目录

前言 11
0.1 本书的目的 11
0.2 本书适用对象 11
0.3 本书的使用方式 12
0.4 Traview 的基本工作逻辑 12
0.5 八个实例数据与软件模块的对应关系 12
0.6 学习建议与推荐顺序 13
第 1 章 开始使用 Traview 14
1.1 软件启动与主界面认识 14
1.2 数据工作区、结果窗口与日志窗口 15
1.3 菜单栏、工具栏与常用入口 16
1.4 第一次使用时应先掌握的四个窗口 16
1.5 Traview 的基本分析流程 16
1.6 本书中的界面名称、变量名称与路径表示方式 17
1.7 本章小结 17
第 2 章 数据导入、数据检查与结果查看 18
2.1 导入 CSV 文件 18
2.2 导入 Excel 文件 19
2.4 在 Data View 中查看原始数据 19
2.5 在 Variable View 中检查变量属性 20
2.6 如何判断变量类型是否合理 21
2.7 如何查看 Results Viewer 22
2.8 如何查看 Syntax & Log（语法与日志窗口） 23
2.9 上机前最常见的准备性错误 24
2.10 本章小结 24
第 3 章 八个案例总览与学习路线 25

3.1 本书八个案例的整体结构 25
3.2 从基础统计到高级模型的学习顺序 25
3.3 各案例的核心任务、适用模块与难度等级 25
3.4 如何根据自己的研究问题选择案例 26
3.5 教学使用建议与上机安排建议 26
3.6 本章小结 27
第 **4** 章 案例一：基础调查与服务评价数据 28
4.1 案例背景与研究场景 28
4.2 数据集结构说明与核心变量介绍 28
4.3 本案例的学习目标 29
4.4 导入数据与初步检查 29
4.5 使用 **Descriptive Statistics** 进行描述统计 31
4.6 使用 **Frequencies** 查看分类变量分布 32
4.7 使用 **Correlations** 查看变量关系 33
4.8 使用 **T-test** 比较促销与疫情前后的差异 34
4.9 使用 **ANOVA** 比较地区、旅行目的与酒店星级差异 35
4.10 使用 **Visualization** 绘制基础图表 37
4.11 从基础统计进入简单需求分析 38
4.12 关于政策影响与工具变量回归的扩展说明 39
4.13 本案例中的常见错误与排查 40
4.14 本章小结 40
第 **5** 章 案例二：酒店经营与市场表现数据 41
5.1 案例背景与研究问题 41
5.2 数据集结构说明与核心变量介绍 41
5.3 本案例的学习目标 42
5.4 导入数据与面板结构检查 42
5.5 使用 **Descriptive Statistics** 查看城市旅游收入与控制变量 43
5.6 使用 **Frequencies** 和分组统计查看处理组与时间结构 44

5.7 使用 **Visualization** 绘制时间趋势图 44
5.8 从 **OLS** 开始：建立最基础的回归模型 46
5.9 使用 **Panel Models** 建立固定效应模型 46
5.11 如何理解 **treated**、**post** 与 **treat_post** 49
5.12 结果解释：从统计显著到经济含义 49
5.13 写回结果与进一步扩展 49
5.14 本案例中的常见错误与排查 50
5.15 本章小结 50
第 **6** 章 案例三：评论文本与平台反馈数据 51
6.1 案例背景与文本分析任务 51
6.2 数据集结构说明与核心变量介绍 51
6.3 本案例的学习目标 52
6.4 导入数据与文本变量检查 53
6.5 从结构化字段开始认识评论数据 54
6.6 在 **Text Analysis** 中选择文本列与预处理方式 54
6.7 使用 **Basic Text Statistics** 查看文本基本特征 55
6.8 使用 **Word Frequency** 分析高频词 55
6.9 使用 **N-gram Frequency** 分析常见短语 56
6.10 使用 **Sentiment Analysis** 进行情感分析 57
6.11 使用 **Topic Modeling** 提取评论主题 58
6.12 使用 **Keyword Occurrence** 检测特定服务问题 59
6.13 使用 **TF-IDF Summary** 提取区分性表达 59
6.14 使用 **Text Similarity** 与 **Nearest-Neighbor Search** 比较评论 59
6.15 将文本结果写回数据表 60
6.16 结合 **Statistics** 继续分析文本结果 61
6.17 结合 **Econometrics** 研究评论行为与回复行为 61
6.18 本案例中的常见错误与排查 61
6.19 本章小结 62

第 7 章 案例四：时间序列预测数据 63
7.1 案例背景与预测任务 63
7.2 数据集结构说明与核心变量介绍 63
7.3 本案例的学习目标 64
7.4 导入数据与时间结构检查 64
7.5 在 Data View 中先理解时间序列数据 65
7.6 使用 Visualization 绘制销售趋势图 65
7.7 使用 Descriptive Statistics 理解销售、温度与促销分布 66
7.8 在 Time Series 模块中设定 Date column 与 Target (Y) 67
7.9 使用 ADF Test 检查平稳性 67
7.10 使用 Exponential Smoothing 进行基础预测 68
7.11 使用 ARIMA 进行单变量时间序列建模 69
7.12 使用 Holt-Winters 或 SARIMA 处理更复杂模式 70
7.13 把 Temperature 和 Promotion 作为外生变量来理解 71
7.14 使用 ARDL 或扩展模型分析外部影响 71
7.15 保存拟合值、残差与预测值 72
7.16 如何解释趋势、预测与外生冲击结果 73
7.17 本案例中的常见错误与排查 73
7.18 本章小结 73
第 8 章 案例五：空间点位与空间属性数据 74
8.1 案例背景与空间分析任务 74
8.2 数据集结构说明与核心变量介绍 74
8.3 本案例的学习目标 75
8.4 导入数据与坐标字段检查 75
8.5 在 Variable View 中理解空间变量含义 76
8.6 使用 Point Map 绘制基础点位图 76
8.7 使用 Heatmap 观察访客集中区域 77
8.8 空间权重与邻接关系的基本理解 77

8.9 使用 **Global Moran's I** 检查评分的整体空间自相关 78
8.10 使用 **Local Moran's I** 识别局部聚类与异常点 79
8.11 使用 **Hotspot Analysis** 识别高访客热点与低访客冷点 80
8.12 使用 **Buffer Counts** 衡量周边酒店密度 81
8.13 使用 **Nearest Neighbor** 判断点位整体分布模式 82
8.14 使用 **IDW Interpolation** 生成评分表面 83
8.15 把空间结果写回数据表 83
8.16 结果解释：从地图到空间结构 83
8.17 本案例中的常见错误与排查 84
8.18 本章小结 84
第 **9** 章 案例六：量表题项与潜变量建模数据 85
9.1 案例背景与潜变量研究问题 85
9.2 数据集结构说明与核心变量介绍 85
9.3 本案例的学习目标 87
9.4 导入数据与问卷结构检查 87
9.5 使用 **Descriptive Statistics** 查看量表题项与行为变量 88
9.6 使用 **Reliability Analysis** 检查服务质量量表一致性 88
9.7 使用 **Factor Analysis** 探索潜在结构 90
9.8 从量表结果进入 **SEM** 的基本思路 91
9.9 在 **SEM Workspace** 中建立最基础的测量模型 91
9.10 在 **SEM** 中加入满意度与忠诚路径 92
9.11 使用 **Validate** 检查模型并运行 **Run SEM** 93
9.12 如何理解满意度的中介作用 94
9.13 使用 **Process Model** 进行中介与调节扩展 94
9.14 使用分类模型预测 **Booking_Success** 96
9.15 本案例中的常见错误与排查 98
9.16 本章小结 98
第 **10** 章 案例七：元分析效应量数据 99

10.1 案例背景与研究综合问题 99
10.2 数据集结构说明与核心变量介绍 99
10.3 本案例的学习目标 100
10.4 导入数据与研究级数据结构检查 100
10.5 从研究视角理解效应量、样本量与方差 101
10.6 使用 **Descriptive Statistics** 查看效应量分布 101
10.7 在 **Meta Analysis** 中设定 **Effect Size Type** 与输入列 102
10.8 使用 **Fixed Effects** 与 **Random Effects** 比较总体效应 103
10.9 使用 **Forest Plot** 阅读研究与总体结果 103
10.10 使用 **Funnel Plot** 检查发表偏倚 105
10.11 使用 **Leave-One-Out Sensitivity Plot** 做敏感性分析 106
10.12 使用 **Subgroup Analysis** 比较地区和样本类型差异 106
10.13 使用 **Meta-Regression** 检验年份、测量工具与发表状态的调节作用 107
10.14 使用 **published** 做发表偏倚与灰色文献比较 108
10.15 结果解释：总体效应、异质性与调节变量 108
10.16 本案例中的常见错误与排查 108
10.17 本章小结 109
第 **11** 章 案例八：投入—产出效率评价数据 110
11.1 案例背景与效率评价问题 110
11.2 数据集结构说明与核心变量介绍 110
11.3 本案例的学习目标 111
11.4 导入数据与投入—产出结构检查 111
11.5 先用基础统计理解投入与产出的规模差异 112
11.6 在 **Efficiency Analysis** 中设定 **DEA** 模型 112
11.7 理解 **Input-oriented** 与 **Output-oriented** 113
11.8 理解 **CRS** 与 **VRS**：常数报酬与可变报酬 114
11.9 运行 **DEA** 并阅读效率得分 114
11.10 使用效率分布图与排序图理解结果 115

11.11 使用 **Write scores back to dataset** 写回效率结果 116
11.12 使用 **region** 和 **hotel_star** 比较区域与星级差异 117
11.13 使用 **SFA** 作为参数前沿模型扩展 117
11.14 DEA 与 **SFA** 的基本区别 118
11.15 结果解释：效率不是收入高低，而是资源转化能力 119
11.16 本案例中的常见错误与排查 120
11.17 本章小结 120
第 **12** 章 结果查看、结果整理与导出 121
12.1 本章概述 121
12.2 Results Viewer：**Traview** 的统一结果中心 121
12.3 结果通常会以什么形式出现 122
12.4 运行分析后为什么要先看结果窗口 123
12.5 如何判断一次分析是否真正成功 123
12.6 如何阅读表格型结果 123
12.7 如何阅读图形型结果 124
12.8 如何阅读文本型结果与模型摘要 124
12.9 如何区分正式结果与过程性信息 125
12.10 结果的阶段性整理：为什么不要等到最后才处理 125
12.11 如何保存当前结果会话 125
12.12 如何导出表格结果 126
12.13 如何导出图形结果 126
12.14 如何导出完整报告 126
12.15 结果文件命名与文件夹管理建议 127
12.16 结果比较：如何在多个案例之间建立联系 127
12.17 清空结果与开始新一轮分析 127
12.18 结果未出现时该怎么办 128
12.19 本章小结 128
第 **13** 章 常见问题与上机故障排查 129

13.1 本章概述 129
13.2 数据导入失败或导入后结构异常 129
13.3 变量名正确，但变量类型不合理 130
13.4 运行分析后没有看到结果 130
13.5 Results Viewer 中结果太多，看不清当前分析结果 130
13.6 Syntax & Log 太多技术信息，不知道该看哪一行 131
13.7 描述统计、相关分析或频数分析结果异常 131
13.8 回归模型无法运行或结果明显反常 131
13.9 文本分析结果为空或几乎没有有意义词项 132
13.10 时间序列结果异常或预测线看起来不合理 132
13.11 空间分析地图不对、点位跑偏或结果全不显著 133
13.12 SEM、**Process Model** 和高级模型运行失败 133
13.13 效率分析结果看不懂，或感觉和收入高低不一致 133
13.14 导出文件失败或导出后找不到文件 134
13.15 设置修改后没有生效 134
13.16 图表显示正常，但结果解释写不出来 134
13.17 一个更有效的排查顺序 135
13.18 本章小结 135
附录 **A** 八个案例核心变量总表 136
A.1 附录说明 136
A.2 八个案例核心变量总表 136
A.3 按变量角色理解八个案例 138
A.4 按模块快速反查案例 138
A.5 本附录小结 138
附录 **B** 各案例常见报错速查表 139
B.1 附录说明 139
B.2 通用问题速查表 139
B.3 案例一常见问题：基础调查与服务评价数据 139

B.4 案例二常见问题：酒店经营与市场表现数据 140
B.5 案例三常见问题：评论文本与平台反馈数据 140
B.6 案例四常见问题：时间序列预测数据 140
B.7 案例五常见问题：空间点位与空间属性数据 141
B.8 案例六常见问题：量表题项与潜变量建模数据 141
B.9 案例七常见问题：元分析效应量数据 141
B.10 案例八常见问题：投入—产出效率评价数据 141
B.11 一条最实用的排查口诀 142
B.12 本附录小结 142
附录 **C** 教学练习与课堂任务建议 143
C.1 附录说明 143
C.2 案例一教学任务：基础调查与服务评价数据 143
C.3 案例二教学任务：酒店经营与市场表现数据 143
C.4 案例三教学任务：评论文本与平台反馈数据 144
C.5 案例四教学任务：时间序列预测数据 144
C.6 案例五教学任务：空间点位与空间属性数据 145
C.7 案例六教学任务：量表题项与潜变量建模数据 145
C.8 案例七教学任务：元分析效应量数据 146
C.9 案例八教学任务：投入—产出效率评价数据 146
C.10 一份可直接使用的上机考核结构 147
C.11 课堂讨论建议 147
C.12 本附录小结 147

前言

0.1 本书的目的

本书是一部围绕 Traview 软件编写的实例型实操指南。它的主要目的，不是像完整用户手册那样逐项罗列所有菜单和窗口，也不是把所有分析方法都写成抽象定义，而是通过八个具有代表性的示例数据集，把软件中最重要的分析路径串联起来，帮助读者在真实问题情境中理解软件的使用方式。

在很多情况下，初学者真正遇到的问题并不是“这个按钮叫什么”，而是“我手里有这样一份数据，我接下来应该做什么”。因此，本书采用案例驱动的组织方式，而不是单纯按软件模块堆砌功能说明。每个案例都围绕一类典型数据和一类典型研究问题展开，并把数据导入、数据检查、分析设定、结果查看和结果导出组织成一个完整的操作过程。通过这种方式，读者不仅能够学会某一个模块如何使用，更能够逐步形成对 Traview 整体工作流的理解。

从更广的角度看，本书的目标还有两个层面。第一，它希望帮助初学者建立一套稳定的数据分析习惯，也就是先检查数据，再进行分析，最后整理结果，而不是一开始就盲目进入模型。第二，它希望帮助教师、研究助理和软件测试者在教学、演示和功能验证中更高效地使用 Traview。也就是说，这本书既可以作为学习材料，也可以作为上机操作参考和软件测试脚本的基础框架。

0.2 本书适用对象

本书主要面向三类读者。第一类是第一次接触 Traview 的学生和初学者。对这类读者而言，本书最重要的价值在于，它能够把复杂的软件环境分解成若干条清晰的操作路径，使学习者不必在一开始就面对全部功能。第二类是希望把 Traview 用于课堂教学、课程作业或实验训练的教师。对于这类读者，本书提供的八个案例既可以作为演示材料，也可以进一步扩展为课堂练习、实验作业或分组讨论任务。第三类是已经具备一定研究基础、但希望借助 Traview 快速完成分析任务的研究人员和助理。对他们而言，本书最有帮助的地方在于，它把多种分析任务组织在一套统一的软件逻辑之下，从而减少在不同软件和不同界面之间频繁切换的成本。

需要说明的是，本书虽然采用较为友好的实操写法，但并不等于它只适合完全没有经验的用户。恰恰相反，具有一定统计、计量或数据分析背景的读者，通常会更容易从案例中看出软件设计的结构逻辑，并把这些案例迁移到自己的真实项目中使用。只是对于初学者来说，本书更强调一步一步带着做；而对于有经验的用户来说，本书更像是一套快速熟悉软件的路径图。

0.3 本书的使用方式

本书并不要求读者从头到尾机械顺序阅读，但它确实提供了一条推荐学习路径。若读者完全没有使用 Traview 的经验，建议先阅读前言、第 1 章、第 2 章和第 3 章。这几部分的目的，是帮助读者先熟悉软件环境，理解结果窗口和日志窗口的作用，并在真正进入案例之前建立一个整体印象。只有理解了软件的总体工作逻辑，后面的案例实操才不会变成机械点击。

在进入案例部分后，读者既可以按本书安排的顺序学习，也可以根据自己的研究兴趣和数据类型跳读。若你的主要任务是做问卷或结构化调查分析，可以优先阅读案例一和案例二。若你的主要任务是处理评论或平台文本，可以优先进入案例三。若你的数据具有明显时间维度，则应重点阅读案例四。若你的数据包含经纬度信息或空间位置，则案例五会更有针对性。若你的研究问题涉及潜变量、元分析或效率评价，则案例六、案例七和案例八更适合你。

在使用本书时，有一个非常重要的建议，即尽量边读边操作。Traview 是一款高度依赖界面和结果窗口交互的软件，仅靠阅读文字并不足以真正掌握其使用逻辑。只有当读者在打开软件、导入数据、点击按钮并看到结果以后，很多概念才会真正变得清晰。因此，这本书最适合的阅读方式，从来不是“看完再用”，而是“边看边做”。

0.4 Traview 的基本工作逻辑

无论使用哪一个案例，Traview 的基本工作逻辑都是相对稳定的。一般而言，软件使用过程大致包括五个阶段。第一个阶段是导入数据，也就是把数据文件载入当前工作区。第二个阶段是检查数据，确认变量名、变量类型、缺失值和关键字段是否合理。第三个阶段是根据研究问题选择合适的分析模块，例如 **Statistics**、**Econometrics**、**Text Analysis**、**Time Series**、**Machine Learning**、**Visualization**、**Spatial Analysis** 或 **Advanced Models**。第四个阶段是查看结果，也就是通过 **Results Viewer** 阅读表格、图形和结果摘要。第五个阶段则是整理和导出结果，把正式输出保存为表格、图像或文档。

之所以要在前言中专门强调这一点，是因为很多初学者在使用分析软件时，容易把注意力全部集中在“点哪个模型”上，而忽略了数据检查和结果整理。Traview 并不是一款鼓励“直接跳到模型”的软件。它的设计理念更接近一个完整的数据分析工作流：数据必须先被理解，分析结果必须统一进入结果窗口，问题发生时也必须能在日志中追踪过程。因此，理解 Traview，首先不是理解每一个模型按钮，而是理解这一条完整路径。

0.5 八个实例数据与软件模块的对应关系

本书选用的八个案例，并不是随意拼凑的，而是尽量覆盖 Traview 当前版本中最有代表性的分析方向。案例一和案例二主要面向结构化数据，分别强调基础统计和计量分析。案例

三面向文本数据，突出评论、反馈和平台文本的处理逻辑。案例四面向时间序列数据，强调预测与动态关系。案例五面向空间点位数据，突出地图、热点和空间统计。案例六面向量表和潜变量建模，衔接信度分析、因子分析和 SEM。案例七面向研究综合型数据，集中展示元分析功能。案例八则面向投入—产出数据，展示 DEA 和 SFA 两类效率分析路径。

这种安排的意义，在于帮助读者理解 Traview 并不是一个“只会做某一类分析”的软件。相反，它适合被视为一个多模块、统一工作流的桌面分析平台。通过这八个案例，读者可以逐步认识到，同一套软件既可以处理结构化表格，也可以处理文本、时间、空间和高级模型。更重要的是，这些模块并不是彼此孤立的。一个模块得到的结果，很多时候还可以写回数据表，再交给另一个模块继续分析。

0.6 学习建议与推荐顺序

如果读者希望用最稳妥的方式学习 Traview，我建议采用由浅入深的顺序。最开始先读第 1 章到第 3 章，理解软件界面、结果窗口和日志窗口。然后依次学习案例一、案例二和案例三。这三章基本能够帮助读者掌握软件中最重要的基础能力，也就是导入数据、理解变量、完成基础统计、完成基础回归、进行简单文本分析，并把结果送到 **Results Viewer**。接下来可以根据需要选择案例四或案例五，分别进入时间序列和空间分析。最后，再学习案例六至案例八，也就是潜变量建模、元分析和效率分析。

这样的顺序之所以重要，是因为高级模型的难点通常并不只是按钮更多，而是数据结构、变量角色和理论设定都更复杂。若读者在前面的基础章节中尚未形成稳定的软件使用习惯，直接进入高级模型往往会感到困难。因此，本书虽然允许跳读，但仍然建议多数读者尽量先把前半部分走通，再进入后半部分。

第 1 章 开始使用 Traview

1.1 软件启动与主界面认识

Traview 是一款以数据工作表为中心的桌面数据分析软件。用户启动软件后，通常会首先看到主窗口。这个主窗口并不是单纯的欢迎页，也不是只显示一组大图标的导航界面，而是一个真正可以开始工作的分析环境。也就是说，当软件打开之后，用户实际上已经进入了可以导入数据、查看工作表并发起分析的状态。

第一次打开 Traview 时，最重要的不是急着点击某个分析模块，而是先对主界面的整体结构形成基本认识。主界面的最上方通常是软件标题区和若干全局功能入口，例如 **Results Viewer**、**Settings** 和授权状态提示。其下是菜单栏，用于组织 Traview 的主要功能。再往下是中央数据工作区，这是用户后续几乎所有操作的基础。界面底部一般还会有状态栏，用来显示当前数据表规模或软件状态。

从学习软件的角度看，主界面的意义不仅在于“长什么样”，更在于它揭示了软件的工作思路。Traview 并不是一个先让用户选模型、再让用户找数据的软件，而是先把数据工作区放在中央，让用户围绕当前数据集展开操作。这一点非常重要，因为它决定了本书和软件本身都会不断强调一句话：先看数据，再做分析。

图 1-1 Traview 主界面总览。

1.2 数据工作区、结果窗口与日志窗口

要真正理解 Traview 的工作流，用户至少需要先认识三个核心界面环境，即数据工作区、结果窗口和日志窗口。中央的数据工作区是用户最常停留的地方，它负责显示当前活动数据集。这里通常包括 **Data View** 和 **Variable View** 两种基本视图。前者用于查看每一行观测和每一列变量的原始数据内容，后者用于查看变量名称、变量属性和变量说明。

与数据工作区不同，**Results Viewer** 并不是用来操作数据的，而是用来查看分析结果的。Traview 当前版本中，绝大多数分析输出都不会长期留在原分析页面，而会被统一发送到 **Results Viewer**。这意味着，用户在完成统计、回归、文本分析、时间序列预测、图表绘制或空间分析之后，都应主动到结果窗口中查看正式输出。初学者最容易犯的一个错误，就是以为“点了分析以后，结果应该留在当前模块页面”，而 Traview 的设计并不是这样。

第三个重要窗口是 **Syntax & Log（语法与日志窗口）**。它的作用并不是展示分析结果，而是记录分析过程。用户若遇到模型失败、图表未生成、变量错误或结果没有按预期出现时，最应该去查看的通常不是 **Results Viewer**，而是 **Syntax & Log**。这个窗口会告诉你分析有没有开始、运行到了哪一步、哪一行提示最早出现了问题。因此，从软件学习的第一天起，就应该把这三个环境区分清楚：数据工作区负责“做准备”，结果窗口负责“看输出”，日志窗口负责“查过程”。

图 1-2 数据工作区、结果窗口与日志窗口的关系。

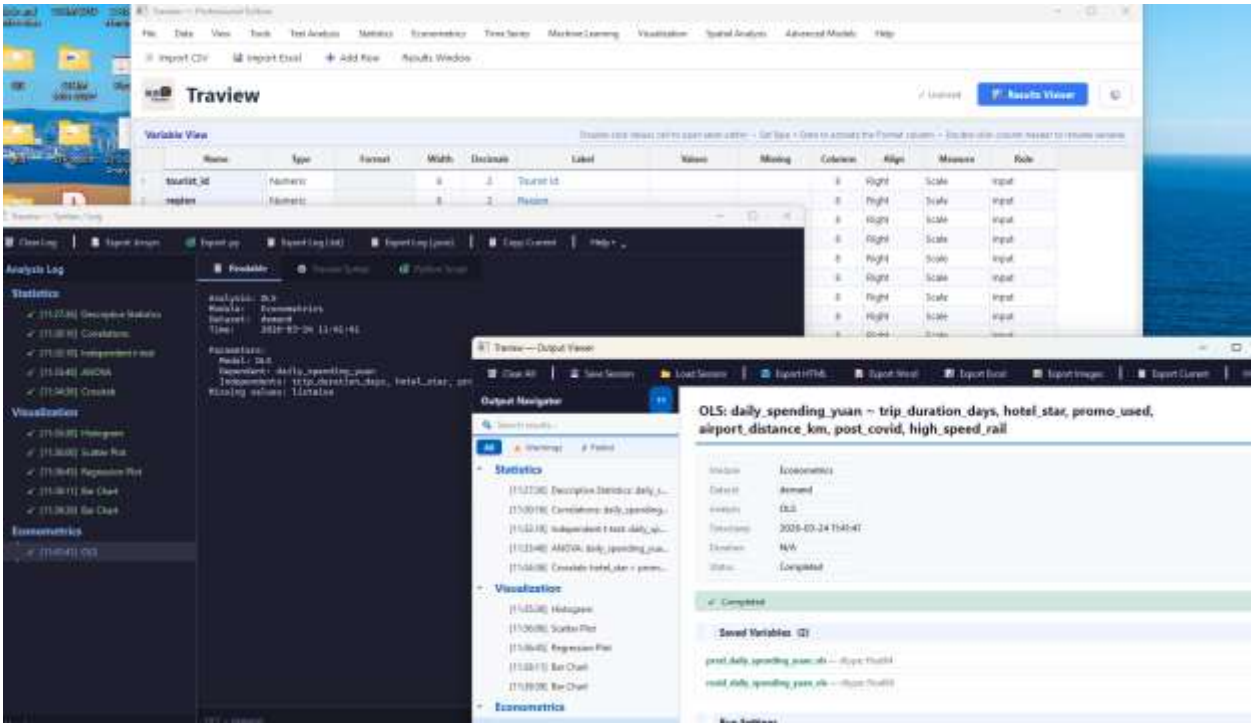

1.3 菜单栏、工具栏与常用入口

Traview 的菜单栏是整个软件功能的主要导航结构。它的存在意义，不只是把命令堆在顶部，而是通过逻辑分类告诉用户“不同类型的工作分别在什么地方进行”。一般来说，数据导入导出会集中在与数据相关的菜单中，分析模块则分别通过 **Statistics**、**Econometrics**、**Text Analysis**、**Time Series**、**Machine Learning**、**Visualization**、**Spatial Analysis** 和 **Advanced Models** 等入口进入，而结果窗口、日志窗口和设置则通常通过 **View** 或顶部全局入口进入。

如果说菜单栏体现的是软件的完整功能地图，那么工具栏和顶部快捷入口体现的则是高频操作的效率路径。例如，**Results Viewer** 之所以通常被放在较显眼的位置，是因为几乎所有分析最终都要去那里看结果。**Settings** 被放在顶部或明显入口，则是因为软件默认行为和导出路径会影响整个使用体验。对新用户而言，刚开始学习时仍建议优先使用菜单栏，因为那样更容易建立完整的功能地图。等到逐渐熟悉之后，再用工具栏和快捷按钮提高效率，会更自然。

1.4 第一次使用时应先掌握的四个窗口

对于第一次使用 Traview 的用户而言，并不需要马上理解所有模块，也不需要一开始就熟记所有菜单路径。更重要的是先掌握四个最基本的窗口或区域。第一个是主数据工作区，也就是 **Data View** 和 **Variable View** 所在的位置。第二个是 **Results Viewer**，它是分析结果集中显示的地方。第三个是 **Syntax & Log（语法与日志窗口）**，它是查看运行过程和错误信息的地方。第四个是 **Settings**，它是调整语言、导出路径、图表风格和默认行为的地方。

之所以说先掌握这四个位置最重要，是因为它们构成了 Traview 日常使用的最小闭环。用户导入数据以后，会先在工作区检查数据；做完分析以后，会去结果窗口看输出；遇到报错时，会去日志窗口找原因；如果默认行为不符合自己习惯，则会进入设置进行调整。只要这四个位置足够清楚，后面的模块学习就会顺很多。

1.5 Traview 的基本分析流程

在具体分析方法各不相同的情况下，Traview 的总体分析流程其实非常稳定。通常情况下，用户首先通过 **Data → Import CSV** 或 **Data → Import Excel** 导入一份数据文件。导入之后，应先在 **Data View** 和 **Variable View** 中检查变量结构、变量类型、缺失值和关键字段。之后，根据研究问题进入相应分析模块。例如，若只是想看均值和分布，应进入 **Statistics**；若想做回归，应进入 **Econometrics**；若数据是评论文本，则进入 **Text Analysis**；若数据有日期，则进入 **Time Series**；若数据有经纬度，则进入 **Spatial Analysis**。

分析运行完成后，用户不应停留在模块页面中等待所有信息自动显示，而应主动转向 **Results Viewer** 查看表格、图形和结果摘要。如果结果没有出现，或者分析中途失败，则应打开 **Syntax & Log** 查看过程信息。若分析设置或输出路径需要长期调整，则再进入 **Settings**。换句话说，Traview 的基本流程可以被概括为：导入数据，检查数据，选择分析，查看结果，必要时查看日志和调整设置。

这条流程看起来简单，但它实际上构成了整本书和整个软件的使用主线。只要用户把这一条主线真正掌握了，后面的不同案例和不同模块就不会显得彼此割裂。

1.6 本书中的界面名称、变量名称与路径表示方式

为了保证本书的表达统一，后续各章会采用固定的界面标注方式。软件中的菜单名称、按钮名称、复选框名称、下拉框名称和窗口名称，统一使用**加粗**表示。例如 **Results Viewer**、**Data View**、**Run Analysis**、**Text Analysis**。变量名、字段名、文件名和写回数据表的新变量，一律使用`等宽字体`表示。例如 `price`、`review_comment`、`sentiment_score`、`hotel_data.csv`。操作路径统一写成 **菜单 → 子菜单 → 命令** 的形式。例如 **Data → Import CSV**、**View → Syntax & Log**。

这套写法并不是形式上的装饰，而是为了帮助读者在阅读时迅速区分“这是界面上的东西”“这是数据表里的变量”“这是操作路径”。对于软件实操类教材来说，这种区分非常重要。因为一旦按钮名、变量名和路径表达混在一起，用户在真正对照软件操作时就会明显吃力。

1.7 本章小结

本章的目的，是帮助读者在正式进入案例之前，先建立对 Traview 主界面和核心工作流的初步认识。通过本章，读者应至少理解四件事。第一，Traview 是一款以数据工作区为中心的桌面分析软件。第二，结果通常会进入 **Results Viewer**，而不是长期停留在当前分析页面。第三，遇到问题时，**Syntax & Log（语法与日志窗口）** 是查看过程和错误的第一入口。第四，Traview 的基本使用逻辑始终是先导入和检查数据，再选择分析模块，最后查看和导出结果。

如果读者在阅读本章后，还没有立刻掌握所有按钮和所有菜单，这并不重要。真正重要的是已经形成一个整体印象：Traview 不是一堆分散按钮的集合，而是一套围绕数据、分析和结果组织起来的完整软件环境。带着这种印象进入后续章节，学习会轻松很多。

第 2 章 数据导入、数据检查与结果查看

2.1 导入 CSV 文件

对于大多数用户来说，真正开始使用 Traview 的第一步，就是把已有数据文件导入软件。当前版本最常见的输入格式包括 CSV 和 Excel。其中，CSV 由于兼容性强、结构简洁，通常是最稳妥的数据交换格式。用户可以通过 **Data → Import CSV** 打开导入对话框，选择相应文件后，软件会尝试读取文件内容并载入当前工作区。

在导入 CSV 文件时，用户需要特别注意两个问题。第一个问题是文本编码。若文件中包含中文、评论文本或其他非英文字符，而导入后显示为乱码，则很可能不是文件损坏，而是编码设置不匹配。此时应优先检查 **Settings → Data → Default file encoding**，并尝试在 **UTF-8** 与 **GBK** 等选项之间进行调整。第二个问题是列结构是否正确。如果导入后列数明显过多或过少，通常说明原始文件中的分隔符、引号或文本内容存在格式问题。在这种情况下，应先回到原始文件检查，而不建议直接在错误导入的表格上继续分析。

对于初学者来说，一个非常重要的习惯是：导入成功并不等于数据已经可以直接使用。Traview 只负责把文件读进来，但数据本身是否规范，仍然需要用户进一步检查。

图 2-1 使用 **Data → Import CSV** 导入文件。

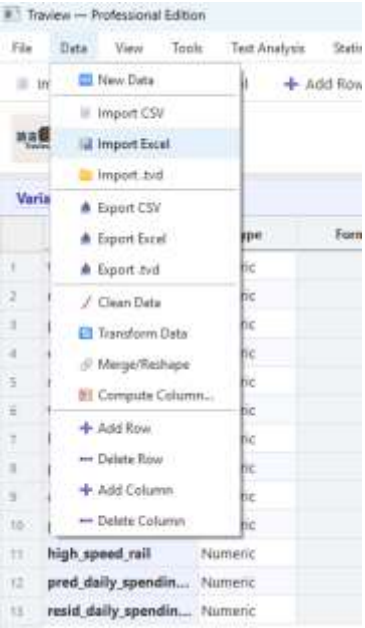

2.2 导入 Excel 文件

若用户的数据保存在 Excel 工作簿中，则可以通过 **Data → Import Excel** 进行导入。相比 CSV，Excel 文件通常更容易被普通用户接受，因为它在表格环境中可视化程度更高。但也正因为如此，Excel 文件更容易混入各种不适合直接分析的元素，例如说明性标题、空白行、合并单元格、备注列和不规则表头。

在导入 Excel 文件之前，较理想的做法是先在原始工作簿中检查工作表结构，尽量确保真正需要分析的部分已经整理为规则数据表，也就是每一列代表一个变量，每一行代表一个观测值，首行作为变量名。如果一个 Excel 工作表中混杂了标题、注释和数据表，那么导入之后往往会产生变量名不正确、列偏移或类型识别异常等问题。

导入成功后，用户仍应在 Traview 中再次核对关键变量。例如，日期列是否被读成普通文本，分类变量是否被误读为数值，货币或百分比列是否混入了符号导致无法正确识别。这些问题在 Excel 环境中往往不明显，但在分析软件中会直接影响后续操作。

2.3 打开示例数据集

除了导入自己的数据，本书中的八个案例通常也会配套相应的示例数据集。读者在学习本书时，最推荐的做法是直接使用这些案例数据进行练习。这样做的好处在于，手册中的变量名、分析路径和结果解释都能与实际操作一一对应，读者不必在学习软件的同时，还额外处理自己真实数据中的复杂清洗问题。

打开示例数据集的方式与普通 CSV 或 Excel 数据相同。关键不在于文件来源，而在于导入后要立刻确认当前工作区显示的，确实是你预期的那份数据集。在教学环境中，一个很常见的问题是学生以为自己打开了案例一的数据，实际上仍在使用上一个案例的数据文件。因此，在每次进入新的案例之前，都建议先看一眼行数、列数和关键变量名，以确认当前数据上下文没有搞错。

2.4 在 Data View 中查看原始数据

数据导入完成后，用户应首先进入 **Data View** 浏览原始表格。**Data View** 的意义，并不只是“看看数据有没有出来”，而是帮助用户建立对样本结构的第一印象。此时应重点注意几个问题。首先，每一行是否确实代表一个独立样本或一个独立观测。其次，变量列是否按预期排列，是否有多余空列。再次，是否存在明显异常值、空白列、重复列或完全不合理的字段内容。

例如，如果一个应为评分变量的列中出现大量 `999` 或 `-1`，那很可能是原始数据用特殊编码表示缺失值。又例如，如果某个日期列看起来像普通字符串而不是标准日期格式，那么

后面的时间序列分析就会受到影响。这类问题在数据视图中通常非常容易被肉眼发现，因此 **Data View** 应被视为导入后的第一道检查关口，而不是一个可有可无的浏览页。

图 2-2 **Data View** 中查看原始数据。

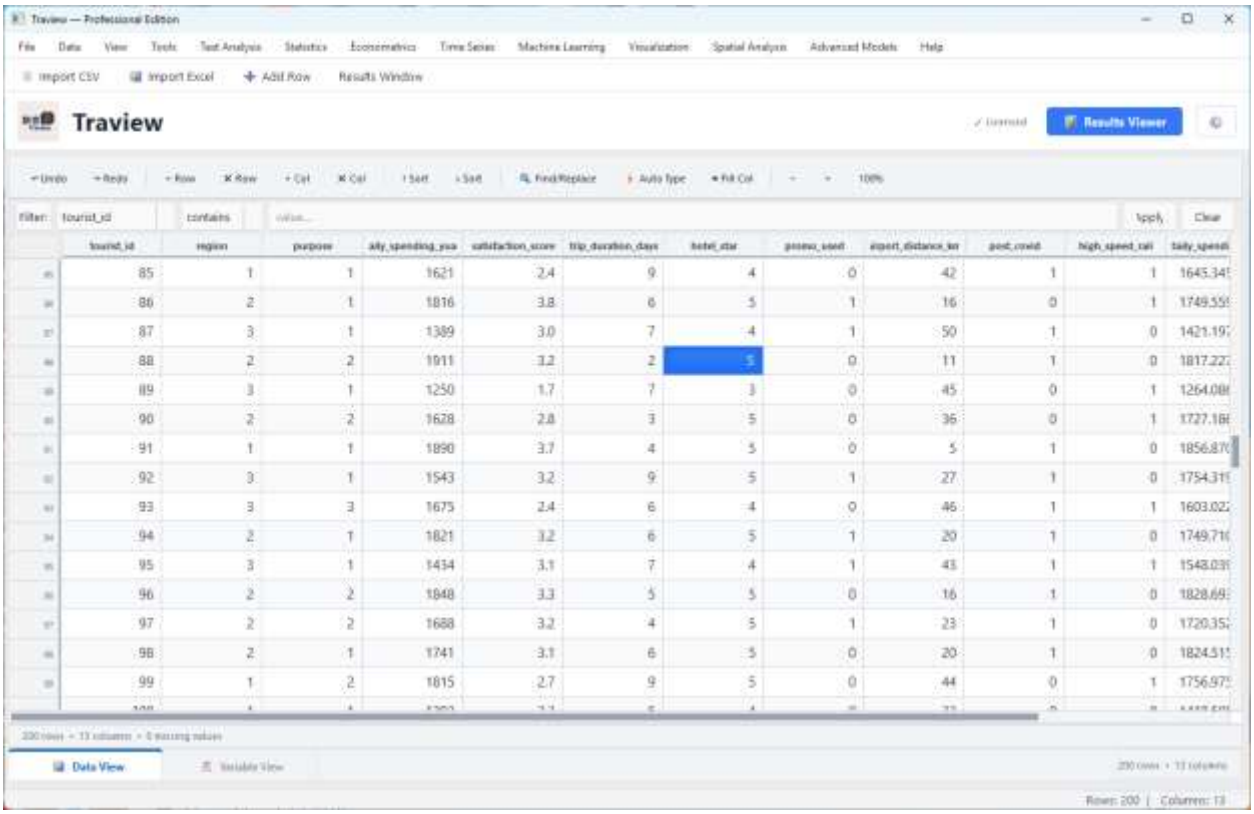

2.5 在 Variable View 中检查变量属性

完成原始数据的快速浏览之后，下一步应进入 **Variable View**。如果说 **Data View** 更接近“看每一个值”，那么 **Variable View** 更接近“看每一个变量”。在这里，用户通常可以看到变量名称、变量类型、变量说明以及其他与变量有关的属性信息。对于分析软件而言，这一步非常重要，因为后续几乎所有分析模块都依赖变量类型和变量含义。

在 **Variable View** 中，用户尤其应关注三件事。第一，变量名是否清楚且易于识别。如果变量名混乱，例如 `v1`、`v2`、`temp3`，建议在正式分析前先重命名。第二，变量类型是否合理。例如，评论文本是否被识别为文本字段，评分是否为数值型，日期是否为日期或至少可排序字段。第三，关键变量是否存在说明缺失。对于长期项目和教学场景而言，哪怕只是给几个核心变量补充简短说明，也会显著提高后续理解效率。

图 2-3 **Variable View** 中检查变量属性。

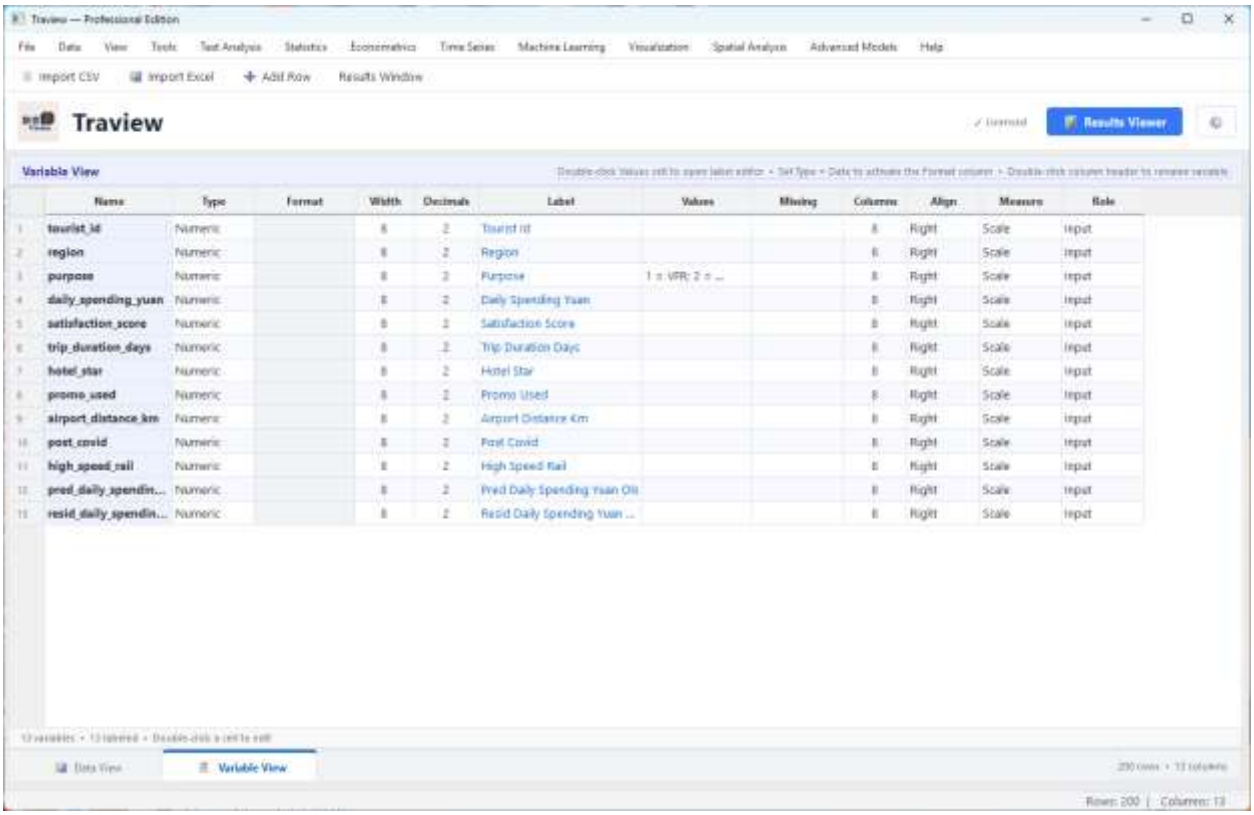

2.6 如何判断变量类型是否合理

在很多分析失败的案例中，问题并不是出在模型本身，而是变量类型一开始就设错了。因此，在进入具体案例之前，学会判断变量类型是否合理是非常重要的一项基本能力。

一般来说，若一个变量用于表示金额、评分、访问量、收入、入住率或其他可进行算术运算的量，它通常应是数值型变量。若一个变量用于表示城市、酒店类型、回复状态、游客类型等类别，它通常应被理解为分类变量。若一个变量承载的是自然语言内容，例如评论、反馈、问答或描述，它通常应作为文本变量。若一个变量表示时间顺序，例如 `date`、`year_month` 或 `quarter`，则它应尽量能够被软件识别或整理为时间字段。

需要特别提醒的是，有些变量虽然在形式上是数字，但在含义上并不是连续变量。例如，`1 = 男`，`2 = 女` 这样的性别编码，虽然看起来是数字，但本质上仍然是分类变量。相反，有些变量虽然带有特殊符号，例如百分号或货币符号，但本质上应当是连续数值。Traview 的自动识别功能可以作为起点，但最终判断变量是否合理，仍然需要用户根据数据含义做出决定。

2.7 如何查看 Results Viewer

在 Traview 中，大多数分析结果不会直接停留在当前模块页面，而会被统一发送到 **Results Viewer**。因此，在完成任何一次分析之后，用户都应主动打开 **Results Viewer**，确认结果是否已经生成。打开方式通常可以是点击主界面右上方的 **Results Viewer**，也可以通过 **View → Open Results Viewer** 进入。

对于初学者来说，**Results Viewer** 的意义远不止“结果显示器”这么简单。它实际上是 Traview 工作流中的统一结果中心。表格、图形、文本摘要以及部分高级模型输出，都会被集中到这里。这种设计有一个明显好处，即用户不必在不同页面中来回寻找结果，而可以在一个窗口中顺序浏览和整理。

在实际操作中，若用户刚刚运行完某个分析却在当前页面上没看到任何变化，第一件事就应该是打开 **Results Viewer**，而不是立刻重复点击运行按钮。因为在很多情况下，结果其实已经成功生成，只是被发送到了统一结果窗口中。

图 2-4 **Results Viewer**。

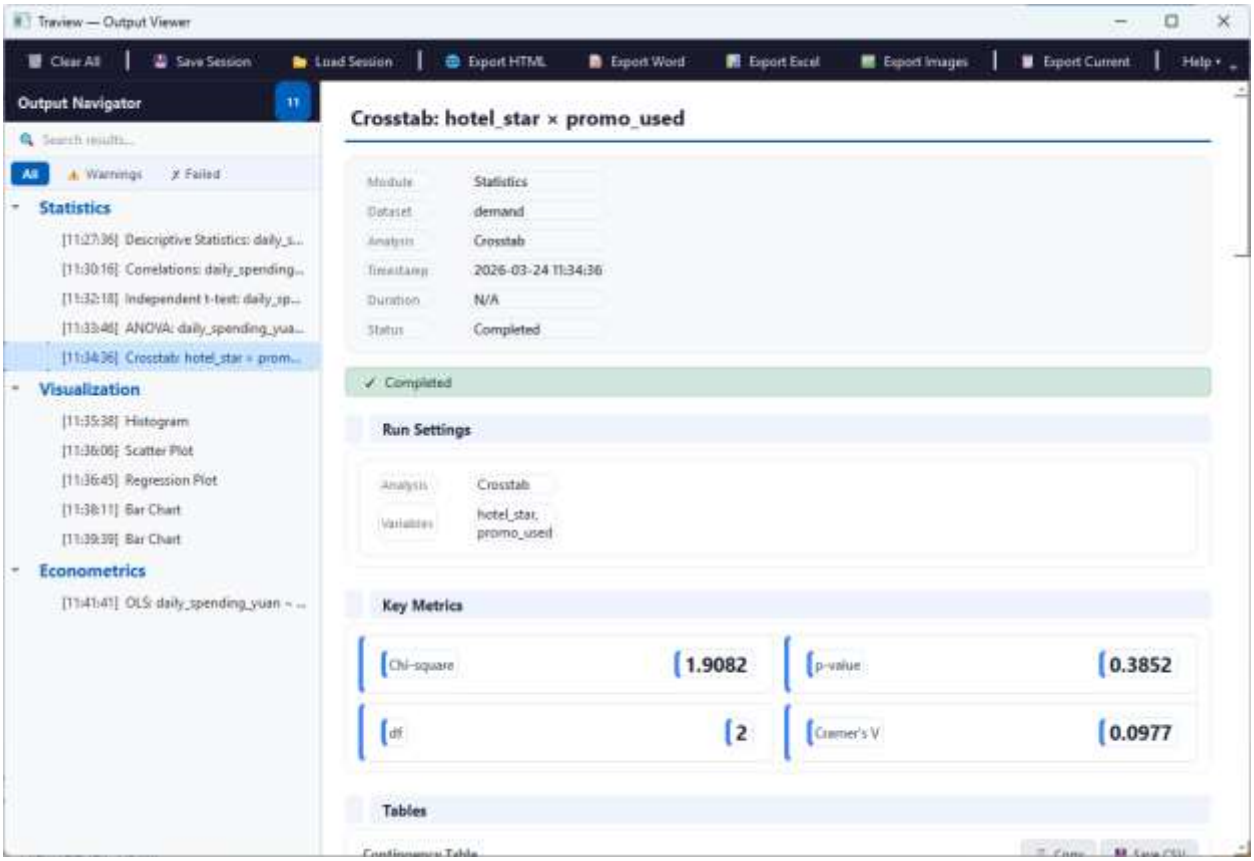

2.8 如何查看 Syntax & Log（语法与日志窗口）

如果用户运行分析后没有得到预期结果，或者软件提示错误，那么最应该查看的通常不是结果窗口，而是 **Syntax & Log（语法与日志窗口）**。用户可以通过 **View → Syntax & Log** 打开这一窗口。它记录的是软件在分析过程中的消息、提示、错误和部分语法相关信息。

对于初学者而言，不需要试图完全读懂日志中的每一行细节。更重要的是学会找到最先出现的关键警告或错误。一般来说，只要找到与当前分析对应的日志段，再查看第一条明显的 **error** 或 **warning**，就足以帮助判断问题大致来自数据、变量、模型还是文件路径。例如，如果日志提示某变量不是数值型，那么问题通常出在变量类型；如果日志提示输出目录不可写，那么问题通常不在分析本身，而在文件权限。

因此，**Syntax & Log** 应被理解为 Traview 中的排错第一站，而不是一个只面向开发者的技术窗口。

图 2-5 **Syntax & Log（语法与日志窗口）**。

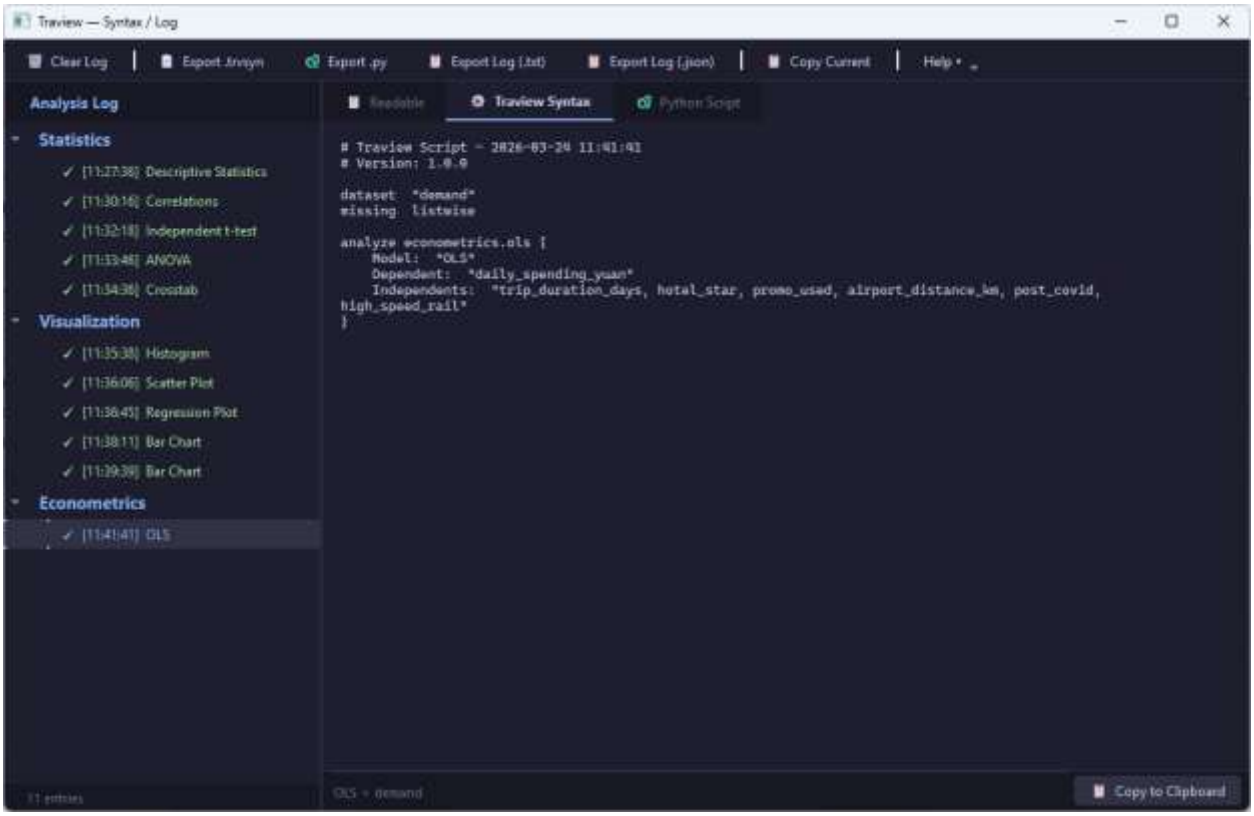

2.9 上机前最常见的准备性错误

在正式进入案例之前，读者应当知道，很多问题其实在“分析开始之前”就已经埋下了。最常见的准备性错误包括：导入后没有检查变量类型，把文本列误当成数值列，把分类编码误当成连续变量，把时间列当作普通文本处理，或在多次切换案例数据后没有确认当前活动数据集是否正确。

另一个常见问题是结果路径和工作流理解错误。很多用户第一次做分析时，发现当前页面上没出现结果，就误以为软件失败，实际上结果已经进入 **Results Viewer**。也有一些用户在分析失败后只会重复点击 **Run Analysis**，却从不查看 **Syntax & Log**。这些都不是模型层面的错误，而是软件使用顺序没有建立起来。

因此，真正成熟的上机准备，并不只是“把文件打开”，而是完成四个动作：确认数据已经导入，确认变量基本合理，确认知道结果去哪里看，确认知道错误去哪里查。只要这四步清楚，后续进入各个案例时就会顺畅很多。

2.10 本章小结

本章介绍了 Traview 实操前最关键的起始步骤，即数据导入、数据检查和结果查看。通过本章，读者应至少能够独立完成以下几件事：通过 **Data → Import CSV** 或 **Data → Import Excel** 导入一份数据；在 **Data View** 中浏览数据结构；在 **Variable View** 中检查变量属性；在分析后进入 **Results Viewer** 查看正式输出；在出错时进入 **Syntax & Log**（**语法与日志窗口**） 查找原因。

这些能力看起来都很基础，但它们几乎决定了后续案例是否能够顺利进行。换句话说，若第 2 章没有真正掌握，那么后面复杂模块中的许多问题都会显得更难。因此，在进入案例一之前，建议读者至少亲手完成一次数据导入，并打开一次结果窗口和日志窗口。

第 3 章 八个案例总览与学习路线

3.1 本书八个案例的整体结构

本书的主体由八个案例构成。这八个案例并不是彼此孤立的八份练习，而是按照由浅入深、由基础到高级、由通用到专业的顺序组织起来的。案例一和案例二主要帮助读者熟悉结构化数据的基础统计和计量分析。案例三引入文本分析，使读者开始接触非结构化文本数据。案例四和案例五则进一步把时间维度和空间维度纳入软件使用范围。最后，案例六、案例七和案例八进入高级分析领域，分别对应潜变量建模、元分析和效率评价。

这样安排的一个重要原因，是 Traview 并不是一款单一功能软件。如果一开始就把最复杂的功能摆在前面，初学者很容易误以为软件很难，其实很多复杂感只是来自顺序不合理。因此，本书希望通过案例顺序帮助读者逐步扩展能力边界。前面的案例重在跑通工作流，后面的案例重在理解更复杂的数据结构和模型逻辑。

3.2 从基础统计到高级模型的学习顺序

对多数第一次使用 Traview 的读者而言，最推荐的学习顺序是：先学习案例一，再学习案例二，然后进入案例三。完成这三部分后，读者通常已经能够独立完成导入数据、检查变量、进行描述统计、运行基础回归、绘制图表并把结果送入 **Results Viewer**。换句话说，Traview 的基本使用逻辑此时已经基本建立。

接下来，若读者的主要兴趣是时间类数据，则可以先进入案例四。若主要兴趣是地图和位置数据，则可以先进入案例五。若希望进一步学习高级模型，则在具备前面案例的基础后，再依次学习案例六、案例七和案例八会更自然。

这种顺序并不是强制的。若某位读者本身就主要做评论分析，当然可以直接从案例三开始；若另一位读者主要研究空间旅游流，也完全可以优先阅读案例五。只是从教学和自学效率角度看，先掌握基础数据工作流，再进入更复杂模块，通常会显著降低挫败感。

3.3 各案例的核心任务、适用模块与难度等级

案例一围绕基础调查与服务评价数据展开，其核心任务是描述统计、频数分析、差异检验和基础图表输出。它主要对应 **Statistics** 和 **Visualization**，难度属于入门级。
案例二围绕酒店经营与市场表现数据展开，其核心任务是回归分析、离散选择模型和面板数据分析。它主要对应 **Econometrics**，难度属于基础到中级。
案例三围绕评论文本与平台反馈数据展开，其核心任务是文本预处理、词频、情感分析、主题建模和文本特征写回数据表。它主要对应 **Text Analysis**，难度属于基础到中级。
案例四围绕时间序列预测数据展开，其核心任务是时间列设定、平稳性检验、单变量预测和多变量动态分析。它主要对应 **Time Series**，难度属于中级。

案例五围绕空间点位与空间属性数据展开，其核心任务是地图绘制、空间自相关、热点识别和缓冲区分析。它主要对应 **Spatial Analysis**，难度属于中级。
案例六围绕量表题项与潜变量建模数据展开，其核心任务是信度分析、因子分析和 SEM。它主要对应 **Statistics** 与 **Advanced Models → SEM Workspace**，难度属于中级到高级。
案例七围绕元分析效应量数据展开，其核心任务是效应量综合、森林图、漏斗图和元回归。它主要对应 **Advanced Models → Meta Analysis**，难度属于高级。
案例八围绕投入—产出效率评价数据展开，其核心任务是 DEA、SFA 和效率得分解释。它主要对应 **Advanced Models → Efficiency Analysis**，难度属于高级。

这样的难度划分并不意味着后面的案例一定“更难点”，而是意味着对变量角色、方法背景和结果解释的要求会逐渐提高。

3.4 如何根据自己的研究问题选择案例

并不是所有读者都需要按顺序把八个案例全部做完。因此，在实际学习中，知道如何根据研究问题选择案例会更加实用。若你的数据本质上是一张结构化调查表、经营表或属性表，并且你的主要问题是看均值、差异和关系，那么应优先学习案例一和案例二。若你的核心材料是评论、问答、反馈或开放式文本，那么案例三会更有帮助。若你的数据是月度、季度、年度或日度序列，并且研究问题围绕趋势和预测展开，则案例四最相关。若你的数据中最关键的是经纬度和位置，则案例五应被优先选择。

若你的研究问题强调潜变量、量表、构念关系和理论路径，则案例六更符合需求。若你面对的是一批独立研究结果，需要做系统综述和研究综合，则案例七最相关。若你关注的是相对效率、投入产出表现和最佳实践前沿，则案例八是最直接的入口。

从教学设计角度看，案例选择其实也反映了软件使用逻辑。因为 Traview 不是为了把所有人都强行带进每一个模块，而是希望用户能够根据自己的问题，自然地进入最相关的数据路径和方法路径。

3.5 教学使用建议与上机安排建议

若本书用于课堂教学，比较理想的安排通常是先用第 1 章到第 3 章做一次整体介绍，然后把案例一作为第一次上机内容。原因在于，案例一最适合帮助学生熟悉软件环境和结果窗口。第二次上机可以进入案例二，训练最基础的回归分析。第三次上机则可根据课程重点在案例三、案例四和案例五之间选择一到两个模块。若课程本身偏方法训练，则后续再进入案例六至案例八。

若本书用于软件测试或助研培训，则更适合把八个案例看成八套标准化测试路径。也就是说，测试者不仅要看“结果是否出来”，还要看变量能否正确导入、结果是否能写回数据

表、图表是否能正常显示、日志是否能给出有效反馈，以及结果窗口是否能稳定承接不同模块的输出。

因此，本章不仅是在介绍案例地图，也是在提示读者：这八个案例既可以是学习路径，也可以是教学脚本和测试脚本。

3.6 本章小结

本章介绍了本书八个案例的整体结构、推荐学习顺序、核心任务和模块对应关系。通过本章，读者应能够形成一个基本判断：自己当前最适合从哪一个案例开始，以及这八个案例大致分别训练 Traview 的哪些能力。对于第一次接触软件的读者而言，案例一和案例二通常是最好的起点；对于已经有明确研究问题的读者，则可以根据数据类型和分析目标直接跳转到最相关的案例。

从整本书的角度看，第 3 章的作用并不是讲具体按钮，而是帮助读者建立一张“学习地图”。只有知道自己接下来要走哪条路，后面的实操章节才会真正变得清楚。因此，读完本章后，建议读者不要急着同时打开所有案例，而是先选定下一章要练习的案例，然后边读边做，逐步推进。

第 4 章 案例一：基础调查与服务评价数据

4.1 案例背景与研究场景

本案例使用的是一份游客个体层面的需求与消费数据。数据中的每一行代表一名独立游客的一次旅行观测，共包含 200 条记录和 11 个变量。与一般只包含满意度或人口属性的简单调查表不同，这份数据同时包含了游客所属地区、旅行目的、日均消费、满意度、停留时间、酒店星级、促销使用情况，以及与政策和出行环境相关的变量，如高铁开通和疫情后时期。这使得它不仅适合用于最基础的描述统计和组间比较，也适合进一步进入需求分析、消费行为分析、政策影响分析，甚至在更高阶的练习中扩展到工具变量回归。

从教学和软件实操角度看，这是一份非常适合入门的数据集。首先，它的变量结构比较清楚，既有连续变量，也有二元变量和分组变量。其次，它几乎可以贯穿 Traview 的多个模块。用户既可以在 **Statistics** 中做描述统计、相关分析、t 检验和 ANOVA，也可以在 **Visualization** 中画出分布图和关系图，还可以在 **Econometrics** 中做基础 OLS 回归。换句话说，这一章不仅是“会打开一个数据集”，更是帮助用户第一次把一份真实结构化数据从导入、检查、分析一路走到结果解释。

本章的重点，不在于一开始就把所有复杂模型都跑完，而在于带着读者走完一条最典型的初始分析路径。也就是说，先理解数据，再描述数据，再比较组别，最后进入一个最基础的需求模型。只要这一套流程走通，后面再进入更复杂的计量案例时，就会容易很多。

4.2 数据集结构说明与核心变量介绍

本案例使用的数据文件名为 `demand.csv`。数据集中共有 200 行和 11 列。每一行代表一名游客的单次旅行观测。当前版本中，数据列如下所示。

变量名	含义	类型或取值	可用于的分析
`tourist_id`	游客编号	整数	个体识别
`region`	地区编码	1=华北，2=华东，3=华南	分组比较、异质性分析
`purpose`	旅行目的	1=休闲，2=商务，3=家庭	分类解释变量
`daily_spending_yuan`	日均消费	连续变量	OLS 因变量、消费分析
`satisfaction_score`	满意度	1–5	相关分析、组间比较、有序分析
`trip_duration_days`	停留天数	连续变量	控制变量、需求分析
`hotel_star`	酒店星级	3–5	分组比较、控制变量
`promo_used`	是否使用促销	0/1	促销影响分析

airport_distance_km	机场距离	连续变量	可作为地理成本变量，也可用于更高阶 IV 练习
post_covid	疫情后时期	0/1	分期比较、政策环境分析
high_speed_rail	高铁开通	0/1	政策效应分析

这份数据最核心的结果变量通常是 daily_spending_yuan，因为它直接反映了游客在旅行中的日均消费水平。从需求分析的角度看，它可以被视为一个非常典型的连续型因变量。其次，satisfaction_score 也很重要，因为它反映了旅行体验结果，并且与消费行为、酒店等级和旅行目的等变量都可能存在关系。trip_duration_days、hotel_star、promo_used、post_covid 和 high_speed_rail 则为解释消费和满意度差异提供了自然的分析路径。

需要特别提醒的是，region 和 purpose 虽然在文件中以数字编码形式出现，但它们本质上仍然是分类变量，而不是连续变量。也就是说，在做分组比较时，它们可以直接使用；但在进入回归模型时，用户应特别注意不要把它们机械地当作线性连续变量解释。对初学者来说，这一点非常关键。

4.3 本案例的学习目标

完成本章之后，读者应能够独立完成以下几项操作。首先，能够把一份结构化的调查数据导入 Traview，并在 **Data View** 和 **Variable View** 中检查变量和数据结构。其次，能够在 **Statistics** 模块中完成描述统计、频数分析、相关分析、t 检验和 ANOVA。再次，能够在 **Visualization** 中绘制最基础的分布图和关系图。最后，能够在 **Econometrics** 中建立一个最基础的消费行为回归模型，并在 **Results Viewer** 中查看和解释结果。

更重要的是，本章希望帮助读者建立一个软件使用习惯。这个习惯不是“先找模型按钮”，而是“先看数据，再做基础统计，再进入更深入分析”。对 Traview 这样的桌面分析软件来说，这种顺序比单独学会某一个模块更重要。

4.4 导入数据与初步检查

本案例的第一步，是通过 **Data → Import CSV** 导入 demand.csv。导入成功后，用户应先不要进入分析模块，而是先在主工作区中浏览数据表。对于这份数据，导入后最应该确认的第一件事，是样本规模是否正确。当前文件应包含 200 行和 11 列。如果行列数明显不同，就应先检查文件本身，而不建议继续分析。

在 **Data View** 中浏览时，用户应特别注意几个变量。daily_spending_yuan 应表现为连续数值，且没有明显错误编码。satisfaction_score 虽然取值接近 1 到 5，但在当前数据中是带小数的数值型字段，因此在描述统计和相关分析中可直接作为连续变量做初步探索。promo_used、post_covid 和 high_speed_rail 应表现为 0 或 1 的二元变量。region

和 purpose 虽然也是数字，但其含义是类别编码。hotel_star 应集中在 3、4、5 三个水平。airport_distance_km 则应为正数连续变量。

接下来，用户应进入 **Variable View**，确认变量名称是否与上表一致，并检查字段是否都已被识别为可分析的列。对于本案例而言，由于所有变量都已经是数值编码形式，因此通常不需要额外的文字转码。但也正因为如此，更需要用户主动记住某些数字列其实代表类别，而不是连续量。换言之，Traview 可以识别“数字”，但“数字背后的含义”仍然需要用户自己理解。

图 4-1 导入 demand.csv 后的 **Data View**。

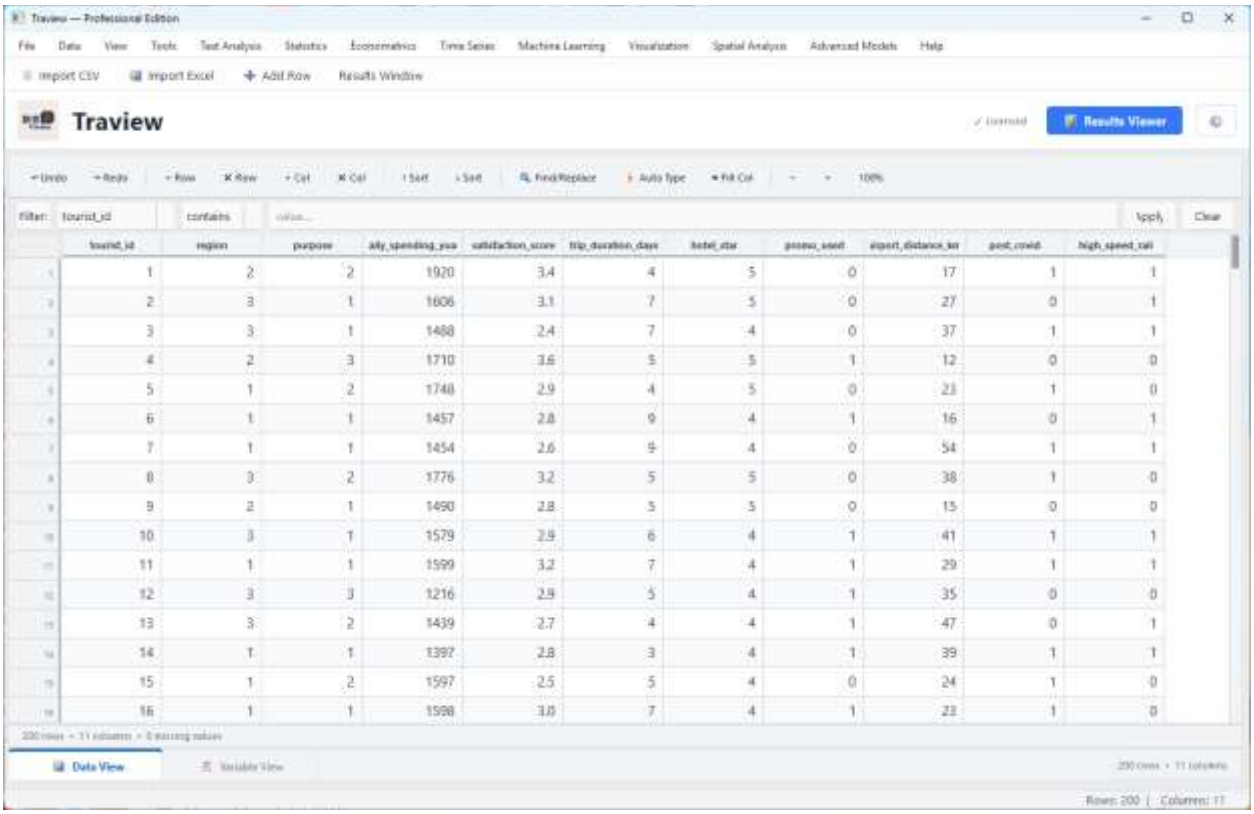

4.5 使用 Descriptive Statistics 进行描述统计

完成初步检查后，本案例最合适的第一项正式分析是描述统计。用户可以通过 **Statistics → Descriptive Statistics** 打开描述统计页面。在变量选择中，建议第一次先选取 `daily_spending_yuan`、`satisfaction_score`、`trip_duration_days`、`hotel_star` 和 `airport_distance_km`。这几列基本覆盖了消费、体验、停留、住宿等级和出行成本等几个关键维度。

在统计量选项中，建议至少勾选均值、中位数、标准差、最小值和最大值。这样可以帮助用户快速回答几个问题。平均日均消费大约处于什么水平。满意度大致是否集中。停留天数和机场距离是否存在较大离散。酒店星级是否主要集中在某一等级。对于这类调查数据来说，这些问题通常是进入回归和政策比较之前最重要的第一步。

如果希望结果更直观，用户还可以同时勾选 **Histogram** 或 **Boxplot**。例如，`daily_spending_yuan` 的直方图能够帮助判断消费分布是较集中还是较分散。`trip_duration_days` 的箱线图则有助于识别是否存在停留时间特别长的极端观测。需要说明的是，此时最重要的并不是立刻解释所有统计学含义，而是通过这一组输出建立对数据分布的直观认识。运行完成后，用户应到 **Results Viewer** 查看表格和图形。若结果没有立刻出现在当前页面，这并不代表分析失败，而只是因为 Traview 会将正式结果统一提交到结果窗口。

图 4-2 **Descriptive Statistics** 参数界面。

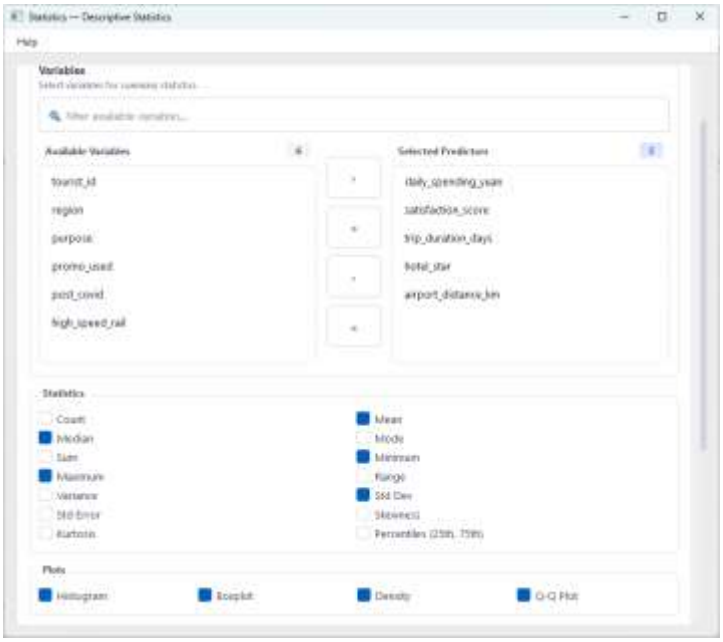

图 4-3 本案例的描述统计结果示例。

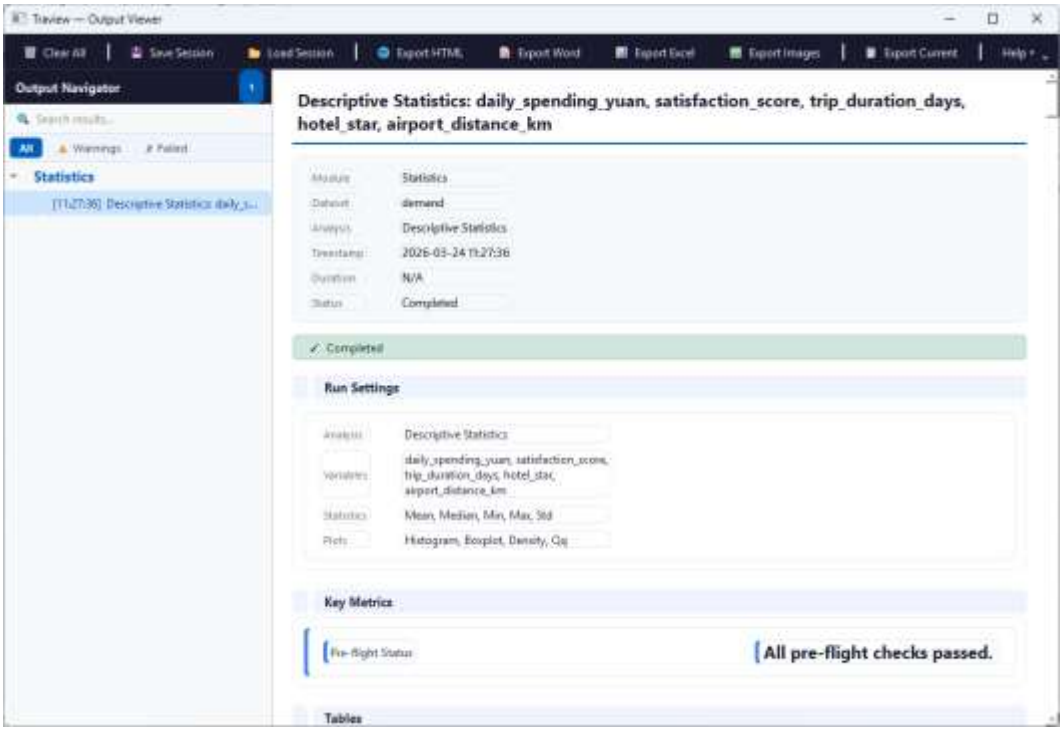

4.6 使用 Frequencies 查看分类变量分布

在完成连续变量的描述统计之后，下一步应当查看分类变量和二元变量的分布。对于本案例，最值得先查看的变量通常包括 `region`、`purpose`、`promo_used`、`post_covid` 和 `high_speed_rail`。这些变量虽然都以数字形式出现，但其真正意义在于类别或状态，而不是连续数值。

用户可以通过 **Statistics → Frequencies** 依次选择上述变量，查看它们的频数和百分比分布。这样做至少有三个好处。第一，可以帮助确认数据编码是否合理。例如，`region` 是否真的只出现 1、2、3 三个值。第二，可以帮助确认样本在不同类别间是否较均衡。若某一类别极少，后续做组间比较时就应格外谨慎。第三，可以帮助用户在正式比较之前，先对样本结构有基本认识。例如，促销使用者和未使用者大致各占多少比例，高铁开通样本和未开通样本是否接近，疫情前后样本是否分布合理。

在这一节中，用户尤其应养成一个习惯，即不要把 0/1 变量只当成“数值型列”，而要主动把它们当作两类组别去理解。因为在后面的 t 检验和政策比较中，这种理解方式会更加自然。

4.7 使用 Correlations 查看变量关系

完成基本分布检查后，用户可以通过 **Statistics → Correlations** 查看关键连续变量之间的相关关系。对于本案例，建议优先选择 `daily_spending_yuan`、`satisfaction_score`、`trip_duration_days`、`hotel_star` 和 `airport_distance_km`。如果希望把二元变量也纳入初步探索，也可以把 `promo_used`、`post_covid` 和 `high_speed_rail` 加入相关矩阵中，但在解释时应记得它们本质上是 0/1 指示变量。

相关分析的作用，不是替代后面的回归模型，而是帮助用户提前形成对变量关系方向和强弱的直观判断。例如，若 `daily_spending_yuan` 与 `hotel_star` 呈明显正相关，那么后续在回归中看到星级系数为正就不会显得意外。若 `airport_distance_km` 与消费关系很弱或方向不稳定，则后续在解释时也应更加谨慎。对于新手来说，相关矩阵最大的价值并不是统计学显著性本身，而是帮助形成对变量网络的整体认识。

若用户同时勾选了热图或散点矩阵输出，则这一节还可以自然衔接到 **Visualization**。在教学场景中，这是一种非常好的做法，因为它可以让学生看到“表格中的相关系数”和“图上的点云关系”其实是在描述同一件事情。

图 4-4 **Correlations** 参数界面。

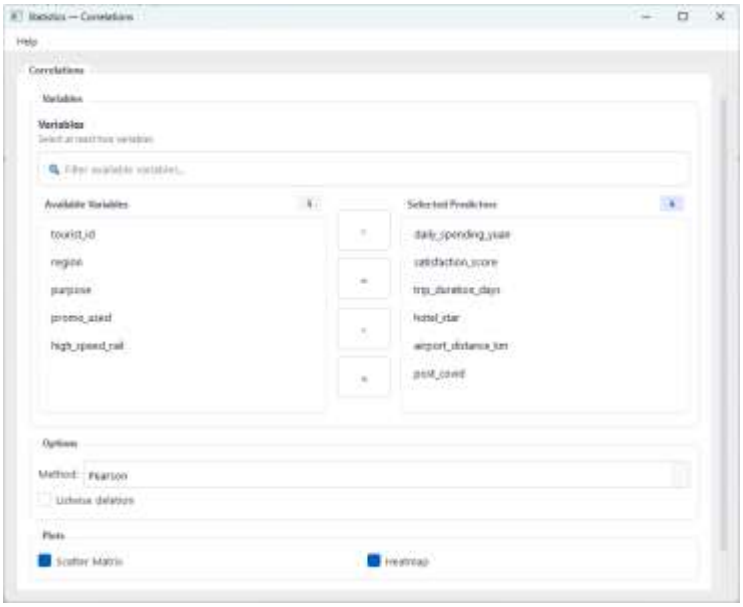

图 4-5 本案例的相关矩阵结果示例。

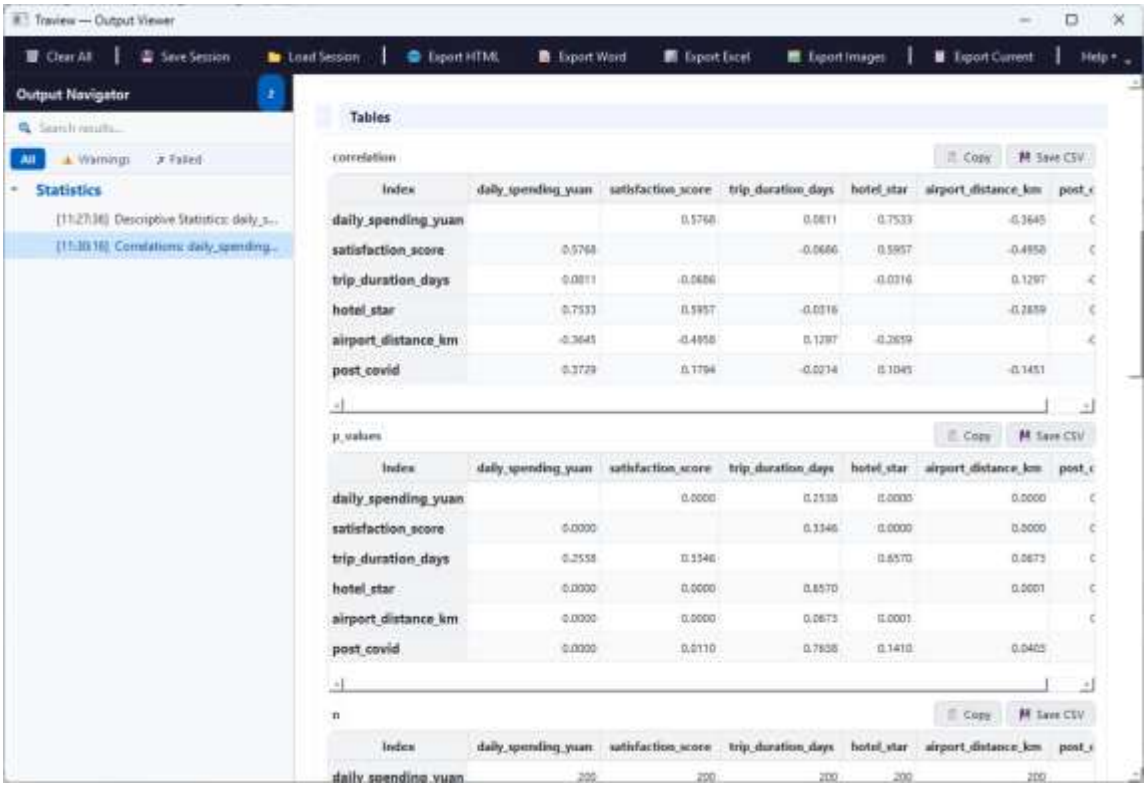

4.8 使用 T-test 比较促销与疫情前后的差异

当用户希望比较两组样本之间是否存在均值差异时，最自然的入口就是 **Statistics → T-test**。对于本案例，最推荐的两个比较对象分别是 `promo_used` 和 `post_covid`。前者可以帮助回答“使用促销的游客与未使用促销的游客，在日均消费或满意度上是否存在差异”；后者则可以帮助回答“疫情后时期与疫情前时期，在消费或满意度上是否表现不同”。

进入 **T-test** 后，若使用独立样本 t 检验，用户应把 `daily_spending_yuan` 或 `satisfaction_score` 设为数值型目标变量，把 `promo_used` 或 `post_covid` 设为分组变量。运行后，结果窗口通常会显示两组均值、均值差异和显著性结果。对于初学者来说，这一步非常适合建立“二元政策变量或状态变量可以直接作为分组工具”的理解。

在解释结果时，不能只看 p 值，而应先看两组均值的方向。例如，如果促销组的 `daily_spending_yuan` 更高，且差异显著，那么至少可以说促销使用与更高消费水平相关。至于这是否具有因果含义，则需要更深入的模型和研究设计来判断。本章作为入门案例，更强调的是“先学会做比较，再逐步学习如何更谨慎解释比较”。

图 4-6 **T-test** 参数界面。

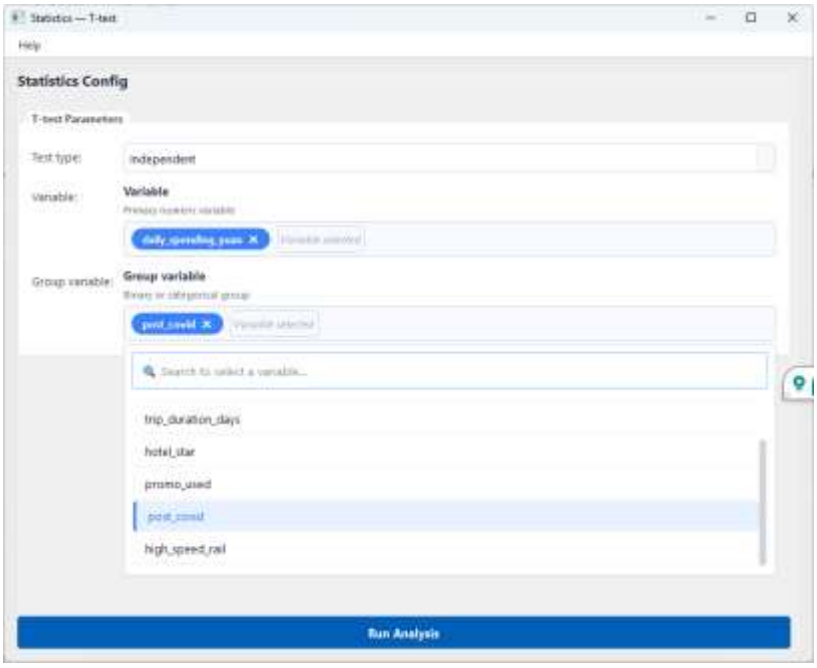

4.9 使用 ANOVA 比较地区、旅行目的与酒店星级差异

与 t 检验相比，**ANOVA** 更适合处理三个或以上类别组别之间的均值比较。对于本案例，最值得尝试的分组变量通常是 `region`、`purpose` 和 `hotel_star`。因为这三个变量都具有多个水平，且很自然地对应区域异质性、出行目的差异和住宿层级差异。

用户可以通过 **Statistics → ANOVA**，把 `daily_spending_yuan` 设为因变量，再分别选择 `region`、`purpose` 或 `hotel_star` 作为分组变量。运行后，结果会告诉用户不同地区、不同旅行目的或不同酒店星级下，消费均值是否存在整体差异。若总体 ANOVA 显著，用户还可继续查看事后比较结果，判断具体是哪些组之间存在差异。

这一节的教学意义非常大。因为它帮助用户理解：当分组不再只是“0/1 两类”时，分析路径就应从 t 检验切换到方差分析，而不是继续把多类别变量勉强塞进二组比较框架。尤其对 `purpose` 这类旅行目的变量来说，这种方法切换非常具有示范意义。

图 4-7 **ANOVA** 参数界面。

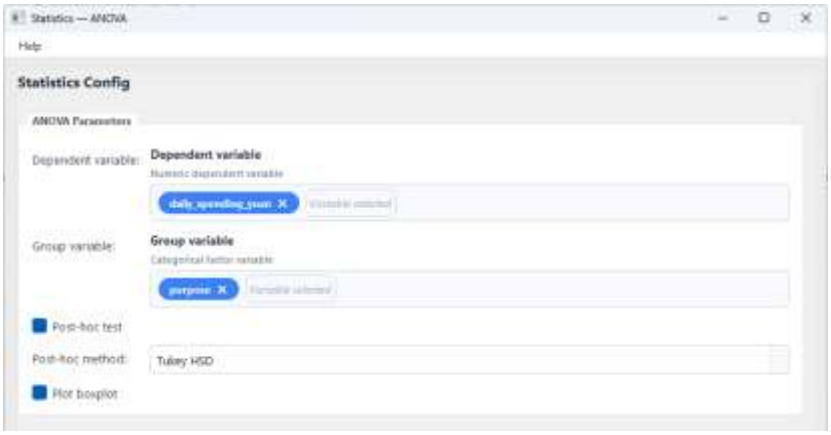

图 4-8 本案例的 ANOVA 结果示例。

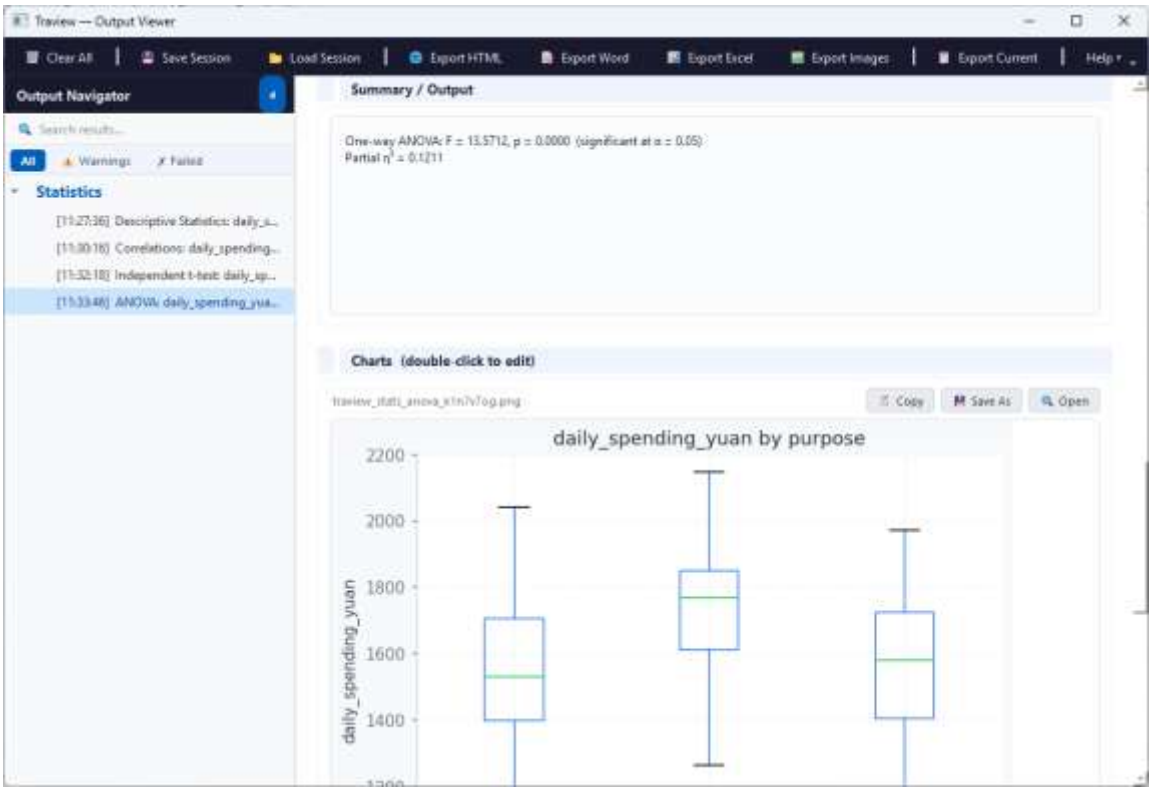

4.10 使用 Visualization 绘制基础图表

在完成描述统计和组间比较之后，本案例还应通过 **Visualization** 生成几类最基础、最有解释价值的图。对于新手来说，推荐至少完成四张图。

第一张图是 `daily_spending_yuan` 的 **Histogram**。这张图的作用是帮助理解游客消费分布是否集中，是否存在明显右偏，是否有长尾。第二张图是 `trip_duration_days` 与 `daily_spending_yuan` 之间的 **Scatter Plot**。这张图有助于观察停留时间与消费之间是否存在上升关系。第三张图可以是 `airport_distance_km` 与 `daily_spending_yuan` 之间的 **Regression Plot**，用于观察机场距离是否与消费水平存在大致线性关系。第四张图则可以是 `purpose` 或 `region` 的 **Bar Chart**，帮助快速查看样本构成。

在图表解释上，新手最需要建立的一个意识是：图形并不是结果表的附属物，而是另一种结果表达方式。很多时候，图能比表格更快地暴露数据问题，例如极端值、偏态或组别不均衡。因此，在本案例中，图表不应被视为“可做可不做”的附加部分，而应被视为基础分析路径的一部分。

图 4-9 本案例基础图表示例。

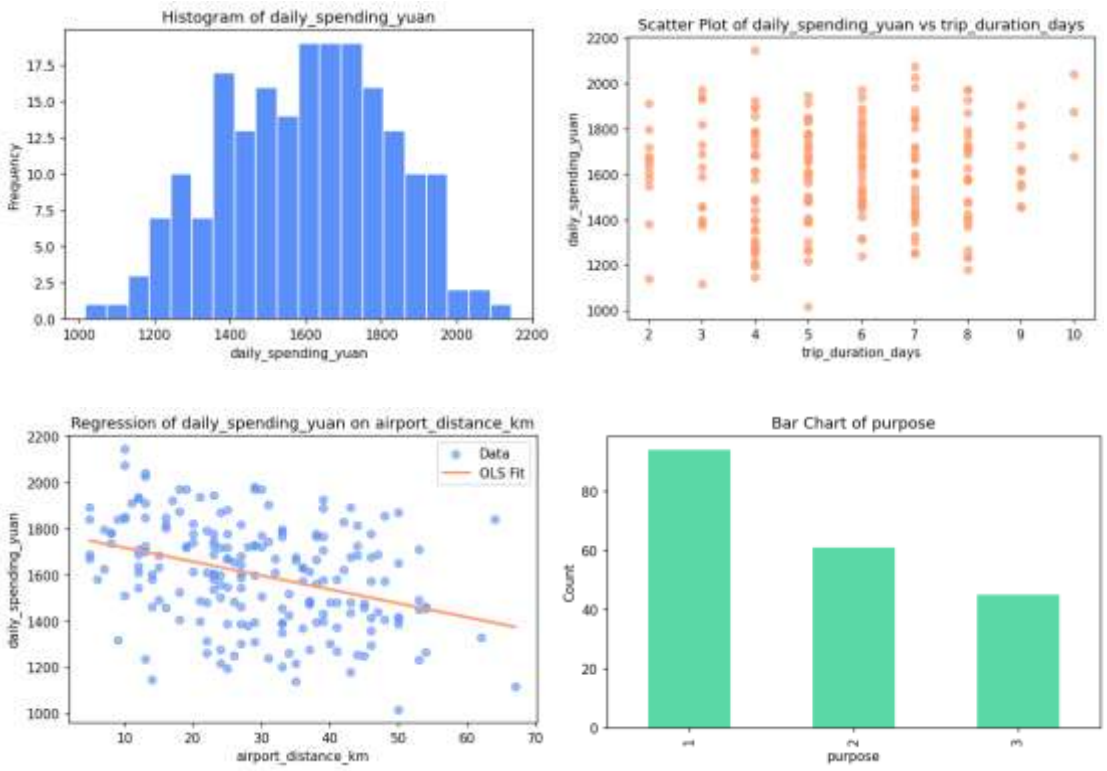

4.11 从基础统计进入简单需求分析

虽然本章主要定位为基础结构化数据案例，但这份数据本身已经非常适合进入一个最简单的需求或消费行为模型。因此，在完成前面的统计和可视化练习之后，用户可以进一步进入 **Econometrics → OLS**，建立一个最基础的消费回归模型。

作为入门练习，一个较稳妥的设定是把 `daily_spending_yuan` 作为 **Dependent variable**，再选择 `trip_duration_days`、`hotel_star`、`promo_used`、`airport_distance_km`、`post_covid` 和 `high_speed_rail` 作为解释变量。这样做的好处是，这几个变量要么是连续变量，要么是清楚的 0/1 变量，便于新手理解结果方向。相比之下，`region` 和 `purpose` 虽然也很重要，但由于它们是类别编码变量，若直接以数值方式放入 OLS，解释上更容易出问题。因此，在入门阶段，可以先把它们留作分组分析或后续扩展练习。

运行之后，用户应在 **Results Viewer** 中查看系数表。此时最重要的不是立刻过度解释所有统计细节，而是先回答几个最基本的问题。例如，停留天数是否与更高日均消费相关，酒店星级是否与更高消费相关，促销使用是否与消费存在显著差异，疫情后时期和高铁开通变量是否在方向上符合直觉。这种“从描述到回归”的过渡，是本案例非常重要的一步，因为它帮助读者意识到，统计分析和计量分析并不是彼此分裂的两套东西，而是同一条分析路径中的不同阶段。如果用户希望进一步练习，还可以勾选 **Save predicted values** 和 **Save residuals**。这样，预测值和残差就会被写回数据表，供后续图表或诊断分析使用。

图 4-10 本案例简单需求模型的 OLS 参数界面。

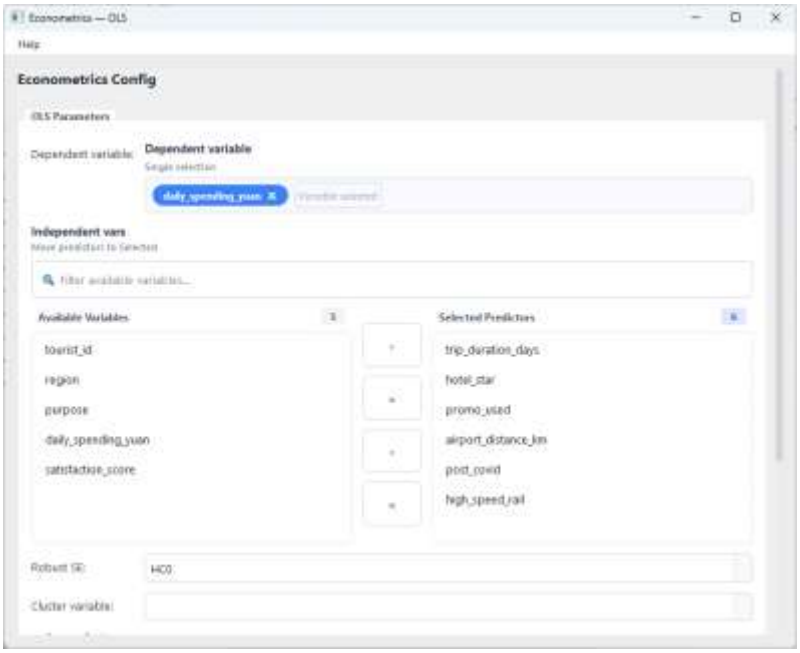

图 4-11 本案例简单需求模型的 OLS 结果示例。

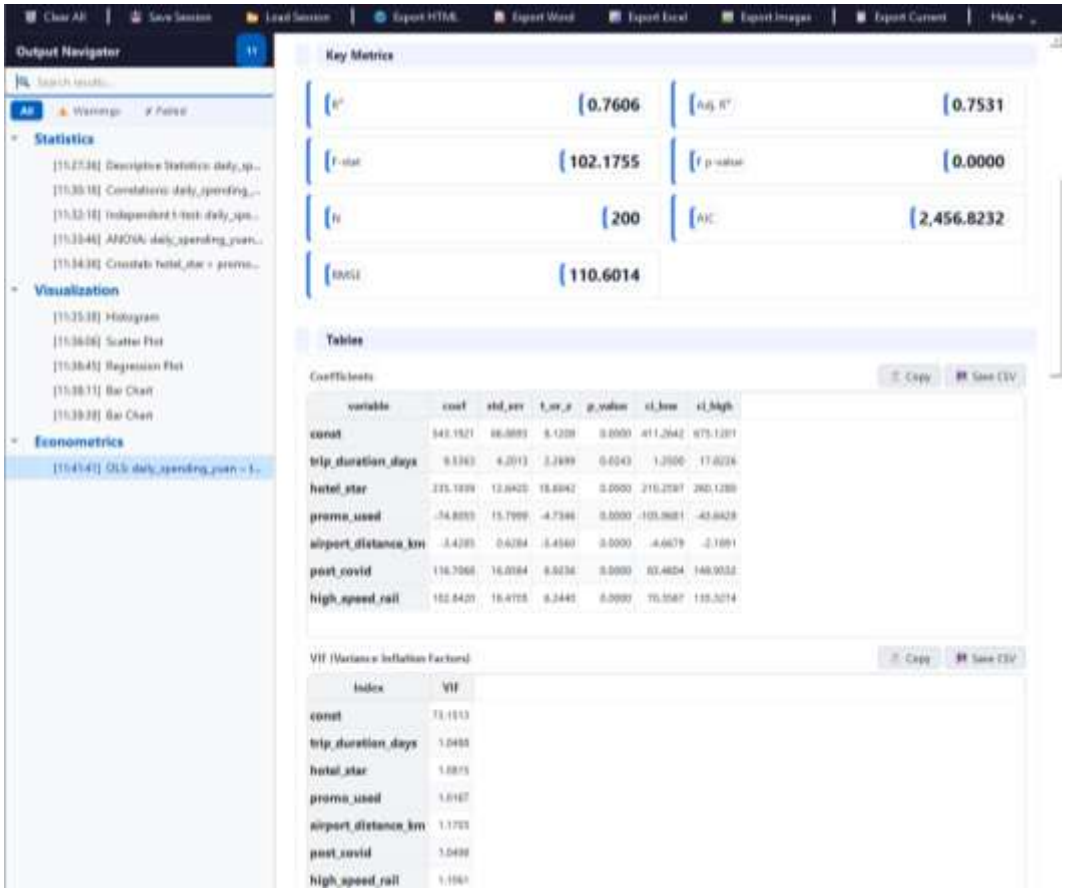

4.12 关于政策影响与工具变量回归的扩展说明

本案例的数据中包含了 `promo_used`、`post_covid`、`high_speed_rail` 和 `airport_distance_km` 这几个非常适合做扩展分析的变量。因此，虽然本章主要定位为基础实操案例，但它也为后续更深入的计量练习埋下了良好基础。

例如，`post_covid` 和 `high_speed_rail` 都可以作为政策环境或制度状态变量，用于做更正式的分期比较和政策影响分析。`promo_used` 则可以作为促销行为变量，帮助用户思考促销是否与消费变化相关。至于 `airport_distance_km`，在更高阶的研究设计中，它可以被视为一个潜在的工具变量候选，用于帮助识别某些可能存在内生性的行为变量。不过，这一类工具变量回归并不是只要“变量看起来像工具”就能直接使用，而是必须有明确的理论理由说明该变量为何与内生解释变量相关、却不直接影响误差项。因此，对初学者来说，这里更适合作为一个预告或扩展方向，而不建议在第一个案例中机械地把工具变量回归当成必做任务。

4.13 本案例中的常见错误与排查

在本案例中，最常见的问题往往并不复杂。第一类常见错误是把 `region` 和 `purpose` 这类编码变量当成普通连续变量使用，尤其是在回归中直接线性解释其系数。解决方法通常不是完全不能用，而是先明确它们本质上是分类变量，更适合做分组比较或在后续章节中进一步做虚拟变量处理。

第二类常见错误是导入后不检查变量结构，直接进入分析。虽然 `demand.csv` 本身相对干净，但即便如此，用户仍应先确认行列数是否正确、变量名是否完整。第三类问题是运行分析后没有看到结果。此时应先去 **Results Viewer**，而不是立刻重跑。第四类问题则是在结果失败时不看 **Syntax & Log（语法与日志窗口）**。如果某次 OLS 没有成功运行，通常应先查看日志中是否提示变量类型不符、结果路径问题或其他预检查错误。

还有一个容易被忽略的问题是解释顺序。很多初学者一拿到表格就只盯着显著性星号，而忽略了均值方向、变量单位和变量角色。对本案例而言，更合理的顺序通常是：先确认模型设定，再看变量方向，再看显著性，最后再考虑政策和行为含义。

4.14 本章小结

本章围绕一份游客个体层面的需求与消费数据，展示了 Traview 中最典型的一条入门分析路径。读者在本章中首先完成了数据导入和变量检查，然后依次进行了描述统计、频数分析、相关分析、t 检验、ANOVA 和基础图表绘制，最后进一步进入一个最简单的消费行为 OLS 模型。这一整套流程的意义，不只是让用户学会点击若干按钮，而是帮助用户真正形成一种软件使用顺序，即先理解数据，再比较数据，最后再进入解释性模型。

对初学者而言，只要本章能够独立完成，Traview 的最基本工作流实际上就已经建立起来了。也就是说，用户已经知道数据怎么进来，基础统计怎么做，图表在哪里生成，结果去哪里看，简单模型如何设定。这些能力会成为后续案例二、案例三以及更高级模块学习的基础。正因为如此，本章虽然是全书的第一个实操案例，却承担着非常关键的“打通软件使用路径”的作用。

第 5 章 案例二：酒店经营与市场表现数据

5.1 案例背景与研究问题

本案例使用的是一份城市层面的旅游经营与政策评估数据。数据覆盖 30 个城市、2015 至 2024 年，共 300 条观测，是一份标准的城市年度面板数据。与案例一中的游客个体横截面数据不同，这份数据的核心特征在于同时具有“城市”与“年份”两个维度，因此它不仅适合做一般回归，更适合用来演示固定效应模型与双重差分模型。

从研究问题上看，这份数据非常适合围绕政策影响展开分析。因为数据中同时包含 `treated`、`post` 和 `treat_post` 三个与处理组和政策时点有关的变量。其中，`treated` 表示某个城市是否属于处理组，`post` 表示某一年是否处于政策实施之后，而 `treat_post` 则是二者的交互项，通常也是双重差分模型中的核心解释变量。结合旅游收入这一结果变量，这份数据就能够自然地支持一个非常经典的问题：某项政策或基础设施变化是否提高了城市旅游收入。

除了政策变量之外，这份数据还包含 `population`、`gdp_per_capita` 和 `hotel_count` 等城市特征变量，因此用户还可以进一步把政策分析与城市发展水平和旅游供给条件联系起来。对 Traview 的教学和实操而言，这一案例非常重要，因为它帮助读者第一次从一般统计比较走向更正式的计量识别设计。

5.2 数据集结构说明与核心变量介绍

本案例使用的数据文件名为 `panel_data.csv`。数据共有 300 行和 9 列。每一行代表一个城市在某一年的观测值。根据实际文件结构，这份数据的变量如下所示。

变量名	含义	类型或取值	可用于的分析
`city_id`	城市编号	当前文件中为城市标识字符串，如 `City01`	面板索引、个体固定效应
`year`	年份	2015–2024	面板时间维度
`treated`	是否处理组	0/1	DID
`post`	政策后时期	0/1	DID
`treat_post`	交互项	0/1	DID 核心解释变量
`tourism_revenue`	旅游收入（万元）	连续变量	因变量
`population`	人口规模	连续变量	控制变量
`gdp_per_capita`	人均 GDP	连续变量	控制变量
`hotel_count`	酒店数量	连续变量	控制变量

需要特别说明的是，city_id 最重要的是能够稳定区分城市，而不一定必须是纯数字。反而在很多面板软件环境中，这种清楚的字符串 ID 更容易阅读。

从分析角度看，tourism_revenue 通常是本案例最核心的结果变量，因为它直接反映城市旅游经济表现。treated、post 和 treat_post 共同构成政策识别框架。population、gdp_per_capita 和 hotel_count 则是典型的控制变量，它们有助于在比较政策前后变化时，把人口规模、经济发展水平和旅游供给条件纳入考虑。

5.3 本案例的学习目标

完成本章之后，读者应能够独立完成以下几项操作。首先，能够识别一份面板数据中的个体维度和时间维度，并在 Traview 中正确检查这些变量。其次，能够使用 **Statistics** 和 **Visualization** 对面板数据做基础探索，包括旅游收入的时间变化和处理组、对照组之间的均值比较。再次，能够在 **Econometrics** 中建立基础 OLS 模型、城市固定效应模型和双重差分模型。最后，能够理解 treat_post 在 DID 框架中的含义，并在 **Results Viewer** 中查看和解释结果。

从教学角度看，本章最重要的不是让用户机械记住“固定效应模型在哪里点”，而是帮助用户理解：当数据同时有城市和年份两个维度时，分析逻辑就应从简单横截面思维转向面板思维。只要这一点真正建立起来，Traview 中更复杂的计量模型就会显得清晰很多。

5.4 导入数据与面板结构检查

本案例的第一步，是通过 **Data → Import CSV** 导入 panel_data.csv。导入后，用户首先应确认数据规模是否正确。当前文件应包含 300 行和 9 列。其次，应重点检查 city_id 和 year 这两个变量，因为它们共同决定面板结构是否成立。

在 **Data View** 中浏览时，用户应确认同一个城市会在多个年份重复出现，而不是每一行都对应一个完全不同的城市。具体来说，当前数据应包含 30 个不同城市，每个城市有 2015 到 2024 共 10 年的记录。如果这个结构被打乱，例如年份缺失、城市重复异常或样本条数不足，那么后面的面板模型就会受到影响。

用户还应特别检查 treat_post 是否确实等于 treated × post。虽然当前数据文件已给出这一列，但在教学和研究中，确认交互项是否与原始变量逻辑一致始终是一个好习惯。若交互项定义错误，则双重差分结果会直接失真。

图 5-1 导入 `panel_data.csv` 后的 **Data View**。

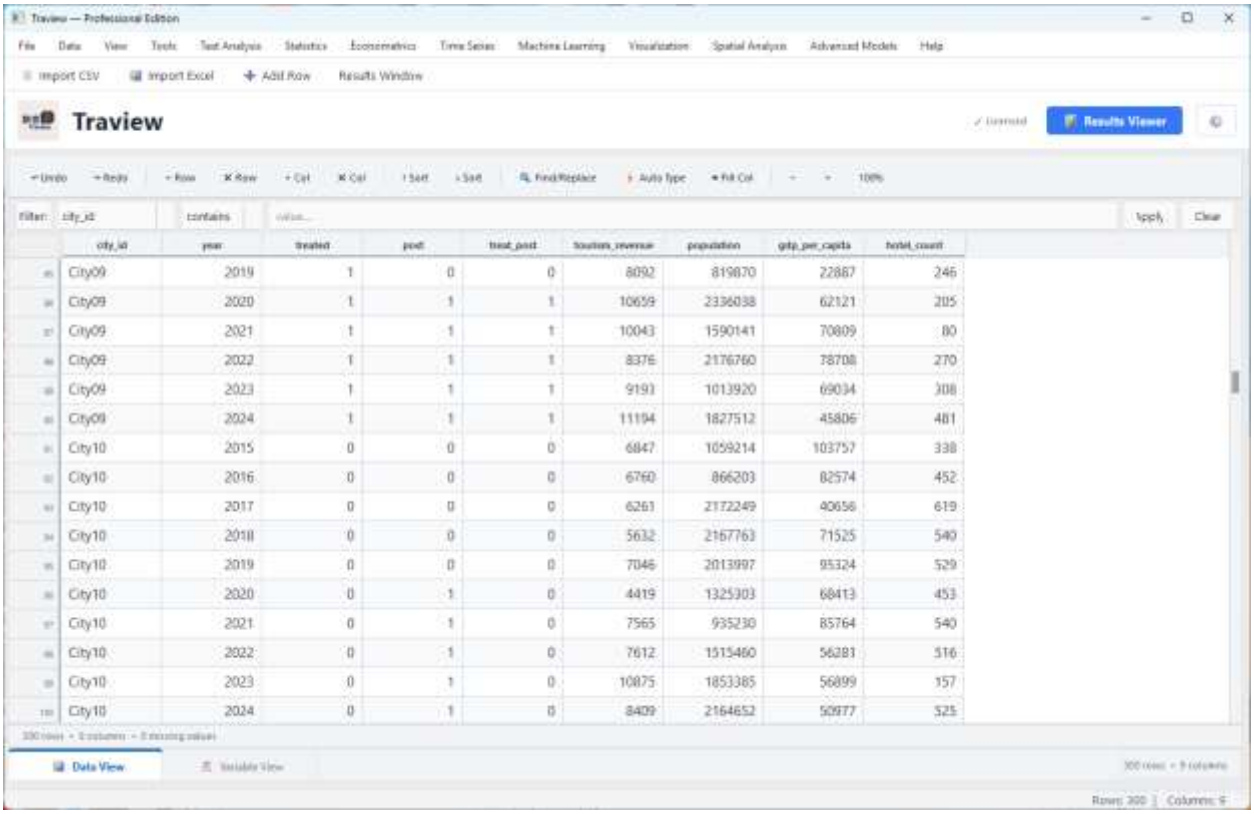

city_id	year	treated	post	treat_post	tourism_revenue	population	gdp_per_capita	hotel_count
City09	2019	1	0	0	8092	819870	22887	246
City09	2020	1	1	1	10659	2336038	62121	205
City09	2021	1	1	1	10043	1590141	70809	80
City09	2022	1	1	1	8376	2176760	78708	270
City09	2023	1	1	1	9193	1013920	69034	308
City09	2024	1	1	1	11194	1827512	45806	481
City10	2015	0	0	0	6847	1059214	103757	338
City10	2016	0	0	0	6760	866203	82574	452
City10	2017	0	0	0	6261	2172249	40656	619
City10	2018	0	0	0	5632	2167763	71525	540
City10	2019	0	0	0	7046	2013997	95324	529
City10	2020	0	1	0	4419	1325303	68413	453
City10	2021	0	1	0	7565	935230	85764	540
City10	2022	0	1	0	7612	1515460	56281	516
City10	2023	0	1	0	10875	1853385	56899	157
City10	2024	0	1	0	8409	2164652	50977	525

5.5 使用 Descriptive Statistics 查看城市旅游收入与控制变量

在进入正式计量模型之前，建议先通过 **Statistics → Descriptive Statistics** 对关键变量做一轮基础汇总。对本案例而言，建议优先选择 `tourism_revenue`、`population`、`gdp_per_capita` 和 `hotel_count`。这些变量分别对应结果变量和三个主要控制变量。

描述统计的作用有两个。第一，它帮助用户快速把握变量的大致量级。例如，旅游收入的均值和波动范围有多大，人口规模是否存在非常大的城市差异，人均 GDP 和酒店数量的离散程度是否明显。第二，它帮助用户发现极端值和异常范围。若某个城市某一年旅游收入异常偏高或偏低，后续在回归解释时就应更加谨慎。

由于本案例的数据是面板形式，用户在看描述统计时应特别注意一点，即这些数值反映的是“城市—年份观测”的整体分布，而不是单一年度或单一城市的静态情况。因此，这里的描述统计更适合作为整体概览，而不是直接替代后面的分组和时间比较。

图 5-2 本案例的 **Descriptive Statistics** 参数界面。

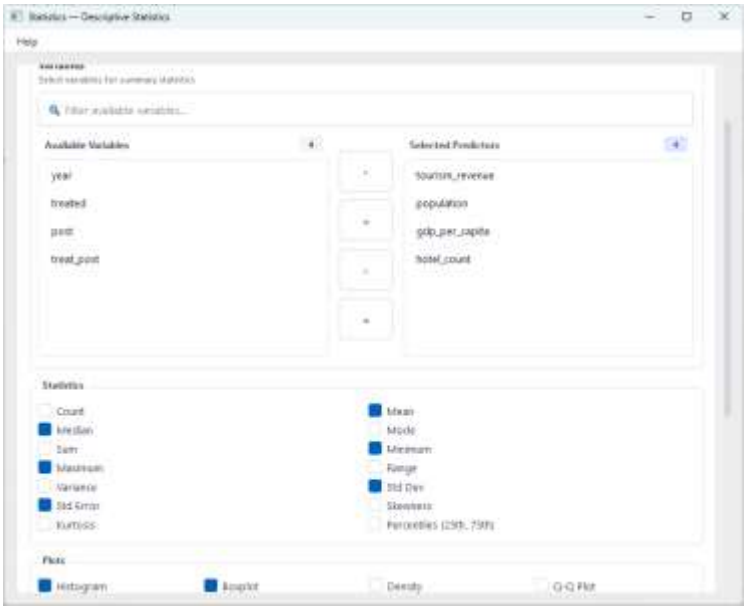

5.6 使用 Frequencies 和分组统计查看处理组与时间结构

虽然本案例以连续变量分析为主，但 `treated` 和 `post` 作为 0/1 变量，在进入 DID 之前也非常值得先做基础检查。用户可以通过 **Statistics → Frequencies** 分别查看这两个变量的分布。更重要的是，应确认处理组和对照组样本数量是否大致合理，政策前后年份划分是否与设计一致。

从 DID 的角度看，一个最基本的合理性前提是：既要有处理组，也要有对照组；既要有政策前时期，也要有政策后时期。若任意一个维度过度失衡，后续 DID 结果的解释都会明显受限。因此，在进入模型之前先做频数和分布检查，是非常有必要的。

若用户希望进一步做更直观的比较，也可以围绕 `treated` 和 `post` 做组间均值表，例如比较处理组与对照组的平均旅游收入，比较政策前与政策后的平均旅游收入。这虽然还不是 DID，但可以为后续解释提供初步直觉。

5.7 使用 Visualization 绘制时间趋势图

对于面板数据来说，仅看一张描述统计表往往不够。一个非常重要的探索步骤，是先把旅游收入的时间变化画出来。用户可以通过 **Visualization → Time Series Plot**，将 `year` 设为横轴，把 `tourism_revenue` 设为纵轴，先观察总体时间趋势。

如果当前版本支持按组别分线，则更理想的做法是分别绘制处理组与对照组的时间趋势；若界面中暂时没有直接暴露多线设置，也可以先在数据层面做分组筛选后分别作图。这样做的目的，是帮助用户初步判断政策实施前两组趋势是否大致平行，以及政策实施后处理组是否表现出明显变化。虽然这种图并不能替代正式 DID 估计，但在教学和研究写作中，它通常都是非常重要的前置图形。

除了折线图之外，用户还可以绘制 `gdp_per_capita` 与 `tourism_revenue` 之间的 **Scatter Plot**，或者画出 `hotel_count` 与旅游收入之间的 **Regression Plot**。这些图形有助于在进入面板回归之前先形成对主要控制变量作用方向的直觉。

图 5-3 旅游收入的统计图示例。

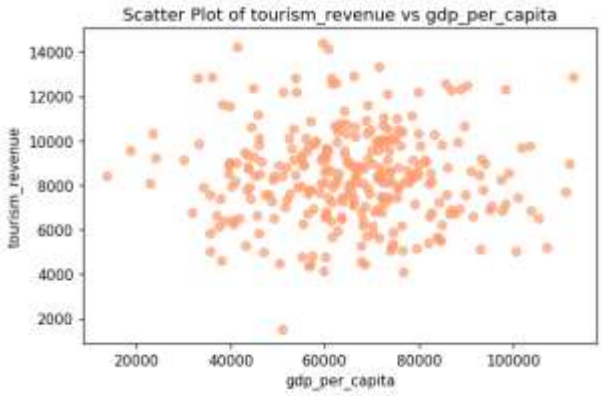

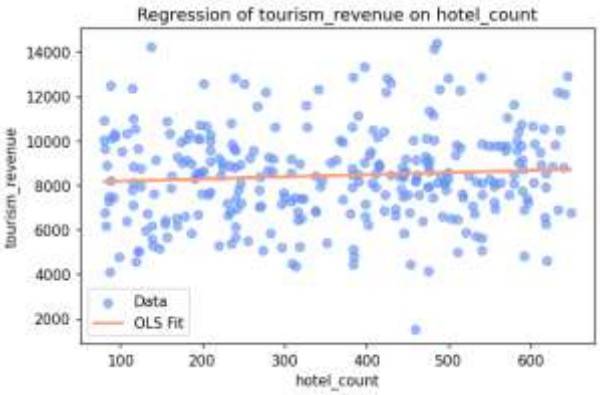

5.8 从 OLS 开始：建立最基础的回归模型

虽然本案例最终要进入固定效应和 DID，但从教学角度看，较好的顺序仍然是先从一个最基础的 OLS 开始。这样可以帮助读者看到：同样一份数据，随着模型层次的提升，解释逻辑也会逐步变化。

用户可以通过 **Econometrics → OLS**，把 `tourism_revenue` 设置为 **Dependent variable**，再把 `treated`、`post`、`population`、`gdp_per_capita` 和 `hotel_count` 放入解释变量中。这里故意暂时不加入 `treat_post`，是为了让用户先看一个“没有正式 DID 交互项”的基础模型，理解处理组和政策后时期各自的平均差异。

运行后，用户在 **Results Viewer** 中应重点看三个层面。第一，模型是否成功运行，样本量是否正常。第二，控制变量的方向是否大致符合直觉。例如，人口规模更大、酒店数量更多的城市是否更可能拥有更高旅游收入。第三，`treated` 和 `post` 各自的系数方向是什么。这一模型还不能正式识别 DID 效果，但它是一个自然的起点。

5.9 使用 Panel Models 建立固定效应模型

当读者已经完成基础 OLS 后，下一步就应进入真正更适合面板数据的模型，即固定效应模型。当前数据的核心特点是同一城市在多个年份重复出现，因此若仅做普通 OLS，就无法充分控制城市本身不随时间变化的特征差异。此时，进入 **Econometrics → Panel Models** 就变得非常自然。

在面板模型中，用户需要把 `city_id` 指定为面板个体变量，把 `year` 指定为时间变量。因变量仍然是 `tourism_revenue`，控制变量可继续使用 `population`、`gdp_per_capita` 和 `hotel_count`。若当前面板模型页面支持选择固定效应或随机效应，则本案例应优先选择固定效应。因为本章的重点正是帮助读者理解如何控制城市层面不随时间变化的异质性。

固定效应模型的核心思想，是在比较同一个城市随时间变化的基础上进行估计，而不是把所有城市简单地混在一起比较。对于初学者来说，这种解释方式非常重要。它意味着模型不再只是问“哪些城市旅游收入高”，而是在问“在同一个城市内部，随着时间推进和控制变量变化，旅游收入如何变化”。这种思维方式正是面板数据分析与普通横截面分析最大的区别。

图 5-4 **Panel Models** 参数界面。

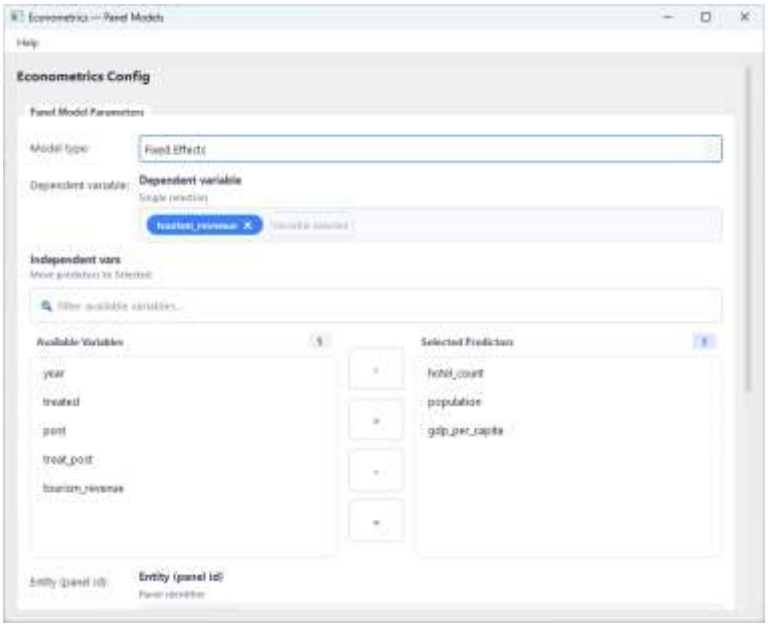

5.10 使用 DID 建立双重差分模型

本案例最关键的一步，是通过 **Econometrics → DID** 建立双重差分模型。由于数据中已经提供了 `treated`、`post` 和 `treat_post`，因此这一案例非常适合用来展示标准 DID 设定。

在 DID 页面中，用户通常需要指定因变量、处理组变量、政策后时期变量以及必要的控制变量。若页面支持直接指定交互项，也可使用 `treat_post` 作为核心解释变量。控制变量建议继续加入 `population`、`gdp_per_capita` 和 `hotel_count`。如果界面支持固定效应控制，还应加入城市和年份固定效应，因为在城市年度面板中，这通常是更完整和更稳妥的 DID 设定。

在结果解释时，`treat_post` 是最关键的系数。它所代表的不是简单的“处理组更高”或“政策后更高”，而是“处理组在政策后相对于对照组发生了多少额外变化”。换言之，它是双重差分中的净政策效应近似。对于新手来说，一定要避免把 `treat_post` 误解释为普通虚拟变量。它不是单纯表示一个组别，也不是单纯表示一个时期，而是表示两者共同作用下的差异变化。

图 5-5 **DID** 参数界面。

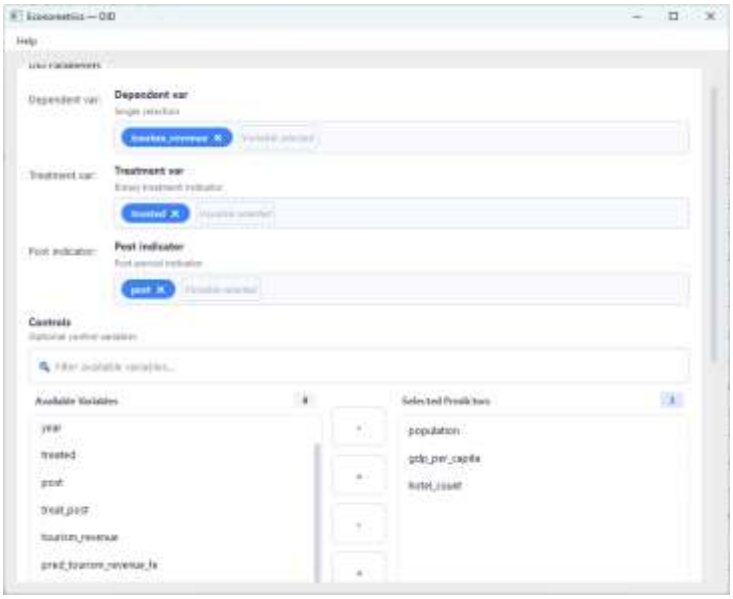

图 5-6 本案例的 DID 结果示例。

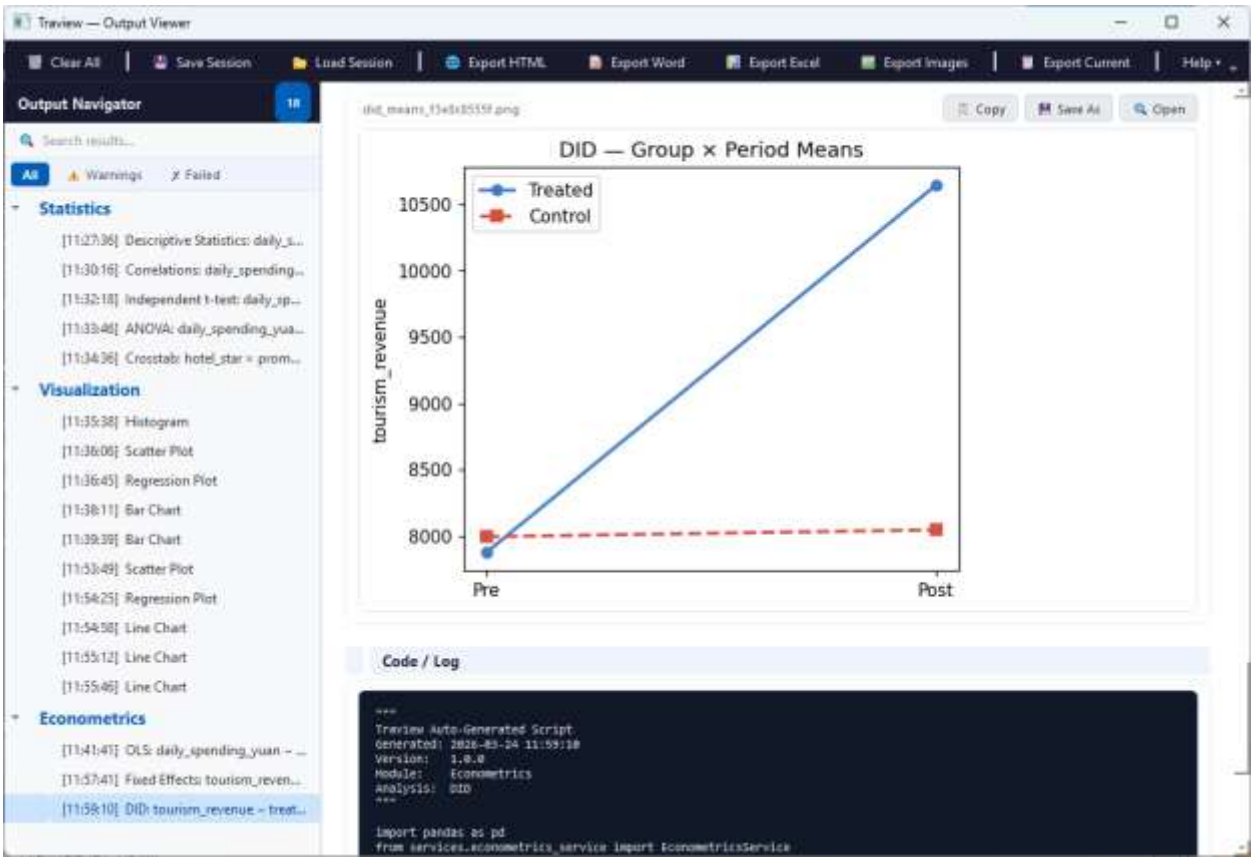

5.11 如何理解 treated、post 与 treat_post

双重差分模型中最容易让初学者困惑的，就是这三个变量到底分别代表什么。为了帮助用户真正理解，本节专门用较直白的方式说明它们的含义。

`treated` 表示一个城市是否属于处理组。它本质上是城市层面的分组变量，通常在时间上不变。
`post` 表示某一年是否处于政策实施之后。它本质上是时间层面的阶段变量。
`treat_post` 表示一个城市既属于处理组、又处于政策后时期。它是 `treated × post` 的交互结果，也是 DID 模型中最核心的变量。

如果只看 `treated`，你看到的是处理组和对照组之间的平均差异。
如果只看 `post`，你看到的是政策前后整体环境变化。
如果看 `treat_post`，你看到的才是“处理组在政策后相对于对照组的额外变化”，也就是 DID 最关心的量。

只要这一层逻辑建立起来，用户在阅读 DID 回归表时就不会再把三个变量混为一谈。

5.12 结果解释：从统计显著到经济含义

在本案例的回归和 DID 结果中，新手最容易做的事，是只盯着显著性星号看。虽然显著性很重要，但对面板数据和政策分析来说，更重要的往往是系数方向和系数量级是否具有合理经济含义。

例如，如果 `treat_post` 为正且显著，那么最自然的解释是：政策实施后，处理组城市的旅游收入相对于对照组出现了额外增长。但这并不等于立刻可以说“政策完全有效”。用户仍应进一步考虑这个系数有多大，控制变量是否合理，趋势图是否支持这种变化，以及模型是否控制了城市和年份固定效应。换言之，DID 结果的解释比一般 OLS 更强调研究设计和比较逻辑，而不是单独一个显著性数值。

对于控制变量也是如此。若 `gdp_per_capita` 为正，通常是符合直觉的，因为经济更发达的城市往往旅游市场也更活跃。若 `hotel_count` 为正，也较自然，因为旅游接待能力通常与旅游收入正相关。但如果某个系数方向明显反常，就不应立刻得出结论，而应先检查变量定义、样本结构和模型设定。

5.13 写回结果与进一步扩展

在 Traview 中，若相关模块支持，用户可以将部分模型结果写回当前数据表，例如预测值或残差。对于本案例，这样做非常有价值。因为一旦预测值和残差写回数据表，用户就可以进一步在 **Visualization** 中画出拟合与实际值比较图，或者在 **Statistics** 中检查残差分

布。这会让面板和 DID 分析不再只是停留在一张回归表上，而是进入更完整的结果诊断阶段。

此外，这份数据还适合进一步扩展两个方向。第一个方向是异质性分析。用户可以按 `treated`、`region` 或其他扩展分组做分组回归。第二个方向是政策前趋势检查。虽然本章作为入门实操不强行展开，但在正式研究中，这一步非常重要，因为 DID 的识别往往依赖平行趋势假设。若后续软件版本或课程安排允许，这部分可以作为本案例的进阶练习。

5.14 本案例中的常见错误与排查

在本案例中，最常见的问题首先来自面板变量设置错误。若用户忘记把 `city_id` 指定为个体维度，或忘记把 `year` 指定为时间维度，那么面板模型结果就可能退化为普通回归思路。第二类常见问题是对 `treat_post` 的误解。很多用户会把它和 `treated` 或 `post` 混淆，从而在解释 DID 时失去双重比较的逻辑。

第三类问题是把 DID 当作普通回归中的一个额外虚拟变量来处理，而没有意识到它本质上是在比较“变化的差异”。这会导致结果解释非常表面。第四类问题则是图形检查不足。很多学生一跑 DID 就急着看回归表，却没有先画出时间趋势图。实际上，对于政策评估类案例，趋势图往往是理解数据和后续写作中非常重要的一步。

最后，如果用户运行 DID 或 Panel Models 后没有看到结果，应先查看 **Results Viewer**，再查看 **Syntax & Log（语法与日志窗口）**。由于 Traview 的结果管理是统一窗口式的，因此“当前页面没变化”并不代表分析失败。

5.15 本章小结

本章围绕一份 30 个城市、2015 至 2024 年的面板数据，展示了 Traview 中面板分析与双重差分分析的基本使用路径。读者在本章中首先完成了面板结构检查和基础描述统计，然后通过图表查看时间趋势，再依次进入基础 OLS、固定效应模型和 DID 模型。通过这一过程，读者不仅学会了在哪里点击相应模块，更重要的是开始理解横截面分析与面板分析的区别，以及 `treat_post` 在政策评估中的真正含义。

从全书结构来看，本章的意义在于把案例一中的“基础统计和简单回归”进一步推进到“面板与识别设计”层面。只要本章真正走通，读者对 Traview 中 **Econometrics** 模块的理解就会明显深化，也会为后面进入文本、时间、空间和高级模型案例打下更扎实的基础。

第 6 章 案例三：评论文本与平台反馈数据

6.1 案例背景与文本分析任务

本案例使用的是一份酒店在线评论数据。与前两个案例主要围绕结构化数值数据展开不同，这份数据同时包含评论标题、评论正文和管理者回复文本，因此它非常适合用于展示 Traview 中 **Text Analysis** 模块的完整工作路径。当前文件共有 240 条评论记录和 21 个变量。每一行代表一条独立评论，既包含评分、住客类型、入住晚数、预订渠道、是否推荐、是否再住、是否回复等结构化变量，也包含三类文本字段，即 `review_title`、`review_comment` 和 `manager_response`。

从研究问题上看，这份数据非常具有现实代表性。因为在线评论研究通常不会只关注文本本身，而是会同时关心文本与评分、顾客行为、平台互动和酒店回复策略之间的关系。例如，评论情感是否与总评分一致，管理者是否更倾向于回复负面评论，回复延迟时间是否与评论特征有关，不同城市或不同酒店档次中的评论主题是否存在差异，这些问题都可以在本案例中得到初步练习。

对于 Traview 的教学和实操而言，这一章有两个目标。第一个目标，是让读者真正学会如何在 **Text Analysis** 中选择文本列、设置预处理、运行词频、情感、主题和相似性分析，并把结果写回数据表。第二个目标，是让读者意识到文本分析并不是一个与其他模块隔离的“孤立世界”。恰恰相反，文本分析的价值往往在于把评论文本转化为结构化特征，再与评分、回复行为和用户属性结合起来，进入后续统计与计量分析。

6.2 数据集结构说明与核心变量介绍

本案例使用的数据文件名为 `review.csv`。数据共有 240 行和 21 列。每一行代表一条酒店评论记录。根据实际文件结构，这份数据的变量如下所示。

6.2.1 结构化变量

变量名	含义	类型或取值	可用于的分析
`review_id`	评论编号	当前文件中为文本型唯一代码，如 `REV001`	唯一识别
`hotel_id`	酒店编号	整数	分组汇总
`city`	城市	分类变量	地区比较
`hotel_segment`	酒店档次	分类变量	分组分析
`traveler_type`	住客类型	分类变量	用户画像、异质性分析
`stay_length_nights`	入住晚数	连续变量	回归、自变量
`booking_channel`	预订渠道	分类变量	组间比较

review_month	评论月份	当前文件中为 YYYY-MM 形式	趋势分析
rating_overall	总评分	连续变量	因变量、结果变量
rating_cleanliness	清洁评分	连续变量	子维度分析
rating_service	服务评分	连续变量	子维度分析
rating_location	位置评分	连续变量	子维度分析
helpful_votes	有帮助票数	计数变量	评论影响力分析
sentiment_label	情感标签	positive / neutral / negative	分类比较
would_recommend	是否推荐	0/1	Logit、自变量或因变量
revisit_intention	是否再住	0/1	Logit、自变量或因变量
response_given	是否回复	0/1	服务补救研究
response_delay_days	回复延迟天数	连续变量，当前文件中对未回复评论为空	响应时效分析

6.2.2 文本变量

变量名	含义	类型	可用于的分析
review_title	评论标题	文本	关键词、情感分析
review_comment	评论正文	文本	主题模型、文本分类、情感分析
manager_response	管理回复	文本	回复策略、服务补救、文本对比

需要特别说明两点。第一，review_id 当前实际文件中它表现为文本型唯一代码，例如 REV001。这不会影响分析，因为它的核心作用只是唯一识别评论。第二，response_delay_days 和 manager_response 在当前文件中各有 50 条缺失值，这与 response_given = 0 完全一致，也就是说，没有回复的评论自然不会有回复文本和回复延迟天数。这一点在后续分析中非常重要，因为它说明某些缺失并不是“数据错误”，而是业务逻辑上的自然缺失。

从数据类别上看，这份数据几乎是一个非常理想的文本分析教学案例。因为它既有评论文本，也有情感标签、评分维度和回复行为变量，可以自然展示“文本分析如何服务于更广泛的行为研究”。

6.3 本案例的学习目标

完成本章之后，读者应能够独立完成以下几项操作。首先，能够导入一份带有文本字段和结构化字段的评论数据，并在 **Data View** 和 **Variable View** 中区分哪些列是文本、哪些列是数值、哪些列是类别变量。其次，能够在 **Text Analysis** 中完成文本预处理、词频分析、n-gram 分析、情感分析、主题建模、关键词检索和文本相似性分析。再次，能够将

情感得分、主导主题或关键词命中结果写回数据表。最后，能够把这些文本特征与结构化变量结合起来，进入更进一步的统计和行为分析。

更重要的是，本章希望帮助读者建立一个认识，即评论数据并不是“只有文本”的数据。真正有价值的研究通常发生在文本与行为变量交叉的地方。例如，负面评论是否更容易得到回复，回复越快是否更可能对应更高的再住意愿，某类主题是否更多出现在某类酒店档次中。这种把文本与结构化行为结合起来的思路，是本案例最重要的方法训练目标。

6.4 导入数据与文本变量检查

本案例的第一步，是通过 **Data → Import CSV** 导入 `review.csv`。导入之后，用户首先应确认数据规模是否正确。当前文件应包含 240 行和 21 列。若行列数明显不同，应先检查原始文件，而不是直接进入文本分析。

在 **Data View** 中浏览时，用户最应先看三类字段。第一类是文本字段，也就是 `review_title`、`review_comment` 和 `manager_response`。用户应确认这些列中的内容是否可读、是否没有乱码，以及文本长度是否大体合理。第二类是评分和行为变量，例如 `rating_overall`、`helpful_votes`、`would_recommend`、`revisit_intention` 和 `response_given`。这些变量将构成后续文本结果解释的结构基础。第三类是分组变量，例如 `city`、`hotel_segment`、`traveler_type` 和 `booking_channel`。这些变量将帮助我们在文本分析之后进一步做异质性比较。

接下来，用户应进入 **Variable View**，确认文本字段被识别为对象型或文本型，评分列和计数列被识别为数值型，`review_month` 被读为可排序的时间字符串。当前文件中，`review_month` 采用 `YYYY-MM` 形式，例如 `2025-04`、`2025-11` 等，这对于趋势分析来说已经比较友好，但在做真正时间序列模型之前，仍应先确认它的顺序性和格式一致性。

图 6-1 导入 `review.csv` 后的 **Data View**。

	review_id	hotel_id	city	hotel_segment	traveler_type	stay_length_nights	booking_channel	review_month	rating_overall	rating_cleanliness	rating_service	rating_loc.
1	REV001	1011	Chengdu	Upscale	Solo	2	Corporate	2025-04	4.3	3.8	4.4	
2	REV002	1005	Chengdu	Budget	Business	4	OTA	2025-03	3.5	3.7	3.8	
3	REV003	1010	Shenzhen	Midscale	Couple	2	OTA	2025-11	3.5	3.5	3.7	
4	REV004	1005	Chengdu	Budget	Business	2	Direct	2025-09	4.0	3.7	4.5	
5	REV005	1003	Guangzhou	Upscale	Couple	5	Direct	2025-05	4.9	4.5	5.0	
6	REV006	1008	Shanghai	Luxury	Family	4	Travel Agent	2025-01	3.6	4.1	4.1	
7	REV007	1006	Hangzhou	Midscale	Business	6	Direct	2025-09	4.1	3.8	3.9	
8	REV008	1002	Shanghai	Midscale	Business	2	Direct	2025-03	3.5	3.6	3.5	
9	REV009	1002	Shanghai	Midscale	Couple	4	Direct	2025-04	4.8	4.8	5.0	
10	REV010	1007	Beijing	Upscale	Couple	3	OTA	2025-07	3.6	4.0	4.1	
11	REV011	1008	Shanghai	Luxury	Couple	5	Travel Agent	2025-08	4.7	4.6	4.5	

6.5 从结构化字段开始认识评论数据

虽然本章的重点是文本分析，但在进入文本模块之前，仍建议先用几分钟认识一下结构化字段。因为评论研究里最常见的错误之一，就是只看评论文本，而忽略了评论发生在什么用户、什么城市、什么酒店和什么行为背景之下。

用户可以先通过 **Statistics → Frequencies** 查看 `city`、`hotel_segment`、`traveler_type`、`booking_channel` 和 `sentiment_label` 的分布。当前文件中，城市主要包括 Beijing、Shanghai、Guangzhou、Shenzhen、Hangzhou 和 Chengdu。酒店档次包括 Budget、Midscale、Upscale 和 Luxury。住客类型包括 Solo、Business、Couple 和 Family。预订渠道包括 Corporate、OTA、Direct 和 Travel Agent。情感标签则包括 positive、neutral 和 negative。

接着，用户还可以对 `rating_overall`、`rating_cleanliness`、`rating_service`、`rating_location`、`helpful_votes` 和 `response_delay_days` 做一次 **Descriptive Statistics**。这样做的意义在于，为后面解释文本结果建立背景。例如，如果大多数评论总体评分较高，那么词频中高频正面词较多就是可以预期的；如果 `response_delay_days` 波动很大，则后续在研究回复策略时就会有更自然的问题意识。

6.6 在 Text Analysis 中选择文本列与预处理方式

完成结构化检查后，用户可以通过 **Text Analysis** 打开文本分析模块。第一次进入本模块时，建议先把主要分析对象放在 `review_comment` 上，因为评论正文通常比标题更丰富，也比管理回复更能代表住客真实体验。后续若需要，再扩展到 `review_title` 或 `manager_response`。

在 **Text column** 中选择 `review_comment` 后，用户应进入 **Preprocessing**。对于当前这类英文评论数据，第一次练习通常建议勾选 **Lowercase** 和 **Remove punctuation**。若希望提升词频和主题结果的可解释性，还可以勾选 **Remove stopwords**。**Remove numbers** 是否勾选则取决于研究目的。若评论中数字本身并不重要，可以勾选；若评论中存在像“5 minutes from subway”这类数字表达，而用户又希望保留这些信息，则应更谨慎。

在 **Min token length** 中，通常可以使用默认值，或者设为 2，以去掉一些单字母噪声词。需要特别提醒的是，预处理不是“勾得越多越好”。例如，如果后续打算做可读性分析或研究原始语言风格，就不宜过度清洗。因此，在每次分析前都应先想清楚，这一步分析到底是为了“压缩语言噪声”，还是为了“保留原始表达”。

图 6-2 **Text Analysis** 中的文本选择与预处理设置。

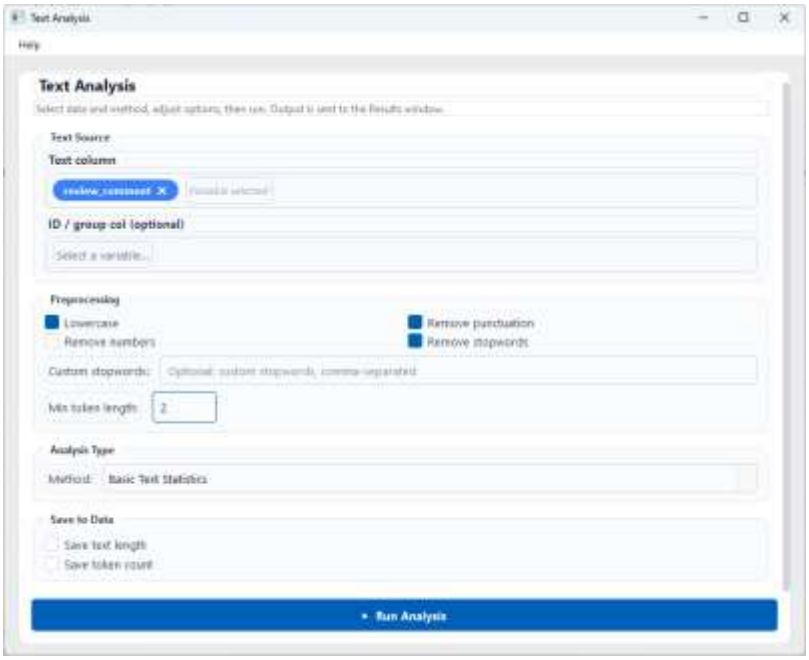

6.7 使用 Basic Text Statistics 查看文本基本特征

在正式进入词频和情感分析之前，建议先运行 **Basic Text Statistics**。这一方法的作用，是帮助用户先理解评论文本本身的规模和复杂度，而不是立刻进入语义解释。对于本案例，用户可以通过它查看评论文本数量、平均长度、平均词数和平均句子数。

这一步看起来简单，但非常重要。因为如果文本本身特别短、空值很多或长度差异极大，那么后面的主题建模和相似性分析效果通常也会受到影响。对于当前这份数据而言，`review_comment` 内容普遍较为完整，因此适合继续做更深入文本分析。若用户愿意，还可以在 **Save to Data** 中勾选 **Save text length** 或 **Save token count**。这样，评论长度就会写回数据表，成为一个新的结构化变量，后续可以分析“评论越长是否越容易获得 helpful votes”这类问题。

6.8 使用 Word Frequency 分析高频词

完成基础文本统计之后，最适合作为第一项正式文本分析的，通常是 **Word Frequency**。用户在 **Analysis Type** 中选择该方法后，可以设定 **Top N words**，例如 20 或 30，然后运行。对当前评论数据来说，这一步能够帮助用户快速回答“住客最常在评论中谈论什么”。

在解释词频结果时，用户应把它当作文本内容的第一层概览，而不是最终结论。例如，高频词若集中在 `room`、`staff`、`clean`、`location`、`breakfast` 等词上，通常意味着这些是

评论的主要内容维度。若出现过多无意义的高频词，则应回头检查停用词和预处理设置是否合理。

在教学中，这一步尤其适合与评分变量联动解释。例如，如果高频词中大量出现服务和清洁相关词，而 `rating_service` 和 `rating_cleanliness` 也恰好是数据中的评分维度，用户就能更自然地理解“文本内容”和“结构化评分维度”其实是在描述相近的服务体验。

图 6-3 本案例的高频词结果示例。

6.9 使用 N-gram Frequency 分析常见短语

在评论研究中，单词本身固然重要，但很多更具体的体验表达其实依赖短语而不是单个词。因此，本案例非常适合继续使用 **N-gram Frequency**。一般来说，可以先从二元短语开始，也就是把 **N** 设为 2。

与单个词相比，n-gram 更容易反映真实语义片段。例如，`front desk`、`customer service`、`great location`、`clean room` 这类短语，比单独的 `desk`、`service` 或 `clean` 更具有具体解释力。因此，当用户在做服务评价研究或评论分类研究时，n-gram 往往比单词频率更接近实际表达。

对于这份数据，建议在词频分析之后立刻运行一次二元短语分析，并将结果与评分维度进行对照阅读。这样能帮助读者意识到，评论中的语言模式并不是抽象的“文本”，而是真正与服务、位置、清洁和住宿体验相对应的表达结构。

6.10 使用 Sentiment Analysis 进行情感分析

Sentiment Analysis 是本案例中最核心的方法之一。虽然数据已经给出了一个现成的 `sentiment_label` 字段，但这并不意味着软件中的情感分析就失去意义。恰恰相反，本案例非常适合用 Traview 重新从 `review_comment` 中自动提取情感得分，再与原始标签、评分和推荐意愿进行比较。

用户在 **Analysis Type** 中选择 **Sentiment Analysis** 后，软件会为每条评论计算情感分数和情感类别。运行之后，结果中通常会出现情感分布表、样本文本预览表和情感图形。若在 **Save to Data** 中勾选 **Save sentiment score** 和 **Save sentiment label**，则新的情感结果还会写回数据表。

这一步最有教学价值的部分，是比较“文本情感”和“结构化评分”之间的一致性。例如，用户可以后续检查文本情感得分是否与 `rating_overall` 正相关，正向评论是否更可能对应 `would_recommend = 1`，负向评论是否更容易触发酒店回复。通过这种比较，读者会非常直观地看到文本分析结果并不是悬浮在空中的，而是可以真正回到行为变量中发挥作用。

图 6-4 本案例的 **Sentiment Analysis** 结果示例。

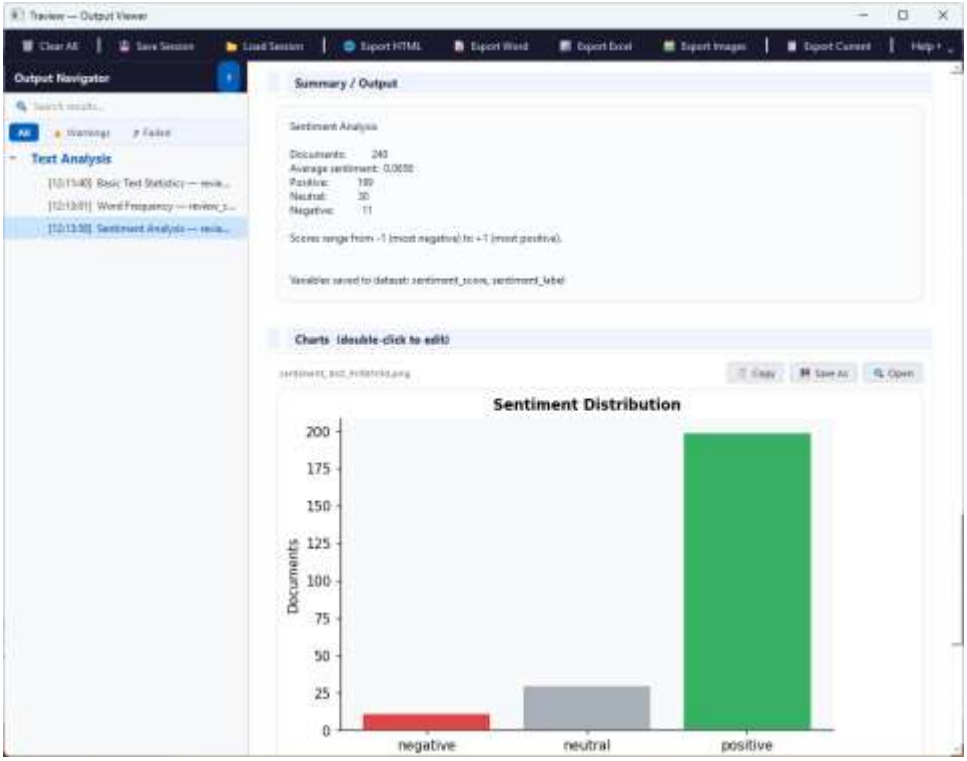

6.11 使用 Topic Modeling 提取评论主题

当读者已经理解词频和情感后，下一步非常适合进入 **Topic Modeling**。这一方法的目标，不是判断评论“正面还是负面”，而是判断评论“主要在谈哪些方面”。对于酒店评论数据，这一步尤其有意义，因为它通常能够提取出围绕清洁、服务、位置、早餐、房间、交通等方面的潜在主题结构。

在当前版本中，用户可以设定 **Number of topics** 和 **Top words per topic**。第一次练习时，不建议把主题数设得太多，通常 3 到 5 个主题已经足够观察基本结构。运行之后，软件会给出每个主题对应的高频代表词，以及每条评论的主导主题。若勾选 **Save dominant topic** 和 **Save topic probability**，这些结果会写回数据表。

这一步的关键，不是机械记住“主题 1、主题 2、主题 3”，而是学会命名和解释主题。例如，一个由 `room`、`clean`、`bathroom` 组成的主题，可以被理解为清洁与住宿环境主题；一个由 `staff`、`check`、`friendly` 组成的主题，则更接近服务接待主题。只有经过这种解释，主题建模结果才真正转化为可研究的内容。

图 6-5 本案例的 **Topic Modeling** 结果示例。

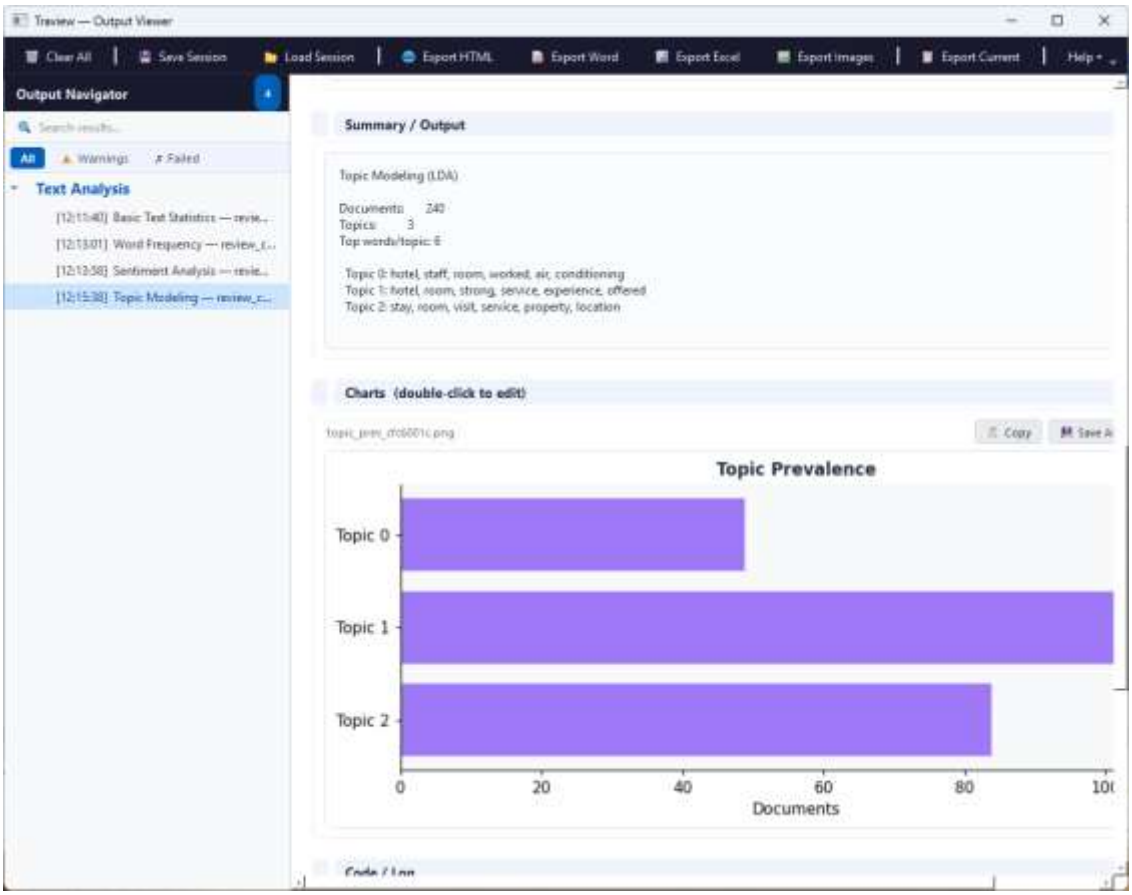

6.12 使用 Keyword Occurrence 检测特定服务问题

除了让软件自动提取高频词和主题，本案例还非常适合做定向关键词分析。用户可以通过 **Keyword Occurrence**，手动输入若干关注词，例如 `clean`, `staff`, `location`, `noise`, `breakfast`, `delay` 等，然后查看这些关键词在评论中出现的频率和覆盖情况。

这种方法非常适合服务质量研究，因为它让研究者能够带着问题去文本中找证据。例如，如果你想知道住客是否经常提到噪音问题，就可以直接把 `noise` 作为关键词；如果想研究评论中对员工服务的提及频率，就可以重点检索 `staff` 或 `service`。在 **Save to Data** 中勾选 **Save keyword hit flag** 或 **Save keyword count** 后，关键词命中结果还可以回到数据表中，为后续 Logit 或 OLS 提供自变量。

例如，用户完全可以进一步研究：提到 `noise` 的评论是否更不容易推荐酒店；提到 `staff` 的评论是否更容易获得管理回复。这就是文本分析与行为研究结合的一个非常自然的例子。

6.13 使用 TF-IDF Summary 提取区分性表达

如果说词频强调“出现得多”，那么 **TF-IDF Summary** 强调的就是“具有区分度”。对于酒店评论数据，这一点非常重要，因为有些词虽然高频，但其实在几乎所有评论中都出现，因此区分不同评论的能力并不强。TF-IDF 则帮助用户找出那些对特定评论更有代表性的关键词。

在当前版本中，用户可以设定 **Max features** 和 **Top N terms**。运行后，软件会给出整体重要词项，以及每条评论的代表性关键词。这一结果特别适合用来快速浏览某条评论的“核心表达”，也适合为后续相似性分析提供基础。

从研究角度看，TF-IDF 最适合帮助用户回答这样的问题：哪些评论表达得更“具体”、更“有辨识度”？哪些酒店回复中使用了更有针对性的词汇？虽然这类问题在基础教学阶段不一定展开得很深，但让学生先接触这种“区分性表达”的概念，是非常有帮助的。

6.14 使用 Text Similarity 与 Nearest-Neighbor Search 比较评论

酒店评论数据中还有一个非常有趣的分析方向，就是寻找彼此相似的评论。用户可以通过 **Text Similarity** 查看最相似的评论对，也可以通过 **Nearest-Neighbor Search** 为每条评论寻找最接近的其他评论。

在教学中，这一步特别适合说明两件事。第一，评论文本其实可以被表示成特征空间中的对象，因此“相似性”是可以计算的。第二，相似评论不一定评分相同，但往往主题接近、表达接近或体验接近。对于平台治理、评论聚类和模板化识别来说，这类分析都很有用。

若用户勾选 **Save NN similarity score** 或 **Save nearest-neighbor index**，则相似性结果还可以进一步写回数据表。之后，完全可以研究“高度相似评论是否更容易来自同一酒店”“相似评论的 helpful votes 是否更接近”等问题。

图 6-6 本案例的 **Text Similarity** 结果示例。

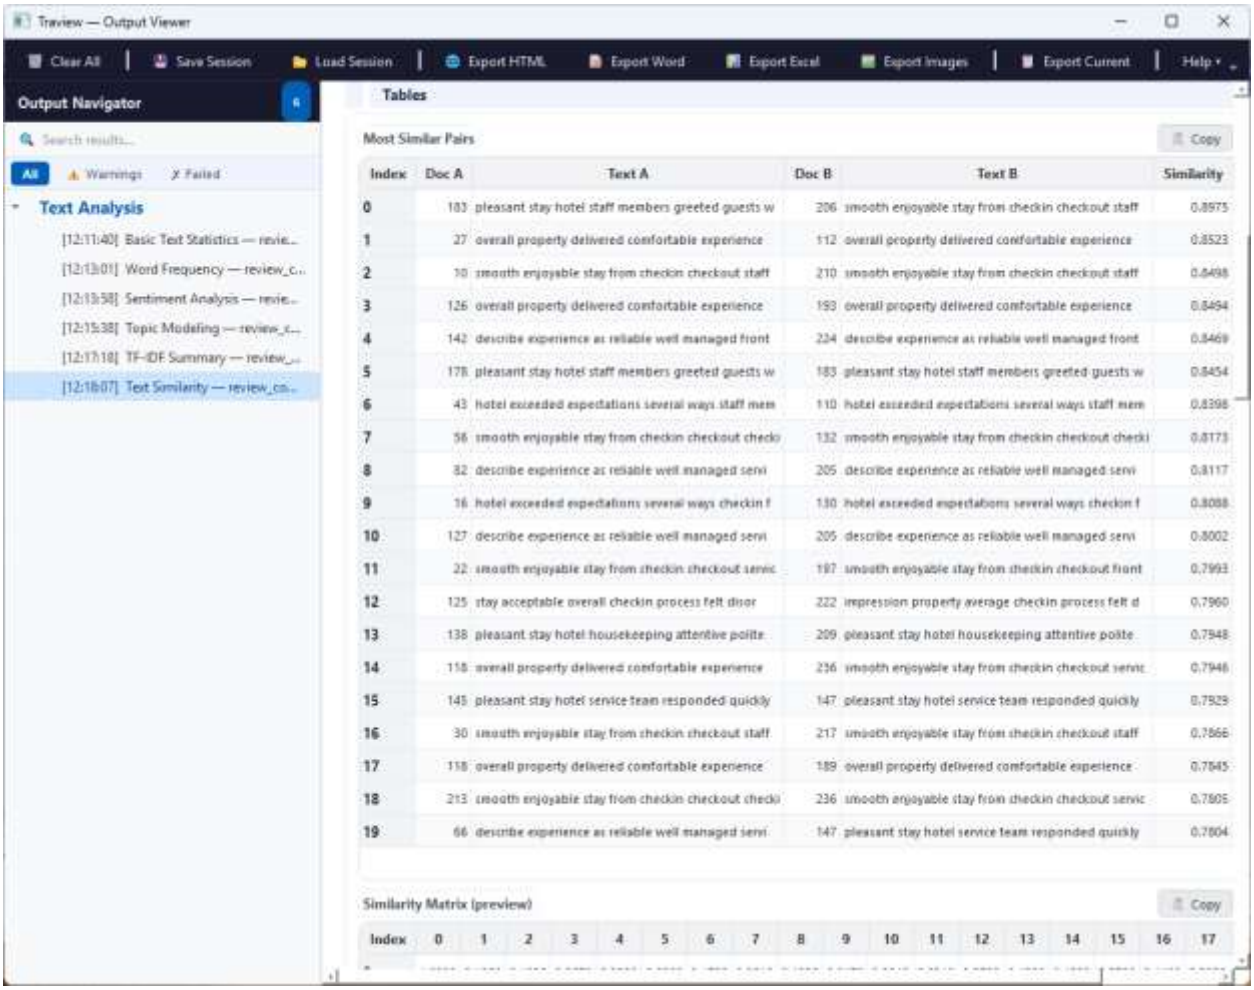

Index	Doc A	Text A	Doc B	Text B	Similarity
0	183	pleasant stay hotel staff members greeted guests w	206	smooth enjoyable stay from checkin checkout staff	0.8975
1	27	overall property delivered comfortable experience	112	overall property delivered comfortable experience	0.8523
2	10	smooth enjoyable stay from checkin checkout staff	210	smooth enjoyable stay from checkin checkout staff	0.8498
3	126	overall property delivered comfortable experience	193	overall property delivered comfortable experience	0.8494
4	142	describe experience as reliable well managed front	224	describe experience as reliable well managed front	0.8469
5	178	pleasant stay hotel staff members greeted guests w	183	pleasant stay hotel staff members greeted guests w	0.8454
6	43	hotel exceeded expectations several ways staff mem	110	hotel exceeded expectations several ways staff mem	0.8398
7	56	smooth enjoyable stay from checkin checkout checki	132	smooth enjoyable stay from checkin checkout checki	0.8173
8	82	describe experience as reliable well managed servi	205	describe experience as reliable well managed servi	0.8117
9	16	hotel exceeded expectations several ways checkin f	130	hotel exceeded expectations several ways checkin f	0.8088
10	127	describe experience as reliable well managed servi	205	describe experience as reliable well managed servi	0.8002
11	22	smooth enjoyable stay from checkin checkout servic	197	smooth enjoyable stay from checkin checkout front	0.7993
12	125	stay acceptable overall checkin process felt disor	222	impression property average checkin process felt d	0.7960
13	138	pleasant stay hotel housekeeping attentive polite	209	pleasant stay hotel housekeeping attentive polite	0.7948
14	118	overall property delivered comfortable experience	236	smooth enjoyable stay from checkin checkout servic	0.7946
15	145	pleasant stay hotel service team responded quickly	147	pleasant stay hotel service team responded quickly	0.7929
16	30	smooth enjoyable stay from checkin checkout staff	217	smooth enjoyable stay from checkin checkout staff	0.7866
17	118	overall property delivered comfortable experience	189	overall property delivered comfortable experience	0.7845
18	213	smooth enjoyable stay from checkin checkout checki	236	smooth enjoyable stay from checkin checkout servic	0.7805
19	66	describe experience as reliable well managed servi	147	pleasant stay hotel service team responded quickly	0.7804

Index	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17

6.15 将文本结果写回数据表

本案例最重要的一步之一，就是把文本结果写回数据表。因为只有当文本结果成为新变量时，文本分析才真正从“看词”变成“做研究”。当前版本中，用户可以根据不同方法写回不同结果。例如，情感分析可以写回 `sentiment_score` 或新的情感标签，主题模型可以写回 `dominant_topic`，关键词分析可以写回关键词命中标记和次数，基础文本统计可以写回文本长度与词数。

对新手来说，建议至少完成一次情感得分写回和一次主导主题写回。这样，当前活动数据表中就会新增一组与文本相关的结构化变量。用户之后可以回到 **Data View** 中看到这些新列，并进一步把它们送入 **Statistics**、**Econometrics** 或 **Machine Learning**。这一步对于理解 Traview 的整体逻辑非常关键，因为它展示了模块之间并不是孤立的，而是可以通过数据表彼此衔接。

6.16 结合 Statistics 继续分析文本结果

当情感得分、主题类别或关键词命中已经写回数据表之后，最自然的下一步是回到 **Statistics** 模块继续分析。比如，用户可以用 **Correlations** 检查 `sentiment_score` 与 `rating_overall`、`rating_service` 和 `helpful_votes` 之间的关系。也可以用 **T-test** 比较 `response_given = 1` 与 `response_given = 0` 两组评论在情感得分上的差异。还可以用 **ANOVA** 比较不同 `hotel_segment` 或不同 `city` 下主导主题的分布差异。

这一节的教学意义在于，它帮助读者真正走出“文本分析只是看词云或词频图”的狭窄理解。文本分析模块本身固然重要，但它更大的价值在于生成可以与评分、推荐、回复和评论影响力相结合的新变量。只有当读者意识到这一点，Traview 中 **Text Analysis** 才真正成为一个强大的研究工具，而不只是一个演示页面。

6.17 结合 Econometrics 研究评论行为与回复行为

除了基础统计，本案例还特别适合进入一些简单的行为研究模型。例如，用户可以通过 **Econometrics → OLS**，把 `rating_overall` 设为因变量，把 `stay_length_nights`、`hotel_segment` 和写回后的 `sentiment_score` 设为解释变量，观察文本情感是否与结构化评分一致。也可以通过 **Econometrics → Discrete Choice → Logit**，把 `would_recommend` 或 `response_given` 设为因变量，研究哪些评论特征更容易带来推荐或更容易获得酒店回复。

特别值得一提的是 `response_given` 和 `response_delay_days`。这两个变量使得本案例不仅是评论分析案例，也是一个初步的服务补救研究案例。用户完全可以研究：负面评论是否更容易被回复，回复延迟是否与评论情感或 helpful votes 有关，不同酒店档次的回复策略是否不同。这类分析虽然在本章中不一定全部展开，但它们很好地说明了这份数据为何不仅适合文本分析，也适合评论行为研究。

6.18 本案例中的常见错误与排查

在本案例中，最常见的问题首先来自文本列选择错误。有些用户会误把 `review_id` 或 `city` 当成文本分析对象，结果当然会非常贫乏。正确做法应是优先选择 `review_comment`，必要时再扩展到 `review_title` 或 `manager_response`。第二类常见问题

是预处理过强。若文本本来不长，又同时去掉数字、标点和停用词，再设置较高的最小词长，最终可分析词项就会明显减少。

第三类问题是忽视自然缺失。当前数据中，`manager_response` 和 `response_delay_days` 的缺失值与 `response_given = 0` 是一一对应的，因此这并不表示数据质量差，而是业务逻辑使然。第四类问题是只停留在文本模块本身，而没有把文本结果写回数据表。这样虽然也能看图看表，但会失去 Traview 跨模块衔接的最大优势。最后，若运行分析后没有看到结果，应先查看 **Results Viewer**，再查看 **Syntax & Log（语法与日志窗口）**，而不是反复点击运行。

6.19 本章小结

本章围绕一份包含评论文本、评分维度、住客特征和酒店回复信息的酒店在线评论数据，展示了 Traview 中 **Text Analysis** 模块的典型工作路径。读者在本章中首先完成了数据导入和文本列检查，然后依次进行了基础文本统计、词频分析、n-gram 分析、情感分析、主题建模、关键词分析、TF-IDF 摘要和文本相似性分析，并进一步把文本结果写回数据表，衔接到统计和行为分析之中。

从全书结构来看，本章的意义在于把前两章中以结构化数值数据为主的分析逻辑，扩展到了文本与行为结合的数据环境中。通过这一章，读者应当真正意识到，Traview 的文本分析并不是孤立的“文本工具箱”，而是一个能够与评分、推荐、回复和平台行为自然结合的分析模块。只要这一点建立起来，后面进入时间序列、空间分析和高级模型时，就会更加容易理解 Traview 的整体设计思路。

第 7 章 案例四：时间序列预测数据

7.1 案例背景与预测任务

本案例使用的是一份按日期记录的餐厅销售时间序列数据。与前几章中以横截面或面板数据为主的案例不同，这份数据的核心特点在于，所有观测值都围绕时间顺序展开。也就是说，数据中的每一行并不只是一个独立样本，而是时间序列中的一个连续时点。因此，这份数据特别适合用于展示 Traview 中 **Time Series** 模块的基本工作流程，包括趋势观察、时间索引设置、平稳性检验、单变量预测以及外生变量影响的分析。

从研究问题角度看，这份数据非常适合回答几个经典问题。第一，餐厅销售收入是否存在明显趋势。第二，销售额是否会受到温度变化影响。第三，促销活动是否会对销售额产生额外冲击。第四，在历史模式的基础上，未来若干期销售额大致可能如何变化。这些问题之所以重要，是因为它们同时涵盖了时间序列分析中最常见的三类任务，也就是趋势识别、预测建模和外生冲击解释。

当前文件共有 50 条观测和 4 个变量，时间跨度按实际数据看是按周记录的序列，而不是逐日序列。虽然概念说明中使用了“日均温度”和“按日期记录”的表述，但从当前文件实际结构来看，`Date` 变量每隔七天记录一次，说明这是一份周度销售数据。对教学来说，这一点反而很有帮助，因为它提醒读者，时间序列分析的关键并不在于“是不是每天一条”，而在于数据是否按固定时间间隔排列，并且时间顺序是否清楚。

7.2 数据集结构说明与核心变量介绍

本案例使用的数据文件名为 `timeseries.csv`。数据共有 50 行和 4 列。每一行代表一个时间点上的观测。根据实际文件结构，这份数据的变量如下所示。

变量名	含义	类型或取值	可用于的分析
`Date`	日期	日期字符串，当前文件中按周排列	时间索引
`Sales`	餐厅销售收入	连续变量	时间序列因变量
`Temperature`	日均温度	连续变量	外生变量
`Promotion`	是否促销	0/1	干预变量、外生变量

从分析角度看，`Sales` 显然是本案例的核心目标变量，因为它代表餐厅销售收入。`Date` 是整个时间序列分析的索引基础，没有它，Traview 就无法知道观测的先后顺序。`Temperature` 和 `Promotion` 则是两个非常自然的外生变量。温度代表天气条件，促销代表

人为干预。也就是说，这份数据不仅适合做“只看销售额本身历史模式”的单变量预测，也适合练习“加入外部影响因素”的扩展型时间序列分析。

7.3 本案例的学习目标

完成本章之后，读者应能够独立完成以下几项操作。首先，能够识别一份时间序列数据中的时间索引变量和目标变量，并在 Traview 中正确设定 **Date column** 与 **Target (Y)**。其次，能够使用折线图和基础统计理解销售额的时间变化特征。再次，能够在 **Time Series** 模块中运行 **ADF Test**、**Exponential Smoothing**、**ARIMA** 和更进一步的带外生变量分析思路。最后，能够在 **Results Viewer** 中查看拟合图、预测图和检验结果，并对外生变量作用做基础解释。

从教学角度看，本章的核心目标不是让读者机械记住几个模型名称，而是帮助读者真正理解“时间索引”这一概念。一旦认识到同样一组数值，因为存在时间顺序而必须采用不同分析逻辑，时间序列分析的门就真正打开了。

7.4 导入数据与时间结构检查

本案例的第一步，是通过 **Data → Import CSV** 导入 `timeseries.csv`。导入成功后，用户首先应确认数据规模是否正确。当前文件应包含 50 行和 4 列。接下来，最重要的任务不是立刻进入预测模块，而是先检查时间结构是否成立。

在 **Data View** 中浏览时，用户应重点查看 `Date` 列。当前数据中，日期表现为 `2023-01-01`、`2023-01-08`、`2023-01-15` 等形式，说明观测是按周排列的，而且时间顺序整齐。这对于后续时间序列分析非常关键。若日期列格式混乱、顺序打乱或存在大量缺口，则在进入 **Time Series** 模块前应先整理。

用户还应浏览 `Sales` 列，确认它是一个连续数值变量，并且不存在明显错误编码。`Temperature` 应为连续变量，`Promotion` 应为 0/1 二元变量。从当前文件结构来看，这些字段都比较干净，因此本案例非常适合作为时间序列模块的入门练习。

图 7-1 导入 `timeseries.csv` 后的 **Data View**。

	Date	Sales	Temperature	Promotion
1	2023-01-01	1265	6.0	0
2	2023-01-08	1335	3.8	0
3	2023-01-15	1428	3.0	0
4	2023-01-22	1547	6.8	0
5	2023-01-29	1612	8.1	1
6	2023-02-05	1675	7.8	0
7	2023-02-12	1792	2.5	0
8	2023-02-19	1882	4.1	1
9	2023-02-26	1933	6.0	0
10	2023-03-05	2012	7.9	1
11	2023-03-12	2058	3.6	1
12	2023-03-19	2101	4.4	0
13	2023-03-26	2162	1.7	0
14	2023-04-02	2156	1.4	0
15	2023-04-09	2153	7.4	0
16	2023-04-16	2182	9.1	0

7.5 在 Data View 中先理解时间序列数据

很多初学者在学习时间序列时，会一进入模块就急着选模型。但对这类数据而言，更重要的往往是先理解“每一行到底代表什么”。在本案例中，每一行并不是一个不同城市、不同游客或不同评论，而是同一个餐厅在不同时间点上的连续观测。因此，这份数据的核心结构是“一个对象，多个时间点”，而不是“多个对象，一个时间点”。

这种理解方式非常重要，因为它决定了后面的模型解释逻辑。若是横截面数据，我们通常关心不同个体之间的差异；而在这里，我们主要关心的是同一个序列随时间如何变化，以及这种变化是否可以被历史值、季节模式和外生变量解释。因此，建议用户在正式进入 **Time Series** 模块之前，先在数据工作区里真正看清楚：日期是按顺序排列的，销售额是在逐期变化的，温度和促销也在随时间变动。这一眼看清楚之后，时间序列分析的逻辑才会自然很多。

7.6 使用 Visualization 绘制销售趋势图

在任何时间序列建模之前，最重要的一步通常是先把目标变量画出来。用户可以通过 **Visualization → Time Series Chart**，将 `Date` 设为横轴，将 `Sales` 设为纵轴，先观察销售额的整体趋势。

对于本案例而言，这一步至少有三个作用。第一，它帮助用户判断销售额是否存在明显趋势，例如逐步上升、逐步下降或阶段性波动。第二，它帮助用户识别是否存在异常时点，例如某几周销售突然跳高或跳低。第三，它帮助用户初步思考促销和温度是否可能与销售

波动相关。例如，若某些销售高点恰好对应促销期，那么后面加入 `Promotion` 作为外生变量就会更有直觉基础。

在教学和实操中，这张图不应被视为附属图，而应被视为时间序列分析的起点。因为任何模型结果最终都应该能回到这张图上去理解：模型是不是大体抓住了原始序列的变化节奏。

图 7-2 `Sales` 的时间趋势图示例。

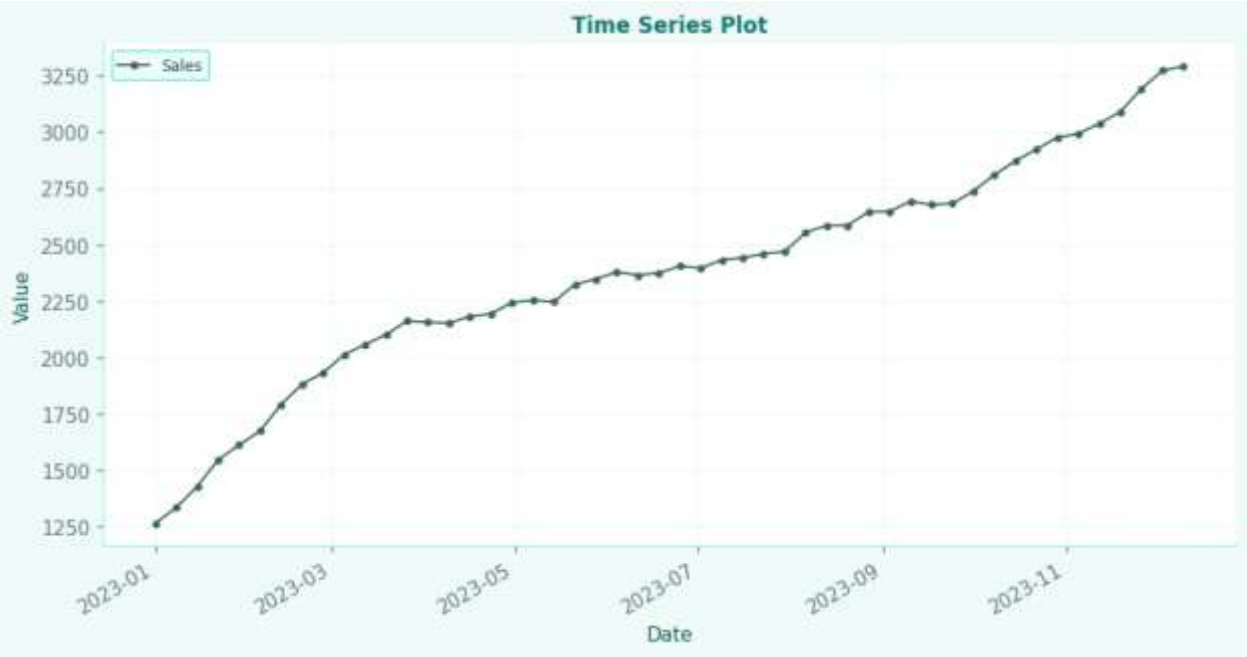

7.7 使用 Descriptive Statistics 理解销售、温度与促销分布

虽然时间序列分析强调顺序和动态结构，但这并不意味着基础描述统计就不重要。用户仍然应通过 **Statistics → Descriptive Statistics** 对 `Sales` 和 `Temperature` 做一轮基础汇总，并通过 **Statistics → Frequencies** 查看 `Promotion` 的分布情况。

这样做的意义在于，时间序列模型并不是脱离数值尺度运行的。你仍然需要知道销售额大致在什么范围内波动，温度变化是否剧烈，促销事件出现得频繁还是稀少。若促销期只占极少数观测，则后续把它作为干预变量时就应特别注意结果稳定性。若温度变化范围很窄，则其对销售的解释空间也可能有限。

因此，在时间序列案例中，基础统计虽然不像横截面案例那样占据中心地位，但它仍然是理解序列背景的重要补充。

7.8 在 Time Series 模块中设定 Date column 与 Target (Y)

完成图形观察之后，用户应通过 **Time Series** 打开时间序列分析模块。进入之后，最关键的第一步是设置 **Date column** 和 **Target (Y)**。在本案例中，`Date` 应被设为日期列，`Sales` 应被设为目标变量。当前数据是按周记录，因此在 **Resample freq** 中，若保持原始周度结构，可根据界面支持情况选择合适频率，或维持默认而不做重采样。

这里最容易出错的地方，是没有真正把时间列设为时间索引，而只是把它当作普通文本列。Traview 之所以要求单独设置 **Date column**，正是为了让软件知道“这是时间顺序的依据”。一旦这一项设定正确，后续所有模型和图表才会建立在正确的时间结构之上。

对新手来说，一个很好的判断标准是：如果你能在自己脑中清楚说出“横轴是什么时间，纵轴是什么值”，那么这个设定通常就是对的。反之，如果日期列只是“长得像字符串”，却没有被真正当作顺序变量理解，那么后面的预测结果通常也会显得混乱。

图 7-3 **Time Series** 模块中的时间列与目标变量设置。

7.9 使用 ADF Test 检查平稳性

在正式进入预测模型之前，一个非常好的习惯是先运行 **ADF Test**。ADF 检验的作用，是帮助用户判断目标序列是否接近平稳。对初学者来说，不必把单位根检验理解得过于数学化，只需要先记住一点：如果序列明显带有趋势或随机漂移，那么某些模型往往需要差分或更合适的处理方式。

在本案例中，用户可以在 **Time Series** 中选择 **ADF Test**，以 `Sales` 为目标序列运行检验。结果出来之后，重点应关注检验是否支持序列平稳。如果不能拒绝非平稳假设，那么后续在使用 **ARIMA** 时通常应考虑差分参数 `d`。如果结果更接近平稳，则模型设定可以更直接一些。

这一节的作用，并不在于把读者训练成时间序列理论专家，而是帮助他们形成一个好习惯：时间序列分析不应一上来就直接预测，而应先做最基本的序列性质检查。

图 7-4 **ADF Test** 模块结果视图。

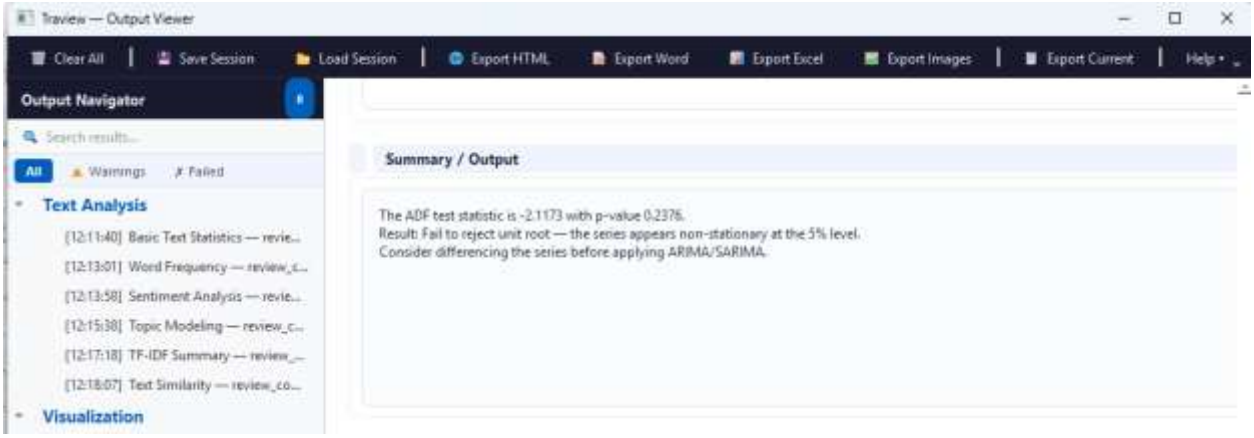

7.10 使用 Exponential Smoothing 进行基础预测

对初学者而言，最适合作为第一步预测模型的，通常是 **Exponential Smoothing**。因为它参数较少、逻辑直观，也最容易帮助用户建立“历史值如何被平滑用于预测”的理解。在本案例中，用户可以在 **Method** 中选择 **Exponential Smoothing**，保持或适度调整平滑参数，然后设置 **Forecast horizon**，例如预测未来 4 期或 8 期。

运行之后，用户应在 **Results Viewer** 中查看拟合图和预测图。第一次阅读结果时，重点不在于过度技术化解释，而在于看模型是否大体跟上了历史变化，预测路径是否平滑、方向是否合理。如果预测图与历史序列完全脱节，就应先回头检查目标变量、时间列和数据频率，而不是立刻断言模型无效。

对于教学而言，**Exponential Smoothing** 的最大价值，是它帮助读者第一次真正看到“过去的数据被延伸到未来”，而且这种延伸是连续的、有逻辑的。

图 7-5 **Exponential Smoothing** 的结果示例。

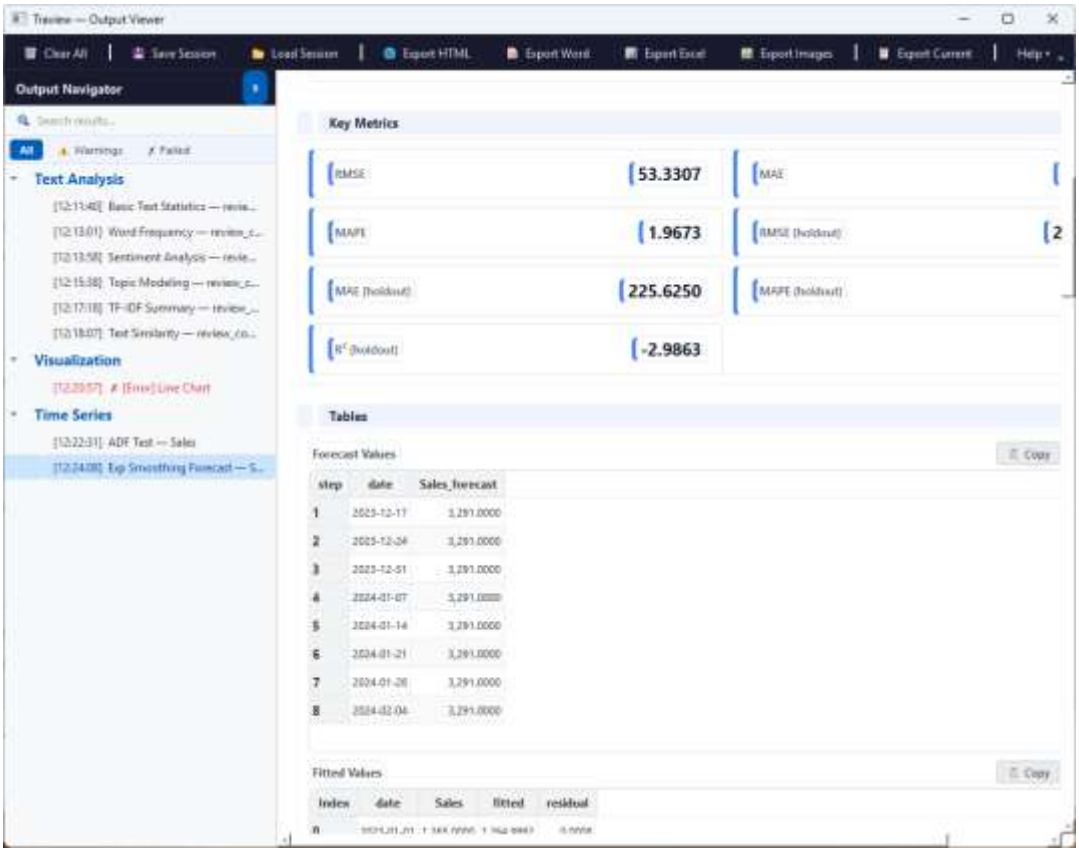

7.11 使用 ARIMA 进行单变量时间序列建模

在理解了基础平滑预测之后，下一步最自然的模型就是 **ARIMA**。与指数平滑相比，ARIMA 更强调序列自身的动态结构，包括自回归项、差分项和滑动平均项。在 Traview 中，用户可以在 **Method** 中选择 **ARIMA**，并设置 p、d 和 q 参数。

对初学者而言，这里不建议一开始就尝试太复杂的参数组合。更合理的方式，是结合前面的趋势图和 ADF 检验结果，先做一个较简单的设定。例如，如果销售序列表现出较明显趋势，则可以尝试把 d 设为 1。之后再通过拟合表现判断是否需要调整 p 或 q。

在解释 ARIMA 结果时，重点应放在拟合图、预测图和残差表现，而不是仅仅盯着参数数字本身。因为对初学者来说，最先要掌握的是“ARIMA 能否合理描述这条序列”，而不是立刻深入到所有参数的统计学细节。

图 7-6 **ARIMA** 的结果示例。

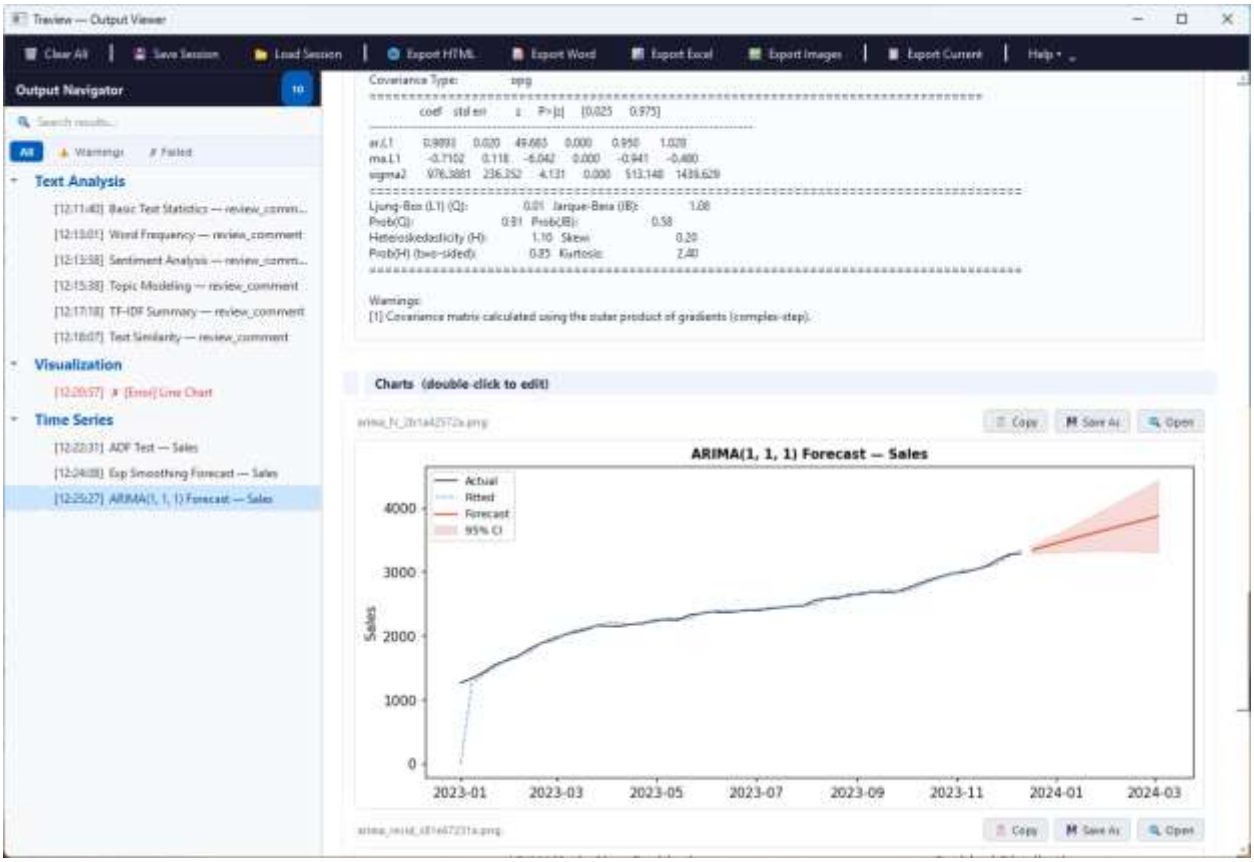

7.12 使用 Holt-Winters 或 SARIMA 处理更复杂模式

如果用户在销售折线图中观察到更复杂的趋势或近似周期性波动，则还可以继续尝试 **Holt-Winters** 或 **SARIMA**。由于当前数据只有 50 个观测点，而且是按周记录，因此这一案例更多适合作为“可以继续扩展”的演示，而不一定要求每个初学者都把季节模型跑得非常深入。

在教学中，可以借这一节强调一个很重要的原则：时间序列模型并不是越复杂越好，而是应根据数据本身的长度、波动特征和研究目标来选择。对于本案例来说，先跑通 **Exponential Smoothing** 和 **ARIMA** 已经足够构成一个很好的入门路径；**Holt-Winters** 和 **SARIMA** 更适合作为扩展训练。

7.13 把 Temperature 和 Promotion 作为外生变量来理解

本案例与纯单变量序列的一个重要不同，在于它还提供了 `Temperature` 和 `Promotion` 两个外生变量。虽然当前 Traview 时间序列模块中，不同方法对外生变量的支持方式可能不完全一致，但从案例教学角度看，读者至少应先理解这两个变量在时间序列研究中的角色。

`Temperature` 代表环境条件。它不是销售额本身的历史值，而是一个与销售同时变化、可能影响销售的外部因素。`Promotion` 则更具有干预变量特征，因为它表示某一时期是否发生了促销活动。若在销售图中发现促销期往往对应销售高点，那么后续就很自然可以思考促销是否构成外生冲击。

在更一般的时间序列建模思路中，这类变量往往可以通过带外生解释项的模型进入，例如 ARDL、回归型时间序列模型，或在某些环境中进入含 exogenous terms 的设定。对本章而言，更重要的是让读者先形成这种意识：时间序列分析不只是“看过去的销售”，还可以把天气和促销这类外部条件纳入解释框架。

7.14 使用 ARDL 或扩展模型分析外部影响

如果读者已经熟悉前面的单变量模型，并希望进一步结合外生变量分析销售变化，那么 **ARDL** 是一个非常适合的扩展入口。用户可以在 **Time Series** 中选择 **ARDL**，把 `Sales` 设为目标变量，再把 `Temperature` 和 `Promotion` 作为外生变量。然后分别设定目标变量滞后和外生变量滞后。

这一节的教学意义，在于帮助读者从“预测未来销售”过渡到“解释销售为何变化”。例如，温度变化是否在当期或滞后一期影响销售，促销是否在实施当期对销售有明显拉动，都是非常自然的问题。即便不要求新手完整掌握所有 ARDL 细节，至少应通过这一节明白：时间序列模型完全可以把外部变量纳入分析，而不是只能围绕目标变量自身做机械延伸。

图 7-7 **ARDL** 的结果示例。

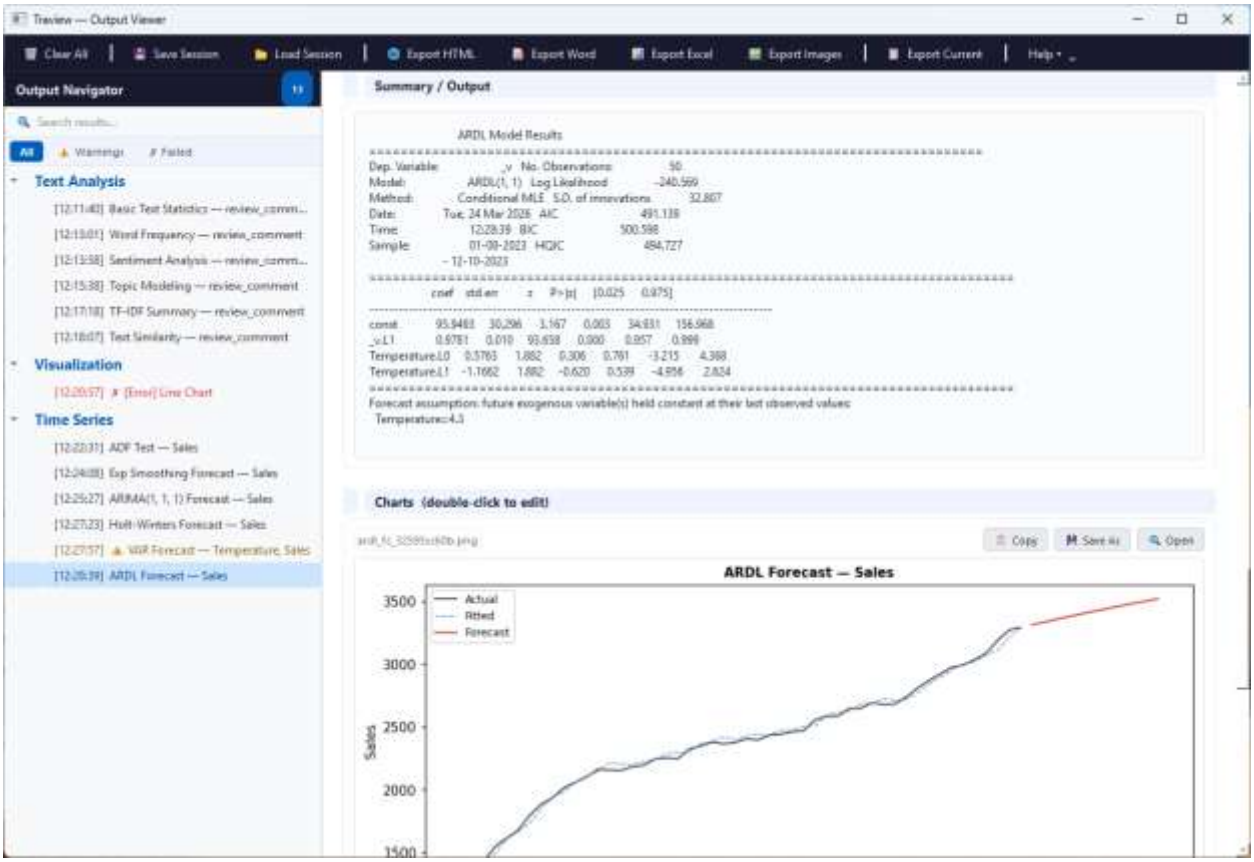

7.15 保存拟合值、残差与预测值

在 Traview 的时间序列模块中，若当前方法支持，用户可以通过 **Save to Data** 保存 **fitted values**、**residuals** 和 **forecast values**。对于本案例而言，这一功能非常值得练习。因为一旦拟合值和残差写回数据表，用户就可以进一步在 **Visualization** 中做实际值与拟合值对比图，也可以在 **Statistics** 中检查残差分布是否存在异常。

这一步还有一个更深层的好处，即它让时间序列分析不再只是一个“看预测线”的过程，而成为可以继续诊断和迭代的分析工作流。对初学者来说，只要能够完成一次结果写回，就会更容易理解 Traview 各模块之间的联动机制。

图 7-8 **Save to Data** 的结果示例。

7.16 如何解释趋势、预测与外生冲击结果

在本案例中，结果解释通常应分成三个层面。第一个层面是趋势解释，也就是销售额总体是在上升、下降还是波动中变化。第二个层面是预测解释，也就是模型根据历史数据对未来几期给出了怎样的延伸路径。第三个层面是外生冲击解释，也就是温度和促销这类变量是否与销售波动存在明显同步或滞后关系。

对初学者而言，最重要的是不要把“预测图”误解为对未来的确定预言。更合理的理解是：在当前模型设定和历史模式基础上，未来若干期最可能沿着某种路径演化。同时，若促销或温度变量在模型中表现出明显关系，也不应立即把它们说成绝对因果，而应结合研究背景说成“与销售变化显著相关”或“在模型中表现出明显影响”。

7.17 本案例中的常见错误与排查

本案例中最常见的问题，首先来自时间列没有被正确理解。若用户没有把 `Date` 真正当作时间索引，而只是把它当成普通文本列，那么后面的分析就会明显失去时间逻辑。第二类问题是把周度数据误当成日度数据，从而在解释预测步数和频率时产生混淆。当前文件虽然按日期记录，但本质上是一份周度序列，因此在写作和解释时应使用“期”或“周”作为更稳妥的表述。

第三类问题是过早进入复杂模型，而没有先画趋势图、做基础统计和运行 ADF 检验。对时间序列来说，这个顺序非常重要。第四类问题是外生变量理解不清。`Temperature` 和 `Promotion` 并不是目标变量，它们更适合被视为外部解释条件。最后，如果运行后没有看到结果，应先查看 **Results Viewer**，若仍有疑问，再打开 **Syntax & Log（语法与日志窗口）** 查看具体报错。

7.18 本章小结

本章围绕一份按周记录的餐厅销售时间序列数据，展示了 Traview 中 **Time Series** 模块的基本使用路径。读者在本章中首先完成了时间结构检查和趋势图绘制，然后设置了 **Date column** 与 **Target (Y)**，接着依次进行了基础描述统计、ADF 平稳性检验、指数平滑预测、ARIMA 建模，并进一步理解了温度和促销作为外生变量的作用。通过这一过程，读者不仅学会了如何在软件中跑通时间序列分析，也初步建立了“时间顺序改变分析逻辑”的认识。

从全书结构来看，本章的意义在于把 Traview 的工作流进一步扩展到动态数据环境中。前几章强调的是结构化横截面、面板和文本数据，而本章强调的是时间维度。一旦这一章真正走通，读者后续进入空间分析和高级模型时，就会更容易理解 Traview 作为一个综合数据分析平台的完整能力。

第 8 章 案例五：空间点位与空间属性数据

8.1 案例背景与空间分析任务

本案例使用的是一份酒店空间点位数据。与前几章中以游客、评论或时间序列为核心的数据不同，这份数据的关键特征在于每一条观测都带有明确的地理坐标，也就是 `latitude` 和 `longitude`。这意味着，用户不仅可以分析“某家酒店的评分或访客数是多少”，还可以进一步分析“这些酒店在空间上如何分布”“高评分酒店是否彼此相邻”“高访客酒店是否形成热点区域”等空间结构问题。

从研究任务上看，这份数据非常适合用来展示 Traview 中 **Spatial Analysis** 模块的基本工作流，包括点位地图绘制、热力图展示、整体空间自相关检验、局部空间聚类识别、热点分析、缓冲区统计和插值表面分析。从研究设计角度看，这份数据确实非常适合扩展到 GWR 一类的空间回归分析，因为它同时包含坐标、结果变量和潜在解释变量。

当前文件共有 100 条酒店观测和 7 个变量。样本覆盖多个城市区域，当前实际的 `region` 字段中主要包括 Beijing、Shanghai、Guangzhou、Chengdu 和 Shenzhen 五类区域标签。这使得本案例不仅可以做空间统计，也可以做区域间的初步比较。对教学来说，这是一份非常理想的入门空间数据，因为其字段少而清晰，坐标完整，空间值变量也具有明确含义。

8.2 数据集结构说明与核心变量介绍

本案例使用的数据文件名为 `spatial.csv`。数据共有 100 行和 7 列。每一行代表一家酒店的空间点位观测。根据实际文件结构，这份数据的变量如下所示。

变量名	含义	类型或取值	可用于的分析
`hotel_id`	酒店唯一编号	当前文件中为字符型代码，如 `H001`	数据识别、合并、索引
`latitude`	纬度	连续变量	地图绘制、空间权重构建
`longitude`	经度	连续变量	地图绘制、空间权重构建
`rating`	酒店评分	约 1–5 区间的连续评分	空间自相关、热点分析
`visitor_count`	月访客数	连续变量	热点分析、空间回归思路、缓冲区比较
`price`	平均房价	连续变量	可作为控制变量，也可用于更高阶空间回归思路
`region`	区域分组	当前文件中为城市标签，如 Beijing、Shanghai 等	分组分析、区域对比

从空间分析角度看，`rating` 和 `visitor_count` 是本案例最值得优先分析的两个变量。前者适合做整体空间自相关和局部聚类分析，后者适合做热点和密度分析。`price` 则可以作为后续解释变量或扩展控制变量。也就是说，这份数据既可以做“酒店评分在空间上是否聚集”的分析，也可以做“高访客酒店是否集中于某些地理区域”的分析。

8.3 本案例的学习目标

完成本章之后，读者应能够独立完成以下几项操作。首先，能够识别空间数据中的坐标字段，并在 Traview 中正确设置 **Latitude**、**Longitude** 和 **Value column**。其次，能够使用 **Point Map** 和 **Heatmap** 完成最基础的空间可视化。再次，能够使用 **Global Moran's I** 检查整体空间自相关，使用 **Local Moran's I** 和 **Hotspot Analysis** 识别局部聚类与热点区域。最后，能够把局部空间类别或缓冲区结果写回数据表，并对空间结果做基本解释。

从教学角度看，本章最重要的并不是把每一种空间统计量都背下来，而是帮助读者建立一种新的分析视角，也就是“同样的数值，如果放到地图上，就不再只是表格问题，而是位置关系问题”。一旦这一点建立起来，后面的空间结果阅读就会顺畅很多。

8.4 导入数据与坐标字段检查

本案例的第一步，是通过 **Data → Import CSV** 导入 `spatial.csv`。导入成功后，用户首先应确认数据规模是否正确。当前文件应包含 100 行和 7 列。随后，最关键的检查任务是坐标字段检查，也就是确认 `latitude` 和 `longitude` 确实是正确的地理坐标列。

在 **Data View** 中浏览时，用户应至少检查三个方面。第一，`latitude` 的取值是否处于合理范围。当前文件中的纬度值大多在中国主要城市的合理范围内，例如北京约 39 度，上海约 31 度。第二，`longitude` 是否同样合理，例如北京经度约 116，上海约 121。第三，这两个字段是否可能被填反。若经纬度位置明显不对，后面点位图往往会全部跑偏。

用户还应简单浏览 `rating`、`visitor_count` 和 `price` 三列。当前文件中，`rating` 表现为浮点型评分，`visitor_count` 和 `price` 则分别是访客规模和价格水平的数值变量。从当前文件结构来看，这几列都比较干净，因此很适合直接进入空间分析。

图 8-1 导入 `spatial.csv` 后的 **Data View**。

	hotel_id	latitude	longitude	rating	visitor_count	price	region
1	H001	39.9042	116.4074	4.5	12500	680	Beijing
2	H002	39.91	116.42	4.2	9800	620	Beijing
3	H003	39.89	116.39	3.8	7600	550	Beijing
4	H004	31.2304	121.4737	4.7	15800	850	Shanghai
5	H005	31.24	121.48	4.1	11200	720	Shanghai
6	H006	31.21	121.45	3.9	8900	590	Shanghai
7	H007	23.1291	113.2644	4.6	9800	620	Guangzhou
8	H008	23.14	113.27	4.3	8400	580	Guangzhou

8.5 在 Variable View 中理解空间变量含义

完成原始数据浏览之后，建议进入 **Variable View** 再看一眼变量结构。对于空间案例来说，这一步尤其重要，因为并不是所有数值列都应该被拿去做空间统计。`latitude` 和 `longitude` 虽然是数值型，但它们的作用是位置索引，而不是被解释变量。`rating`、`visitor_count` 和 `price` 虽然也是数值型，但它们才是真正附着在空间位置上的属性变量。`region` 则是区域标签，用于分组和对比，而不是空间权重构建本身的基础。

这种区分非常关键，因为很多初学者第一次接触空间分析时，容易把“只要是数字列都能丢进空间模型”当成理所当然。事实上，空间分析比普通统计更依赖变量角色清楚。只要把坐标列、属性列和分组列分清楚，后面的操作就会容易很多。

8.6 使用 Point Map 绘制基础点位图

在进入任何空间统计量之前，最重要的一步几乎总是先画点位图。用户可以通过 **Spatial Analysis** 打开空间模块，在 **Latitude (numeric)** 中选择 `latitude`，在 **Longitude (numeric)** 中选择 `longitude`，然后先将 **Analysis Type** 设为 **Point Map**。此时，`Value column` 可以先留空，也可以指定 `rating` 或 `visitor_count`，用于给点位附加颜色表达。

点位图的作用不仅是“看图好看”，而是帮助用户确认三件非常基础的事情。第一，所有酒店是否真的落在预期地理区域内。第二，点位是否大致围绕几个主要城市群聚集。第三，是否存在明显孤立点或错误点。若这一张图看起来完全不合理，例如所有点挤在地图角落或落在海上，那么后面的 Moran’s I、热点分析和缓冲区分析都不应继续解释。

当前文件中的酒店点位覆盖北京、上海、广州、深圳和成都等城市，因此在点位图上，用户应能看到几个相对清楚的城市群。正因为这种空间结构较直观，这份数据才非常适合作为空间分析的教学案例。

图 8-2 本案例的 **Point Map** 结果示例。

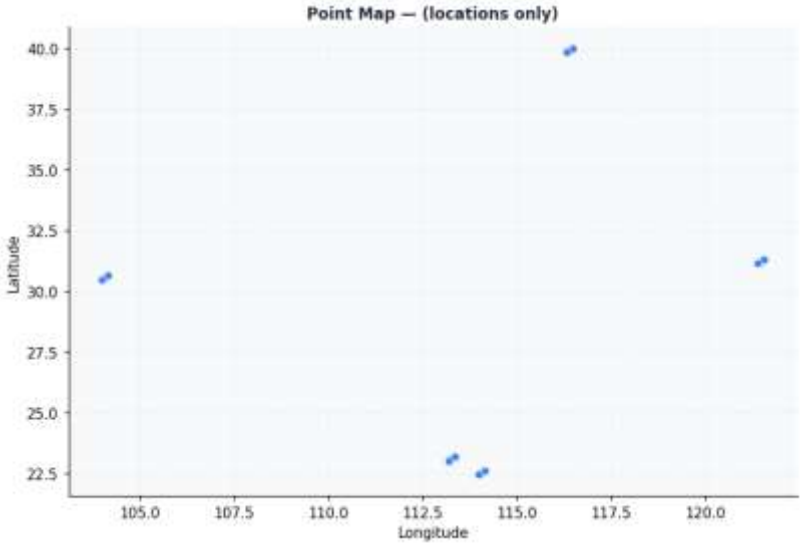

8.7 使用 Heatmap 观察访客集中区域

在确认坐标无误之后，下一步非常适合使用 **Heatmap**。在 **Analysis Type** 中选择 **Heatmap**，并在 **Value column (numeric)** 中选择 `visitor_count`。这样生成的图形就不再只是展示点的位置，而会进一步突出哪些区域的访客强度更高。

这一步对于理解空间分布非常有帮助。与 **Point Map** 相比，热力图更强调“哪里更热”，也就是高访客酒店是否在某些区域形成明显集中。若用户只看表格中的 `visitor_count`，通常很难直观感受到空间上的聚集效应；而热力图恰恰能把这种空间集中趋势快速呈现出来。

在解释热力图时，应注意它反映的是强度分布，而不是正式显著性判断。换言之，某一区域看起来更“热”，并不等于它已经在统计上被证明为显著热点。若用户希望进一步做正式判断，则应继续进入 **Hotspot Analysis** 或 **Local Moran's I**。

8.8 空间权重与邻接关系的基本理解

在进行 **Global Moran's I**、**Local Moran's I** 和 **Hotspot Analysis** 之前，用户需要理解一个非常重要的概念，即空间权重。所谓空间权重，本质上是在告诉软件：哪些酒店应当被视为彼此的邻居，邻近关系是按照最近的若干点来定义，还是按照一定距离范围来定义。

当前 Traview 版本支持两类常见设置方式。第一类是 **Use k-nearest neighbors**，也就是按最近的若干邻居构建空间关系。第二类是 **Distance threshold (km)**，也就是只有在一定距离范围内的点才被视为相互邻近。对于教学入门来说，`k = 5` 往往是一个比较自然的起

点，因为它能保证每个点至少有一组固定数量的邻居。若使用距离阈值，则需要更谨慎，因为阈值过小会导致有些点没有邻居，阈值过大则会让空间关系过于泛化。

在本案例中，由于酒店分布跨越多个城市，若直接使用非常小的距离阈值，有可能出现跨城市几乎没有邻接关系的情况。因此，对初学者而言，先使用 `k-nearest neighbors` 往往更稳妥。

8.9 使用 Global Moran's I 检查评分的整体空间自相关

在完成地图展示之后，下一步最适合作为正式空间统计起点的，就是 **Global Moran's I**。用户可以在 **Analysis Type** 中选择该方法，并将 `rating` 设置为 **Value column**。权重设置建议先采用 **Use k-nearest neighbors**，并把 `k` 设为一个适中的值，例如 5。若界面中提供 **Permutations**，则可保持默认值。

Global Moran's I 的作用，是判断酒店评分在整体空间上是否表现出正向聚集、负向分散或接近随机分布。对本案例而言，核心问题可以表述为：高评分酒店是否更倾向于与高评分酒店相邻，低评分酒店是否也更倾向于彼此接近。若结果为正且显著，则通常说明评分具有空间聚集特征；若结果接近零且不显著，则更说明整体上接近随机分布。

在解释这一结果时，用户应特别注意，全局 Moran’s I 只能告诉你“整体上是否存在空间结构”，却不能直接告诉你热点具体在哪里。因此，若结果显著，下一步就应当进入局部分析，而不是停留在整体统计量层面。

图 8-3 本案例的 **Global Moran's I** 结果示例。

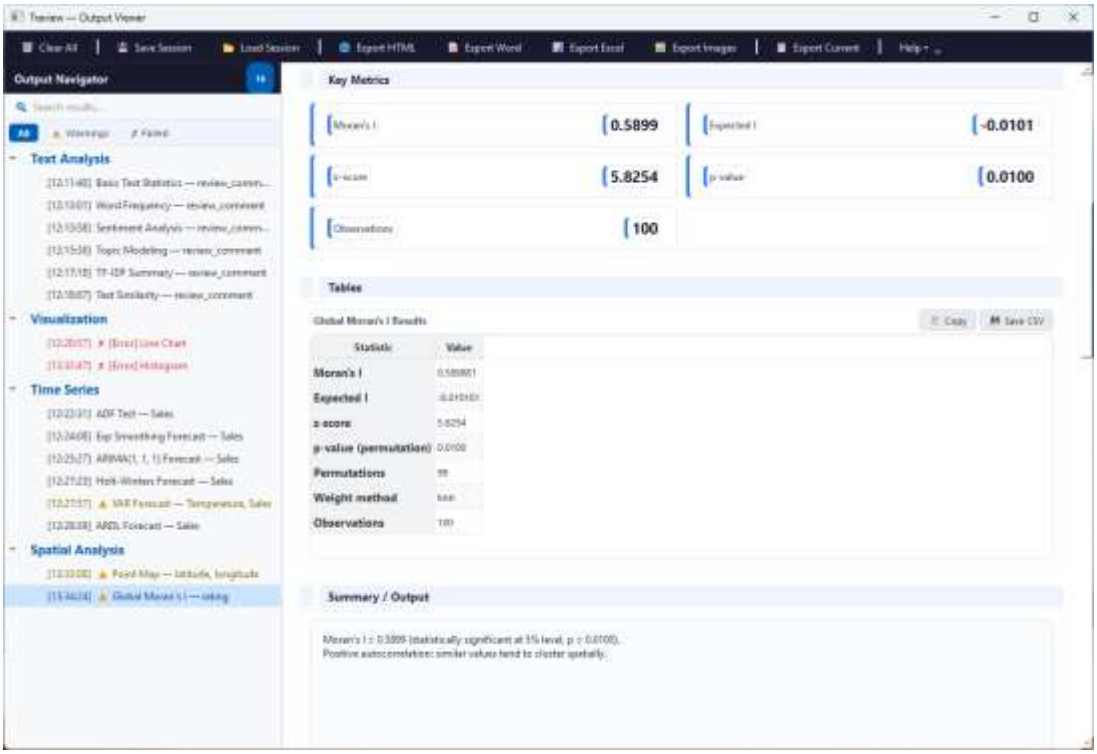

8.10 使用 Local Moran's I 识别局部聚类与异常点

当整体空间自相关存在之后，更有解释力的通常是局部分析。用户可以在 **Analysis Type** 中选择 **Local Moran's I**，仍以 `rating` 作为 **Value column**，并沿用前面的邻接权重设定。运行之后，软件通常会为每一家酒店生成局部聚类类别。

在当前 Traview 版本中，局部结果通常包括 **High-High**、**Low-Low**、**High-Low**、**Low-High** 和 **Not significant** 等类别。对初学者而言，可以把它们理解成四种典型空间位置。**High-High** 表示高评分酒店位于高评分邻域中，属于高值聚类。**Low-Low** 表示低评分酒店位于低评分邻域中，属于低值聚类。**High-Low** 和 **Low-High** 则更接近局部异常点，也就是某家酒店的评分与周边邻居明显不一致。

这一分析的教学价值非常高，因为它帮助读者第一次看到“空间统计不仅可以给出一个总数，还可以回到每一个点”。如果在 **Save to Data** 中勾选保存分类标签和统计值，局部结果还可以写回数据表，后续用于区域比较和进一步分析。

图 8-4 本案例的 **Local Moran's I** 结果示例。

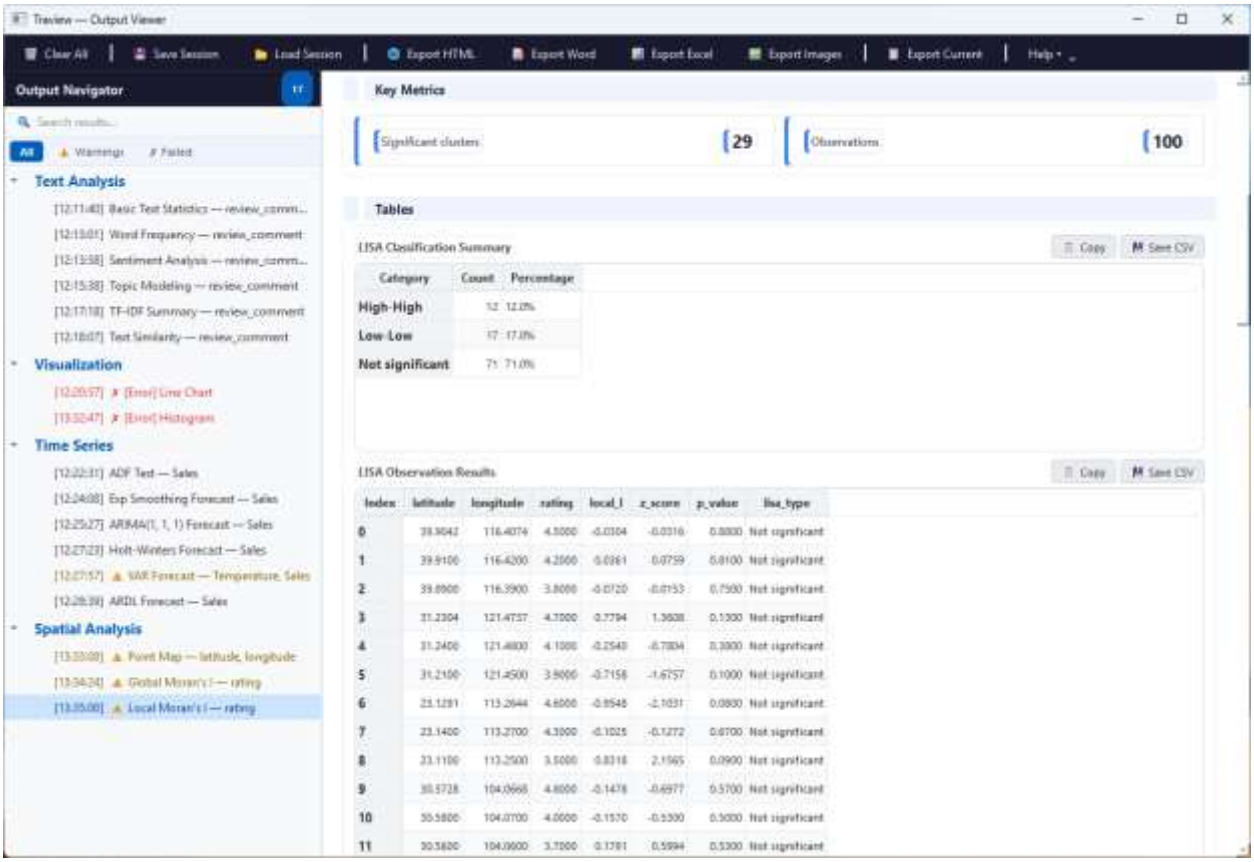

8.11 使用 Hotspot Analysis 识别高访客热点与低访客冷点

除了对评分做空间聚类分析之外，本案例还非常适合对 `visitor_count` 进行热点分析。用户可以在 **Analysis Type** 中选择 **Hotspot Analysis**，把 `visitor_count` 设为 **Value column**，并采用与前面相同的邻接权重设置。

与 **Local Moran's I** 相比，热点分析更容易被初学者直观理解。因为结果通常直接分类为 **Hotspot**、**Coldspot** 和 **Not significant**。对于本案例而言，这个分析对应的问题就是：高访客酒店是否在某些区域形成显著热点，低访客酒店是否在某些区域形成显著冷点。由于访客数本身具有明显经营意义，因此这一结果在应用研究和报告中通常也更容易解释。

若热点结果写回数据表，用户还可以进一步比较热点酒店与非热点酒店在 `price` 或 `rating` 上的差异。这种从空间分类回到统计比较的路径，正是 Traview 跨模块使用的一个典型例子。

图 8-5 本案例的 **Hotspot Analysis** 结果示例。

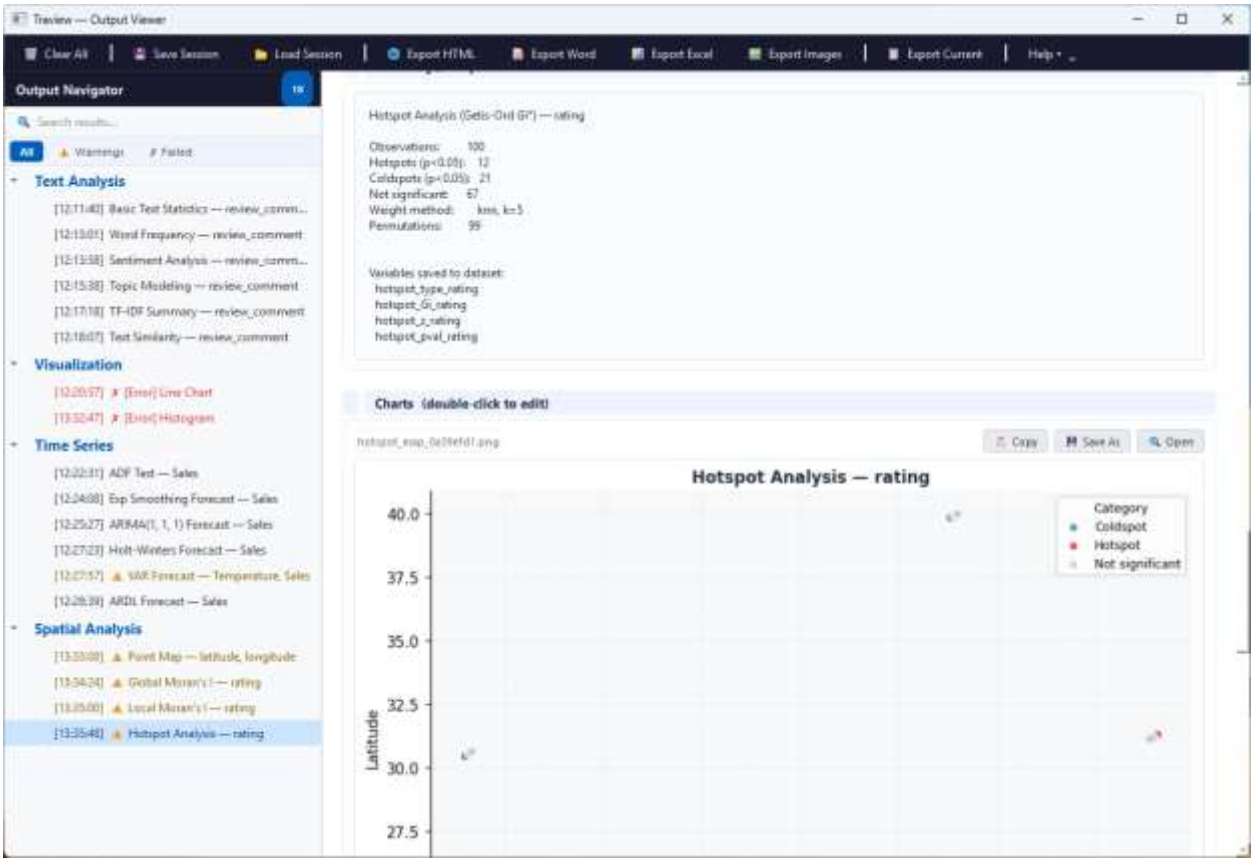

8.12 使用 Buffer Counts 衡量周边酒店密度

空间分析并不总是只围绕 Moran's I 和热点。有些研究问题更关心的是某一点周边到底有多少对象。在本案例中，这种问题也非常自然。例如，我们可以问：某家酒店周边一定距离内还有多少其他酒店？高评分酒店是否位于更密集的竞争环境中？

用户可以在 **Analysis Type** 中选择 **Buffer Counts**，然后设定 **Buffer radius (km)**。对于酒店点位数据来说，1 公里、2 公里或 5 公里都可以作为教学演示的起点。运行之后，软件会为每个点生成缓冲区内对象数量。若勾选 **Save buffer counts**，这个结果还会写回数据表。

这一分析特别适合和价格或访客数结合起来思考。例如，酒店是否在更高密度区域中拥有更高访客数？高价格酒店是否更集中于高密度商业区？虽然这些问题在本章不一定全部展开，但 **Buffer Counts** 已经为这类更深入分析提供了非常自然的结构化变量。

图 8-6 本案例的 **Buffer Counts** 结果示例。

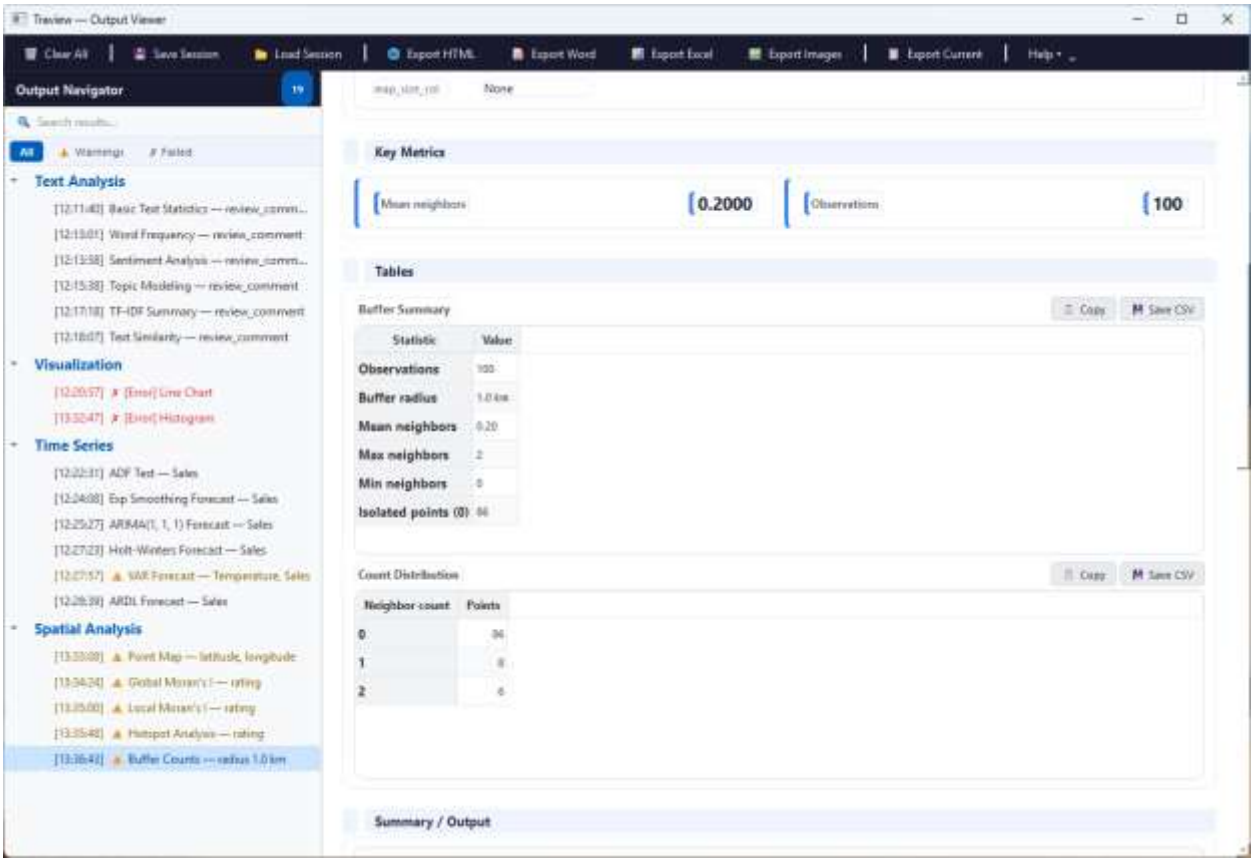

8.13 使用 Nearest Neighbor 判断点位整体分布模式

除了附着在点上的属性变量，空间分析还可以直接研究点本身的分布模式。**Nearest Neighbor** 正是为此服务的方法。它不依赖 `rating` 或 `visitor_count`，而只关心酒店点位本身是更接近聚集、随机还是分散。

用户在 **Analysis Type** 中选择 **Nearest Neighbor** 后，通常不需要额外指定值列。运行后，结果会给出最近邻指数，也就是 NNI。对初学者来说，只需记住一个简单规则：若 NNI 小于 1，通常意味着点位更聚集；若接近 1，则更接近随机；若大于 1，则更接近分散。

在本案例中，由于酒店明显分布在几个主要城市，因此整体上出现聚集倾向是完全可能的。这个分析的意义在于，它把“地图上看起来像聚在一起”转化成了一个正式的统计判断。

图 8-7 本案例的 **Nearest Neighbor** 生成的新的变量示例。

8.14 使用 IDW Interpolation 生成评分表面

如果用户希望进一步把离散点位上的评分值转化为连续空间表面，则可以使用 **IDW Interpolation**。在 **Analysis Type** 中选择该方法后，把 `rating` 设为 **Value column**，再根据需要设定 **Grid size** 和 **IDW power**。

这一分析特别适合教学展示，因为它能把“酒店评分”从一个个离散点，转化为在地图上连续过渡的高低表面。直观上，用户可以看到哪些区域更接近高评分带，哪些区域更接近低评分带。不过，在解释时必须非常谨慎。插值表面是一种基于距离加权的估计，而不是实际完整观测值地图。因此，它适合用来帮助理解空间趋势，但不应被解释得过度精确。

对于本案例而言，IDW 插值最适合作为“空间可视化的延伸”，而不是作为正式推断的唯一依据。

8.15 把空间结果写回数据表

本案例中一个非常重要的操作，是把空间分析结果写回数据表。对当前 Traview 版本而言，最值得写回的通常包括 **Local Moran's I** 的局部分类标签、局部统计量，**Hotspot Analysis** 的热点标签，以及 **Buffer Counts** 的邻域计数结果。

一旦这些结果回到数据表，用户就可以立刻在 **Statistics** 中比较不同空间类别的均值差异。例如，可以比较热点酒店与非热点酒店的平均房价，也可以比较 **High-High** 评分聚类区与其他区域的访客规模。换句话说，空间分析不再只是生成一张地图，而是开始产出可以进一步进入统计和回归的结构化变量。这正是 Traview 作为综合分析平台的重要优势之一。

8.16 结果解释：从地图到空间结构

在本案例中，结果解释通常应分成三个层次。第一个层次是空间展示层，也就是通过 **Point Map** 和 **Heatmap** 说明酒店在地理上如何分布，以及高访客区域大致位于哪里。第二个层次是整体结构层，也就是通过 **Global Moran's I** 和 **Nearest Neighbor** 判断酒店评分或酒店位置整体上是否具有空间聚集特征。第三个层次是局部结构层，也就是通过 **Local Moran's I** 和 **Hotspot Analysis** 识别具体的热点、冷点和异常点。

这种分层解释方式非常重要，因为很多初学者容易把所有空间结果混在一起看。实际上，一张热图回答的是“哪里看起来更热”，而 Moran’s I 回答的是“整体上是否存在空间相

关”，热点分析回答的是“哪里构成显著热点”，而缓冲区计数回答的则是“周边有多少对象”。只要把这些问题清楚地区分开，空间分析就会变得有条理得多。

8.17 本案例中的常见错误与排查

本案例中最常见的问题首先来自坐标列设定错误。若 `latitude` 和 `longitude` 被选反，或误把 `price` 之类数值列当成坐标列，地图结果通常会立即异常。第二类问题是直接跳过点位图检查，急于进入 Moran’s I 或热点分析。对空间数据来说，这个顺序非常危险，因为只要点位图不对，后面所有空间统计都失去基础。

第三类问题是误把 `region` 当作构建空间邻接关系的依据。实际上，邻接关系在本章中主要由坐标和距离定义，而不是由区域标签直接定义。第四类问题则是把热点图当作显著性证明，把热力图当作正式统计结论。用户应始终记住，热力图和点位图是展示工具，而显著性判断应依赖正式空间统计量。最后，若分析后没有看到结果，应先查看 **Results Viewer**，必要时再进入 **Syntax & Log**（语法与日志窗口） 查看过程提示。

8.18 本章小结

本章围绕一份酒店空间点位数据，展示了 Traview 中 **Spatial Analysis** 模块的基本使用路径。读者在本章中首先完成了坐标检查和点位图绘制，然后依次进行了热力图展示、整体空间自相关检验、局部空间聚类识别、热点分析、缓冲区计数、最近邻分析和插值表面生成，并进一步理解了如何把空间结果写回数据表，用于后续统计分析。

从全书结构来看，本章的意义在于把 Traview 的工作流进一步扩展到“位置”这一维度。前面的案例已经展示了结构化数据、文本数据和时间序列数据，本章则强调地理坐标与空间邻近关系的重要性。一旦这一章真正走通，读者就会更容易理解：Traview 不只是能在表格中分析数据，还能把数据放回地图与空间结构之中去解释。

第 9 章 案例六：量表题项与潜变量建模数据

9.1 案例背景与潜变量研究问题

本案例使用的是一份游客问卷调查数据。与前几章中的经营数据、评论数据和空间点位数据相比，这份数据最重要的特点在于它同时包含人口统计特征、旅行特征、服务质量相关题项、满意度、推荐意愿、重游意愿、忠诚度和消费变量。因此，它不仅适合做一般统计分析和回归分析，更适合进入信度分析、因子分析、结构方程模型以及中介和调节分析。

当前文件共有 300 条问卷记录和 21 个变量。每一行代表一名游客的一份完整问卷。数据中既有单个观测变量，例如年龄、收入水平、旅行天数和消费金额，也有可以被视为潜在构念测量题项的 Likert 量表变量，例如 `Service_Quality_Item1`、`Service_Quality_Item2`、`Service_Quality_Item3`、`Cleanliness`、`Location` 和 `Value_For_Money`。这种数据结构非常适合用来讲解“为什么有些变量不是单独解释，而是共同测量一个潜变量”。

从研究问题角度看，这份数据至少支持三类非常自然的路径。第一类是测量模型路径，也就是检验服务质量相关题项是否能够构成一个稳定的一致性量表。第二类是结构路径，也就是考察服务质量、满意度、忠诚和行为结果之间的关系。第三类是扩展路径，也就是进一步研究满意度是否在服务质量与忠诚之间起中介作用，不同地区或不同性别群体的路径是否存在差异，以及能否利用这些变量预测预订成功或推荐意愿。对 Traview 的教学而言，这一案例的价值非常高，因为它把量表分析、SEM 和行为变量联系到了同一套数据之中。

9.2 数据集结构说明与核心变量介绍

本案例使用的数据文件名为 `survey.csv`。数据共有 300 行和 21 列。每一行代表一名游客的独立问卷记录。根据实际文件结构，这份数据的变量如下所示。

9.2.1 基础特征变量

变量名	含义	类型或取值	可用于的分析
ID	游客编号	当前文件中为字符型唯一代码，如 `TOUR001`	唯一识别
Age	年龄	连续变量	分组分析、控制变量
Female	女性	0/1	多组分析、控制变量
Income_Level	收入水平	有序分类	分组、控制变量
Education	教育水平	有序分类	分组、控制变量

Region	地区	分类变量	多组比较、多组SEM
Trip_Purpose	出行目的	1=家庭，2=休闲，3=商务，4=探险	分组分析
Duration_Days	旅行天数	连续变量	控制变量

9.2.2 潜变量测量项

变量名	含义	类型或取值	可用于的分析
Service_Quality_Item1	服务质量题项 1	1–5 Likert	信度、CFA、SEM
Service_Quality_Item2	服务质量题项 2	1–5 Likert	信度、CFA、SEM
Service_Quality_Item3	服务质量题项 3	1–5 Likert	信度、CFA、SEM
Cleanliness	清洁感知	1–5 Likert	CFA、回归、SEM
Location	位置感知	1–5 Likert	CFA、回归、SEM
Value_For_Money	性价比感知	1–5 Likert	CFA、回归、SEM

9.2.3 满意度、忠诚与行为变量

变量名	含义	类型或取值	可用于的分析
Overall_Satisfaction	总体满意度	1–5 Likert	中介、结果变量
Recommend	推荐意愿	当前文件中为 1–5 Likert	忠诚结果变量、回归
Return_Intention	重游意愿	当前文件中为 1–5 Likert	忠诚结果变量、回归
Visit_Frequency	到访频率	连续/计数	行为变量
Loyalty_Score	忠诚得分	连续变量	SEM、回归
Spending_Yuan	消费金额	连续变量	回归
Booking_Success	预订成功	0/1	分类模型、Logit、ML

从方法路径上看，这份数据最自然的起点是围绕 Service_Quality_Item1 到 Service_Quality_Item3 先做信度分析，再把 Cleanliness、Location 和 Value_For_Money 一起纳入更广义的服务体验结构，随后进一步研究这些感知如何通过 Overall_Satisfaction 影响 Loyalty_Score、Recommend 和 Return_Intention。这恰恰构成了一个非常标准的潜变量与行为结果相连接的研究场景。

9.3 本案例的学习目标

完成本章之后，读者应能够独立完成以下几项操作。首先，能够识别问卷数据中的人口统计变量、分组变量、量表题项和行为结果变量。其次，能够使用 **Statistics** 模块完成量表题项的描述统计和信度分析。再次，能够使用因子分析初步探索量表结构，并在 **Advanced Models → SEM Workspace** 中建立一个最基础的测量模型与结构模型。最后，能够理解满意度在服务质量与忠诚之间可能扮演的中介角色，并知道如何进一步进入 **Process Model** 或分类模型扩展分析。

从教学角度看，本章的核心目标不是让读者一开始就掌握所有 SEM 细节，而是帮助他们真正理解“量表题项”与“潜变量”之间的关系。只要这一点建立起来，后面的 SEM、CFA 和中介分析才会显得有逻辑，而不是单纯的按钮堆叠。

9.4 导入数据与问卷结构检查

本案例的第一步，是通过 **Data → Import CSV** 导入 survey.csv。导入成功后，用户首先应确认数据规模是否正确。当前文件应包含 300 行和 21 列。随后，最重要的任务是区分这 21 列中哪些是背景变量，哪些是量表题项，哪些是行为和结果变量。

在 **Data View** 中浏览时，用户应先看基础特征列，例如 Age、Female、Income_Level、Education、Region、Trip_Purpose 和 Duration_Days。这些变量将主要用于控制、分组或多组比较。接着，用户应重点观察 Service_Quality_Item1 到 Service_Quality_Item3、Cleanliness、Location、Value_For_Money、Overall_Satisfaction、Recommend 和 Return_Intention。这些变量大多取值在 1 到 5 之间，说明它们是标准 Likert 量表项。最后，再看 Visit_Frequency、Loyalty_Score、Spending_Yuan 和 Booking_Success，它们对应行为和结果变量。

在 **Variable View** 中，用户应确保量表题项都被识别为可参与统计分析的数值列。虽然它们是 Likert 量表，但在 Traview 的多数模块中通常仍可以作为数值变量参与描述统计、信度分析和 SEM。与此同时，Region 和 Trip_Purpose 虽然也是数字或类别编码形式，却更适合作为分组变量，而不应与量表题项混为一谈。

图 9-1 导入 `survey.csv` 后的 **Data View**。

	Name	Type	Format	Width	Decimals	Label	Values	Missing	Columns	Align	Measure	Role
1	ID	String		8	0	Id			8	Left	Nominal	Input
2	Age	Numeric		8	2	Age			8	Right	Scale	Input
3	Female	Numeric		8	2	Female			8	Right	Scale	Input
4	Income_Level	String		8	0	Income Level			8	Left	Nominal	Input
5	Education	String		8	0	Education			8	Left	Nominal	Input
6	Region	String		8	0	Region			8	Left	Nominal	Input
7	Trip_Purpose	Numeric		8	2	Trip Purpose			8	Right	Scale	Input
8	Duration_Days	Numeric		8	2	Duration Days			8	Right	Scale	Input
9	Service_Quality_Ite...	Numeric		8	2	Service Quality Item1			8	Right	Scale	Input
10	Service_Quality_Ite...	Numeric		8	2	Service Quality Item2			8	Right	Scale	Input
11	Service_Quality_Ite...	Numeric		8	2	Service Quality Item3			8	Right	Scale	Input
12	Cleanliness	Numeric		8	2	Cleanliness			8	Right	Scale	Input
13	Location	Numeric		8	2	Location			8	Right	Scale	Input
14	Value_For_Money	Numeric		8	2	Value For Money			8	Right	Scale	Input
15	Overall_Satisfaction	Numeric		8	2	Overall Satisfaction			8	Right	Scale	Input
16	Recommend	Numeric		8	2	Recommend			8	Right	Scale	Input
17	Return_Intention	Numeric		8	2	Return Intention			8	Right	Scale	Input
18	Visit_Frequency	Numeric		8	2	Visit Frequency			8	Right	Scale	Input
19	Loyalty_Score	Numeric		8	2	Loyalty Score			8	Right	Scale	Input
20	Spending_Yuan	Numeric		8	2	Spending Yuan			8	Right	Scale	Input
21	Booking_Success	Numeric		8	2	Booking Success			8	Right	Scale	Input

21 variables — 21 labeled • Double-click a cell to edit

9.5 使用 Descriptive Statistics 查看量表题项与行为变量

在进入信度和因子分析之前，用户应先通过 **Statistics → Descriptive Statistics** 对核心量表题项和结果变量做一轮基础描述统计。建议优先选择 `Service_Quality_Item1`、`Service_Quality_Item2`、`Service_Quality_Item3`、`Cleanliness`、`Location`、`Value_For_Money`、`Overall_Satisfaction`、`Recommend`、`Return_Intention` 和 `Loyalty_Score`。

这样做的作用有三个。第一，可以帮助确认题项分布是否合理，例如是否有严重偏态、天花板效应或地板效应。第二，可以帮助判断不同题项之间的均值是否大致接近，从而为后续信度分析和因子分析提供直觉基础。第三，可以帮助用户初步理解满意度、推荐意愿和忠诚得分的大致水平。

对于问卷数据而言，这一步非常重要，因为若某些题项几乎没有变异，后续 SEM 或因子分析的意义就会大打折扣。当前这份数据的题项结构较为整齐，因此非常适合继续进入测量模型分析。

9.6 使用 Reliability Analysis 检查服务质量量表一致性

本案例中，最适合首先进入的高级统计方法是 **Reliability Analysis**。用户可以通过 **Statistics → Reliability Analysis**，先选择 `Service_Quality_Item1`、`Service_Quality_Item2` 和 `Service_Quality_Item3` 作为第一组量表。运行后，重点查看 Cronbach’s alpha 以及各题项删除后的信度变化。

这一分析的教学意义非常明确。因为它帮助用户回答一个基础问题：这几个服务质量题项能否被视为一个内部一致的量表？若信度较高，则说明它们可以较自然地共同测量某个潜在构念；若信度很低，则说明这些题项之间的一致性不足，不宜简单合并。对初学者来说，这一步往往是从“几个独立题目”走向“潜变量思维”的第一道门槛。

在本案例中，用户还可以进一步尝试把 `Cleanliness`、`Location` 和 `Value_For_Money` 作为更广义服务体验的一部分，看看不同组合下的信度如何变化。不过从方法教学角度看，第一次练习仍建议先以三个 `Service_Quality_Item` 为核心，因为它们最明显地构成一组平行题项。

图 9-2 **Reliability Analysis** 参数界面。

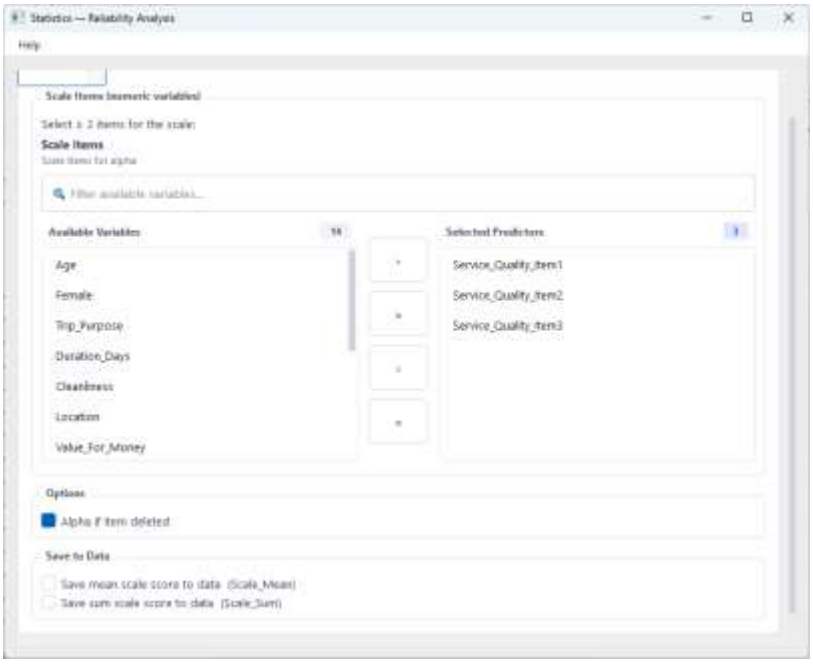

图 9-3 本案例的信度分析结果示例。

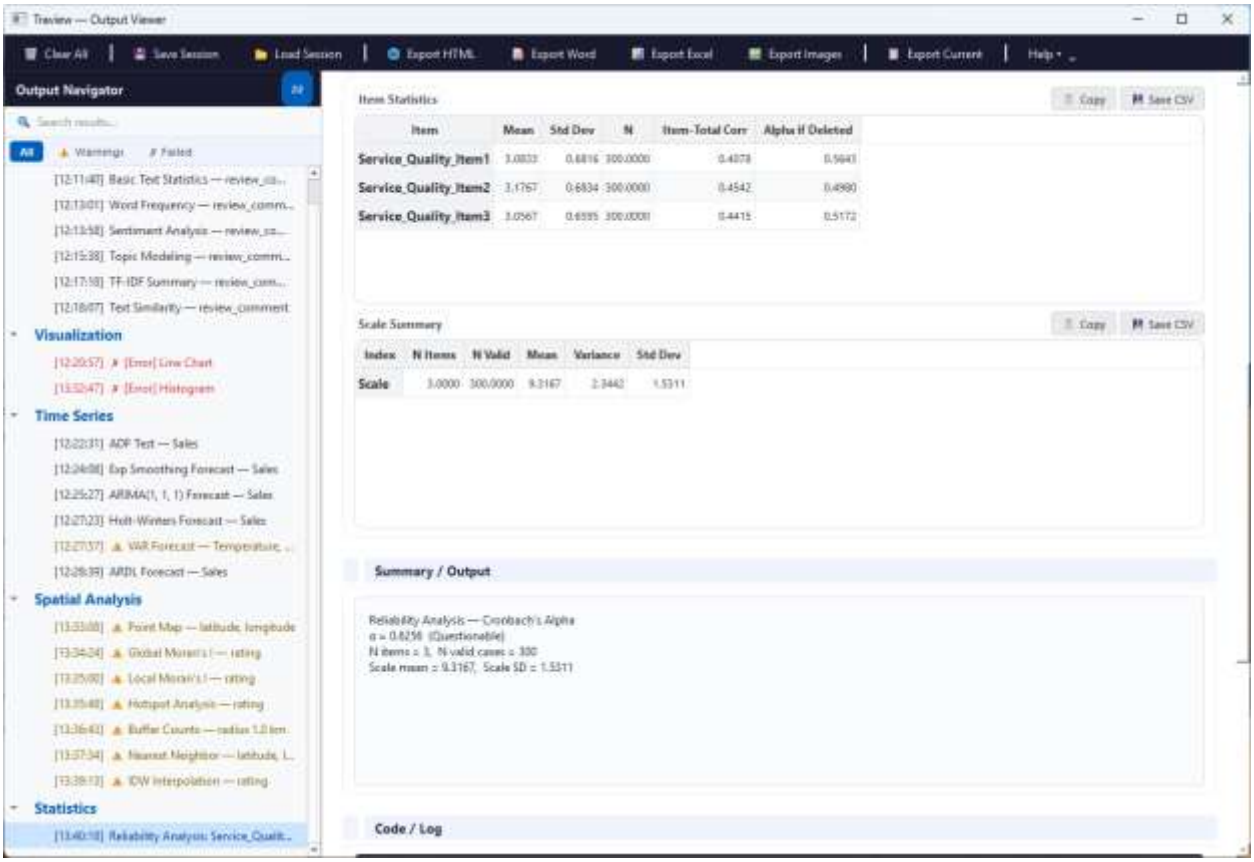

9.7 使用 Factor Analysis 探索潜在结构

在完成信度分析之后，下一步最自然的方法是 **Factor Analysis**。用户可以通过 **Statistics → Factor Analysis**，把 `Service_Quality_Item1`、`Service_Quality_Item2`、`Service_Quality_Item3`、`Cleanliness`、`Location` 和 `Value_For_Money` 一并放入分析中，观察这些题项在因子载荷上是否形成较清晰的潜在结构。

对本案例而言，一个很常见的研究预期是：服务质量三题项可能形成一个较集中的因子，而 `Cleanliness`、`Location` 和 `Value_For_Money` 则可能共同反映更广义的服务体验或价值感知维度。当然，最终结构应以数据结果为准。用户在阅读因子分析结果时，不应只看“提取了几个因子”，更应关注各题项主要加载在哪个因子上，以及这些因子是否具有可解释性。

这一步的意义在于，它为后续进入 SEM 提供了测量结构的直觉基础。换句话说，因子分析不只是一个独立方法，而是通往结构方程模型的一座桥梁。

9.8 从量表结果进入 SEM 的基本思路

在本案例中，用户不应把 SEM 看成“突然跳出来的高级模型”，而应把它理解为前面几步自然发展的结果。信度分析告诉我们题项是否有内部一致性，因子分析告诉我们题项是否在潜在结构上可以归为一组，而 SEM 则进一步允许我们同时处理测量关系和结构关系。也就是说，只有当前面的量表检查已经做过，SEM 才真正有基础。

对这份数据而言，一个最自然的 SEM 思路是：先把 `Service_Quality_Item1`、`Service_Quality_Item2` 和 `Service_Quality_Item3` 定义为一个潜变量，例如 ServiceQuality；然后把 `Overall_Satisfaction` 作为满意度结果变量；再把 `Loyalty_Score` 作为忠诚结果变量。若希望更完整，还可以让 `Recommend` 和 `Return_Intention` 作为忠诚相关结果变量共同参与结构路径。

9.9 在 SEM Workspace 中建立最基础的测量模型

用户可以通过 **Advanced Models → SEM Workspace** 打开结构方程模型子模块。进入之后，建议第一次先在 **Diagram** 中建立一个非常简单的测量模型，而不要一上来就画过于复杂的路径。具体来说，可以先点击 ◯ **Latent** 创建一个潜变量，例如命名为 `ServiceQuality`，然后点击 ▭ **Observed** 创建三个观测变量节点，即 `Service_Quality_Item1`、`Service_Quality_Item2` 和 `Service_Quality_Item3`。接着用 **Loading Path (=~)** 从潜变量指向三个题项，形成最基本的测量模型。

图 9-4 本案例的基础测量模型示意（Diagram 视图）。

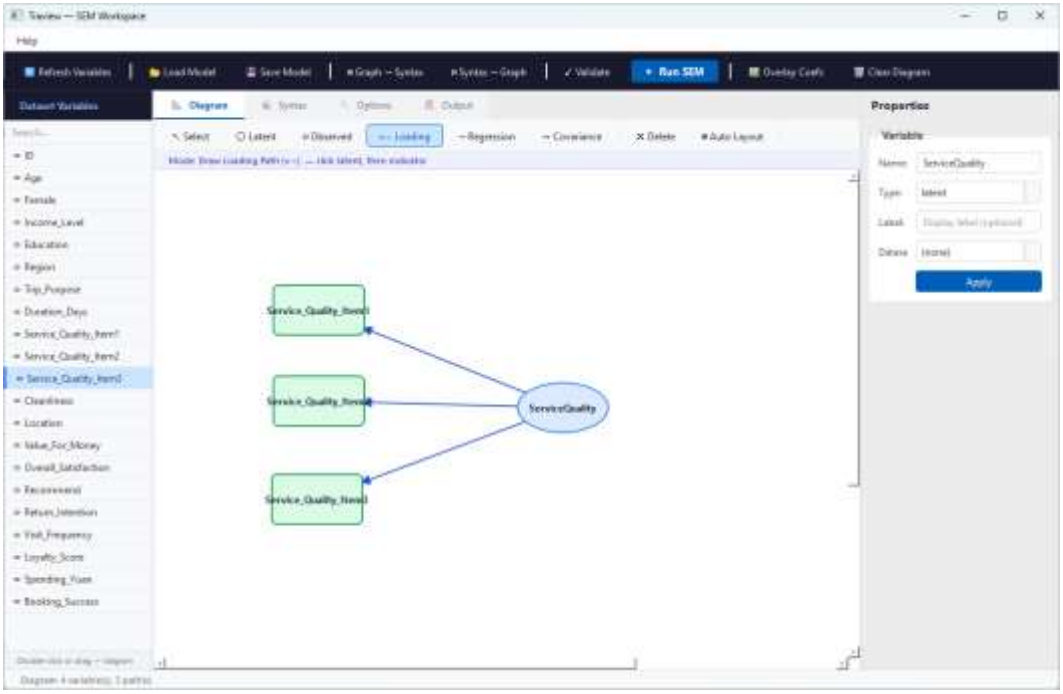

完成之后，用户应在右侧 **Properties** 面板中确认观测变量名称与数据表字段完全一致。因为在 SEM 中，观测变量一旦命名和原始字段不匹配，后续验证和估计就会失败。若用户更熟悉语法，也可以直接进入 **Syntax** 标签页，写出：

```
ServiceQuality =~ Service_Quality_Item1 + Service_Quality_Item2 +
Service_Quality_Item3
```

对于初学者而言，这一步最重要的不是画图本身，而是第一次真正看到“潜变量不是直接出现在数据表里，而是由若干观测题项共同定义”。

图 9-5 本案例的基础测量模型示意（Syntax 视图）。

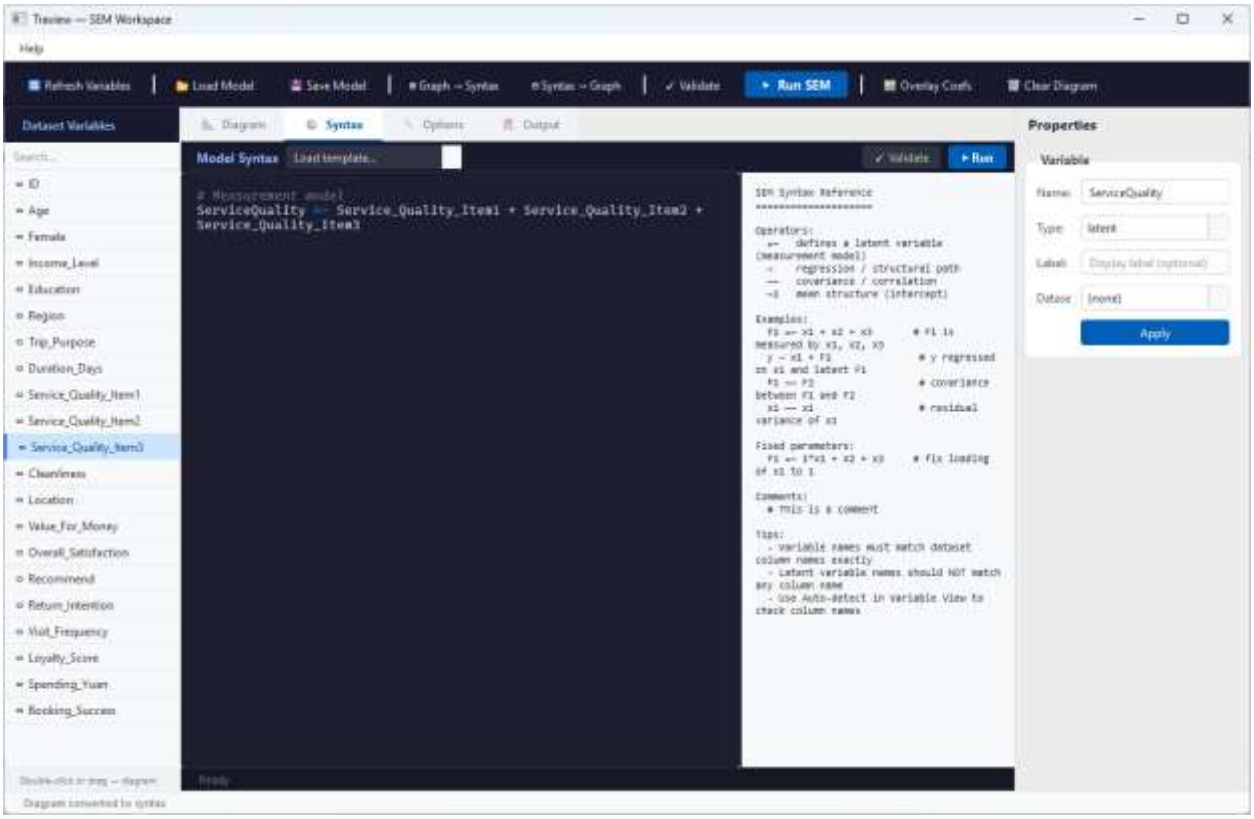

9.10 在 SEM 中加入满意度与忠诚路径

当基础测量模型建立之后，下一步就可以加入最简单的结构路径。对本案例而言，一个非常自然的路径设定是：`ServiceQuality → Overall_Satisfaction → Loyalty_Score`。如果希望保留一条直接效应，也可以同时设置 `ServiceQuality → Loyalty_Score`。这样，就形成了一个最基础的中介结构，也就是服务质量可能通过总体满意度影响忠诚度。

在 **Diagram** 中，用户可以新增 `Overall_Satisfaction` 和 `Loyalty_Score` 两个观测变量节点，然后用 **Regression Path (~)** 连接这些路径。若使用语法，则可以写成：

```
ServiceQuality =~ Service_Quality_Item1 + Service_Quality_Item2 +
Service_Quality_Item3
Overall_Satisfaction ~ ServiceQuality
Loyalty_Score ~ Overall_Satisfaction + ServiceQuality
```

这个模型虽然简单，但已经足以体现 SEM 的两个核心优势。第一，它同时包含测量模型和结构模型。第二，它允许用户在同一框架下讨论直接效应和间接路径。

9.11 使用 Validate 检查模型并运行 Run SEM

在正式估计之前，用户应先点击 **Validate**。这是本案例中非常重要的一步。因为 SEM 失败最常见的原因并不是统计本身，而是变量命名、路径表达或数据映射出现问题。当前版本的 **Validate** 会帮助用户检查观测变量是否存在、是否为数值型，以及模型语法是否基本合理。

通过验证后，用户即可点击 **Run SEM**。若估计成功，结果会同时进入 **Output** 标签页和 **Results Viewer**。在阅读结果时，建议用户先看模型是否成功收敛，再看整体拟合指标，例如 `CFI`、`RMSEA` 和 `chi2` 等，然后再进入路径系数解释。对于初学者而言，这个顺序非常重要，因为 SEM 与一般回归不同，路径系数只有在模型整体拟合尚可的前提下才更值得认真解释。

图 9-6 **Validate** 与 **Run SEM** 操作与结果示意。

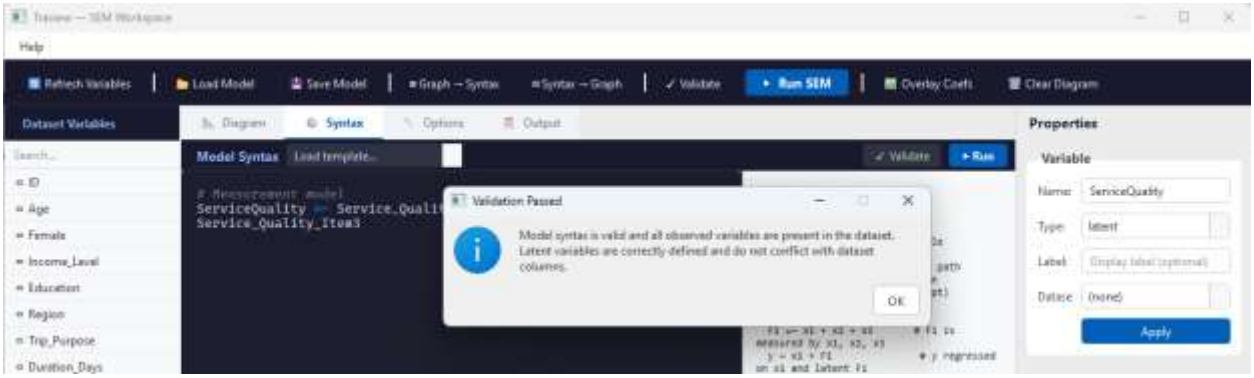

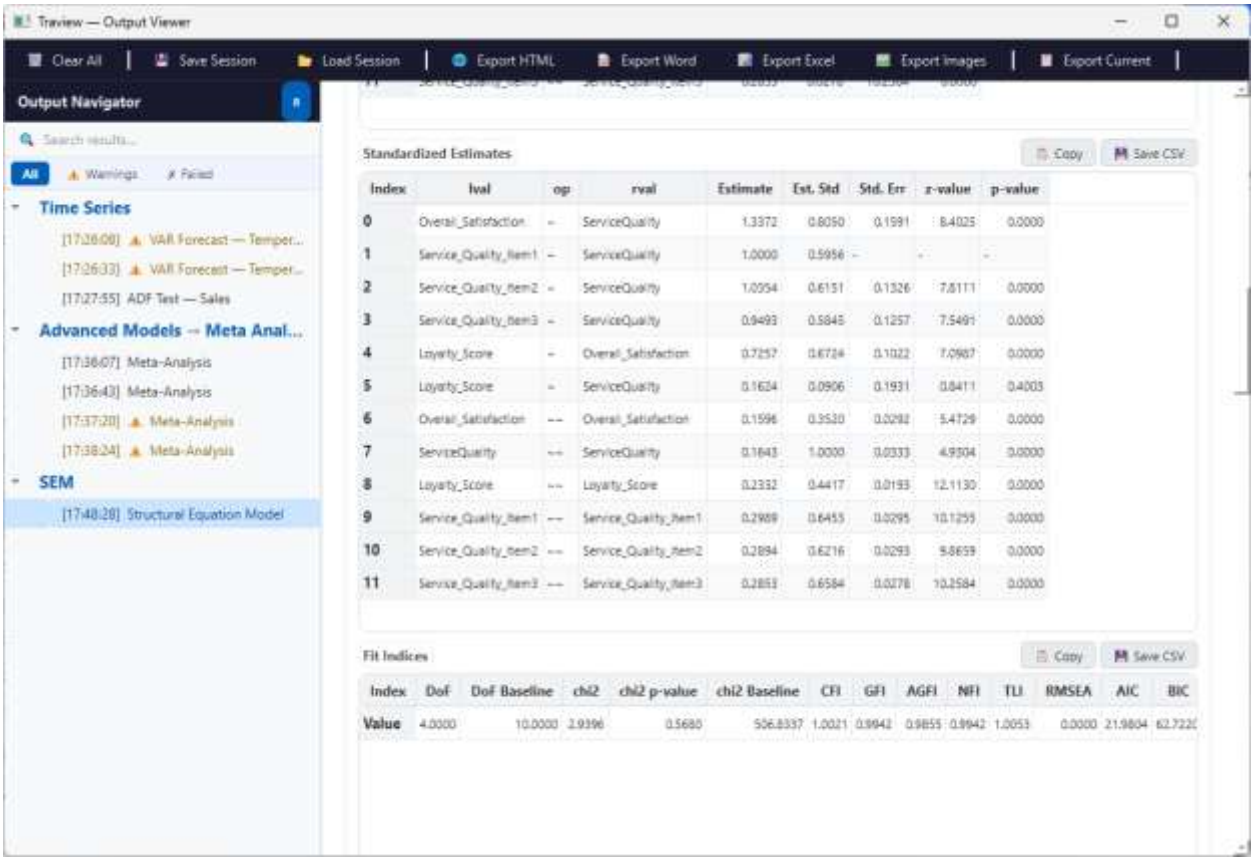

9.12 如何理解满意度的中介作用

本案例天然适合讲解一个非常常见的中介思路，也就是服务质量是否通过总体满意度影响忠诚。若在 SEM 中设置了 `ServiceQuality → Overall_Satisfaction → Loyalty_Score` 这一路径，那么其核心逻辑就是：更好的服务质量感知会提升总体满意度，而更高的满意度又进一步提升忠诚度。

对初学者来说，中介作用的关键并不在于背公式，而在于先理解“先影响谁，再通过谁影响谁”。在本案例中，若满意度路径显著，就意味着满意度可能不是一个独立存在的结果，而是服务质量通向忠诚的重要通道。若同时保留 `ServiceQuality → Loyalty_Score` 的直接路径，则还能比较直接效应和间接效应是否同时存在。

虽然更完整的中介分析还可以在 **Advanced Models → Process Model** 中完成 bootstrap 间接效应检验，但就本章而言，先在 SEM 中建立并理解这种路径结构已经非常有价值。

9.13 使用 Process Model 进行中介与调节扩展

如果读者希望进一步把本案例扩展为更明确的机制分析，则可以进入 **Advanced Models → Process Model**。例如，把 `Service_Quality_Item1` 到 `Item3` 的均值 `Scale_Mean` 或合成

得分作为 X，把 Overall_Satisfaction 作为 M，把 Loyalty_Score 作为 Y，就可以做一个简单中介模型。若进一步把 Female、Region 或 Trip_Purpose 作为调节变量，也可以探索“不同群体的机制是否相同”。

从教学上看，这一步很适合作为“SEM 之后的扩展”。因为 SEM 更强调整体验证结构，而 Process Model 更强调单一路径机制和 bootstrap 间接效应。两者并不冲突，反而能相互补充。本章不一定要求每个读者都把 Process 模型跑完，但应至少让读者知道：当前这份数据完全具备支持中介和调节分析的潜力。

图 9-7 本案例的 **Process Model** 模型参数界面。

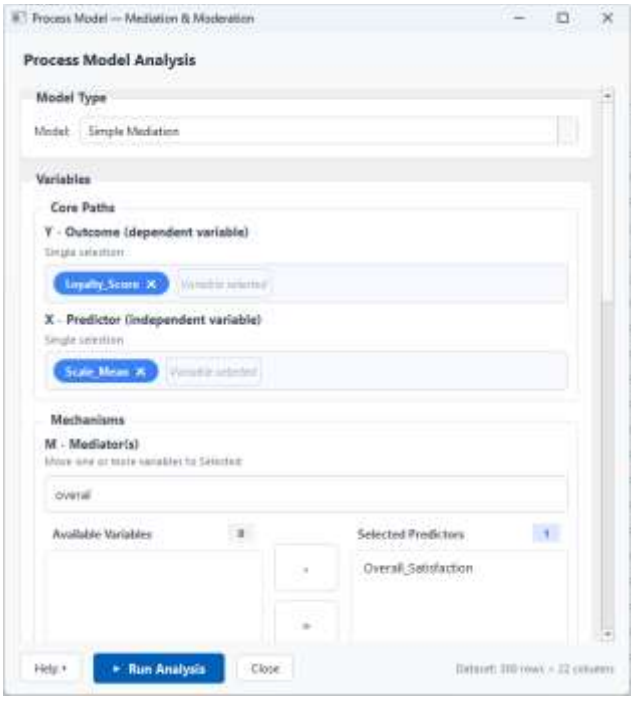

图 9-8 本案例的 **Process Model** 模型结果示意。

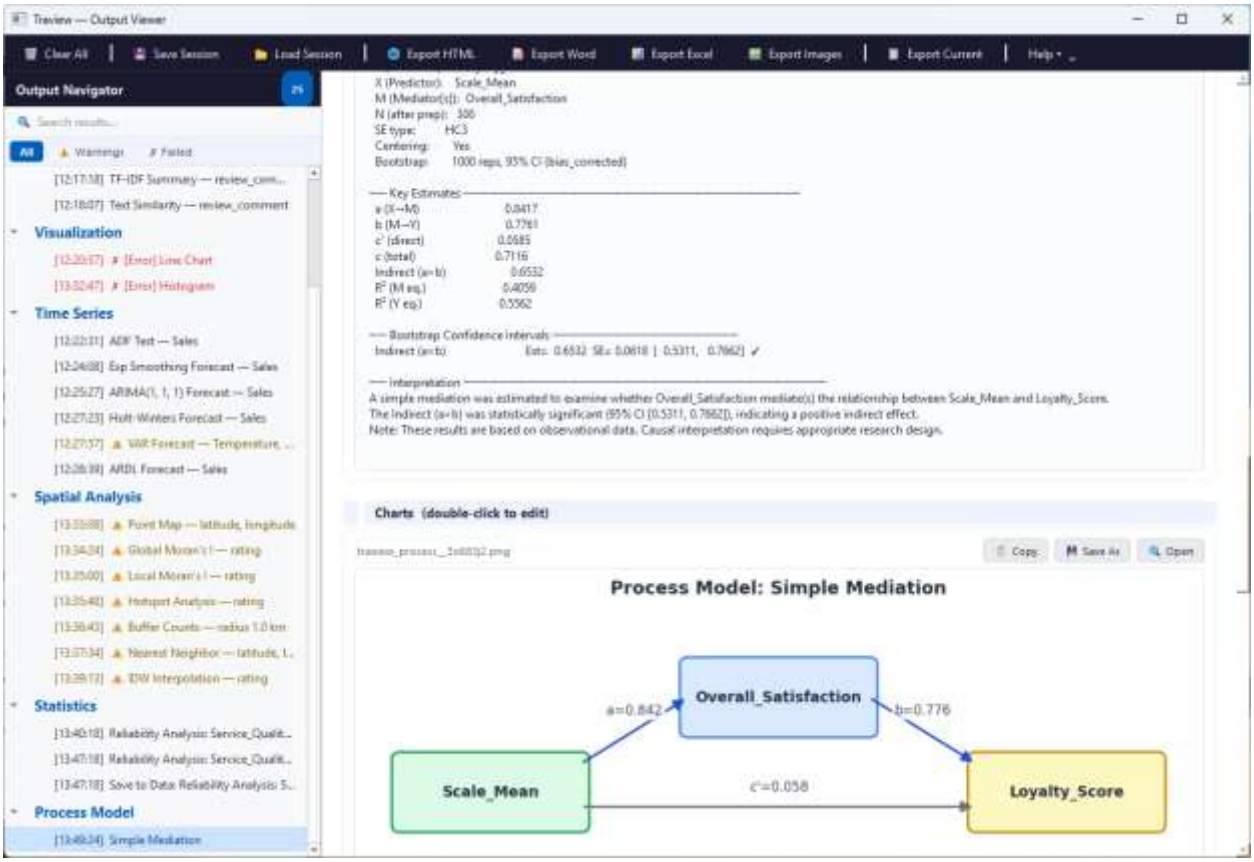

9.14 使用分类模型预测 Booking_Success

除了潜变量建模，本案例还包含一个非常适合扩展到分类预测的变量，即 `Booking_Success`。它是 0/1 变量，因此既可以在 **Econometrics → Discrete Choice → Logit** 中建模，也可以在 **Machine Learning → Classification** 中作为目标变量使用。

例如，用户可以用 `Age`、`Female`、`Income_Level`、`Duration_Days`、`Overall_Satisfaction`、`Recommend`、`Return_Intention` 和 `Loyalty_Score` 作为特征，预测 `Booking_Success`。在 **Machine Learning → Classification** 对话框，我们选择 `GradientBoosting`。 在教学中，这一步非常有帮助，因为它让学生看到问卷数据不仅能做 SEM，也能直接进入分类预测。换句话说，同一份数据可以支持完全不同的问题路径，而 Traview 的多模块结构恰好允许这种切换自然发生。

图 9-9 本案例的 **Classification** 模型参数界面。

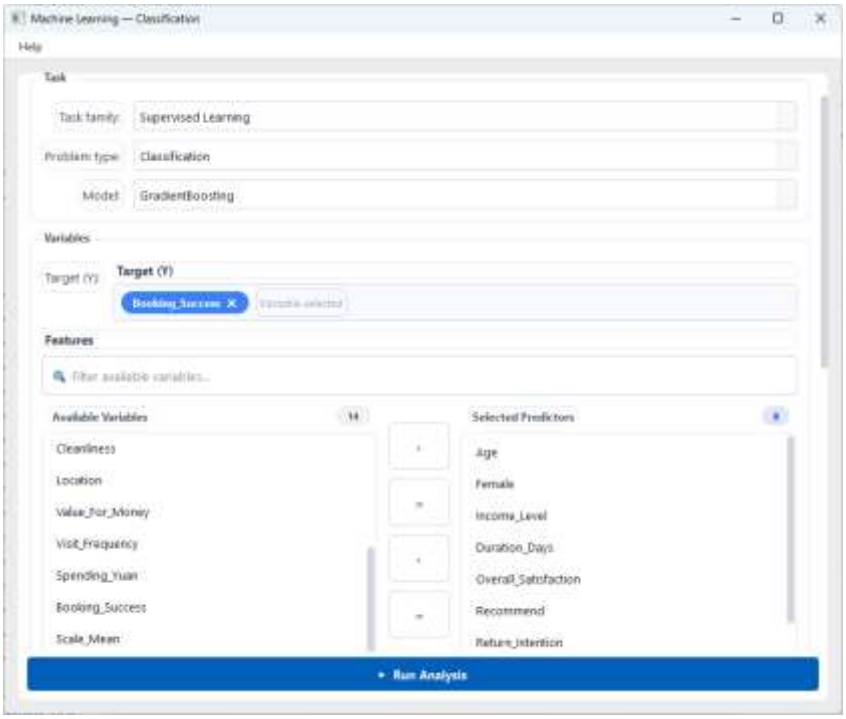

图 9-10 本案例的 **Classification** 模型结果示意。

9.15 本案例中的常见错误与排查

本案例中最常见的问题，首先来自变量角色混乱。有些用户会把量表题项和结果变量混在一起做信度分析，或在 SEM 中把潜变量和观测变量命名成同一个名字。正确做法是先明确哪些变量是测量项，哪些变量是结果项，哪些变量只是控制或分组变量。第二类常见问题是把 Likert 量表完全等同于任意连续变量。虽然在很多分析模块中它们可以当作数值使用，但在解释时仍应记住它们代表有序态度评分。

第三类问题是 SEM 语法与字段名不一致。例如，把 `ServiceQuality` 写成潜变量时没有问题，但若把 `Service_Quality_Item1` 拼错，则 **Validate** 往往会立刻报错。第四类问题是急于进入复杂 SEM，而跳过信度分析和因子分析。对教学来说，这种顺序通常并不稳妥。最后，若模型运行后没有看到结果，应先查看 **Results Viewer**，若失败则进入 **Syntax & Log**（**语法与日志窗口**） 查看是语法、变量类型还是收敛问题。

9.16 本章小结

本章围绕一份游客问卷调查数据，展示了 Traview 中量表分析、潜变量建模和行为扩展分析的基本使用路径。读者在本章中首先完成了问卷结构检查和量表题项描述统计，然后通过 **Reliability Analysis** 检查了服务质量题项的一致性，通过 **Factor Analysis** 初步探索了潜在结构，并进一步进入 **SEM Workspace** 建立了基础测量模型和服务质量—满意度—忠诚的结构路径。同时，本章还说明了如何进一步扩展到 **Process Model** 和分类预测。

从全书结构来看，本章的意义在于把前面的结构化数据、文本、时间和空间分析进一步推进到“潜变量与理论模型”层面。读者通过本章应当意识到，Traview 不仅能处理显性数据关系，也能支持测量题项、潜在构念和行为结果之间的更复杂结构。只要这一章走通，后面的元分析和效率分析就会更容易被理解为同样属于“高级但有清晰路径”的方法模块。

第 10 章 案例七：元分析效应量数据

10.1 案例背景与研究综合问题

本案例使用的是一份研究层面的元分析数据。与前面章节中的游客个体数据、评论数据、时间序列数据和空间点位数据不同，这份数据的每一行并不是一个游客、一条评论或一个时间点，而是一项独立研究的效应量记录。也就是说，本案例处理的不是“原始样本”，而是“研究的研究”。这正是元分析与一般统计分析最本质的区别。

当前案例的核心研究问题，是服务质量与游客满意度之间的相关性。数据集中采用 Pearson 相关系数 `r` 作为效应量，并包含 50 项独立研究，覆盖不同年份、不同地区、不同样本类型和不同测量工具。换句话说，这份数据非常适合用来回答这样几个典型问题：服务质量与游客满意度之间的总体关系到底有多强，不同研究之间是否存在明显异质性，这种关系是否会因为地区、样本类型或测量方式不同而发生变化，以及是否存在潜在的发表偏倚。

从 Traview 的教学和实操角度看，这份数据非常理想。因为它既可以展示最基础的固定效应和随机效应元分析，也可以自然扩展到亚组分析、元回归和发表偏倚诊断。对很多初学者来说，元分析之所以显得抽象，往往是因为不知道“每一行研究数据在软件里应该长什么样”。而这份案例数据恰好把这种结构表现得非常清楚，因此非常适合作为 **Advanced Models → Meta Analysis** 的标准入门案例。

10.2 数据集结构说明与核心变量介绍

本案例使用的数据文件名为 `meta.csv`。数据共有 50 行和 9 列。每一行代表一项独立研究的效应量记录。根据实际文件结构，这份数据的变量如下所示。

变量名	含义	类型或取值	可用于的分析
`study_id`	研究编号	当前文件中为字符型代码，如 `S001`	研究识别
`es`	效应量	连续变量	元分析核心输入
`n`	样本量	整数	权重、方差估计
`var`	效应量方差	连续变量	加权、综合估计
`year`	发表年份	连续变量	时间趋势、元回归
`region`	地区编码	1=亚洲，2=欧洲，3=北美，4=其他	亚组分析
`sample_type`	样本类型	1=酒店，2=目的地，3=航空/交通，4=餐饮	亚组分析、元回归
`measurement`	测量工具	1=SERVQUAL，2=自定义量表，3=单项评分	Moderator、元回归

published	是否已发表	0/1	发表偏倚分析

从方法角度看，es 和 var 是最核心的两列。es 提供每项研究的相关系数效应量，var 提供对应方差，因此它们构成加权综合估计的基础。n 在某些设定中也很重要，因为它既反映研究规模，也可以辅助理解效应量稳定性。region、sample_type 和 measurement 是典型的调节变量，它们使这份数据非常适合做亚组分析和元回归。published 则为发表偏倚或灰色文献比较提供了非常自然的入口。

10.3 本案例的学习目标

完成本章之后，读者应能够独立完成以下几项操作。首先，能够识别一份元分析数据中最核心的三类信息，也就是效应量、方差和调节变量。其次，能够在 **Advanced Models → Meta Analysis** 中完成固定效应模型和随机效应模型的设定与运行。再次，能够根据地区、样本类型和测量工具进行亚组分析或元回归。最后，能够阅读森林图、漏斗图和敏感性分析结果，并对异质性和发表偏倚做基础解释。

从教学角度看，本章最重要的并不是让读者背诵所有元分析术语，而是帮助他们真正理解元分析数据与一般样本数据的区别。在这里，每一行不是一个游客，而是一项研究。只要这一点真正建立起来，后面的输入设定和结果解释就会显得自然很多。

10.4 导入数据与研究级数据结构检查

本案例的第一步，是通过 **Data → Import CSV** 导入 meta.csv。导入之后，用户首先应确认数据规模是否正确。当前文件应包含 50 行和 9 列。随后，应重点检查数据是否真正符合“研究级数据”的结构。

在 **Data View** 中浏览时，用户应注意每一行都代表一项独立研究，而不是个体样本。study_id 应唯一识别每一项研究。es 应为介于相关系数合理范围内的连续值，当前文件中的效应量大多为正相关，且量级在中等范围内波动。var 应为较小的正数，说明方差已经预先计算好。region、sample_type 和 measurement 则应表现为有限类别编码，而不是连续变量。

在 **Variable View** 中，用户应确保 es 和 var 都被识别为数值列，n 被识别为整数型数值变量，published 被识别为 0/1 二元变量。由于元分析高度依赖输入格式正确，因此这一节的重要性实际上不低于后面的模型运行。只要效应量或方差列读取错误，整个元分析就无法成立。

图 10-1 导入 meta.csv 后的 **Data View**。

	study_id	es	n	var	year	region	sample_type	measurement	published
1	S001	0.52	320	0.0032	2015	1	1	1	1
2	S002	0.45	180	0.0057	2016	1	2	2	1
3	S003	0.68	450	0.0023	2017	2	1	1	1
4	S004	0.31	210	0.0049	2018	3	3	3	0
5	S005	0.59	280	0.0037	2019	1	1	1	1
6	S006	0.22	150	0.0069	2020	4	2	2	1
7	S007	0.71	390	0.0026	2021	2	1	1	1
8	S008	0.38	260	0.004	2022	1	4	2	1
9	S009	0.55	340	0.003	2015	3	1	1	1
10	S010	0.12	120	0.0086	2016	2	3	3	0
11	S011	0.64	410	0.0025	2017	1	1	1	1
12	S012	0.29	190	0.0054	2018	4	2	2	1
13	S013	0.47	300	0.0034	2019	2	1	1	1
14	S014	0.75	500	0.0021	2020	1	1	1	1

10.5 从研究视角理解效应量、样本量与方差

在进入 **Meta Analysis** 模块之前，读者应先从概念上理解三个最关键的输入列，即 es、n 和 var。es 表示每项研究报告的服务质量与游客满意度之间的相关效应量。它回答的是“这一项研究发现二者之间关系有多强”。n 表示该研究样本量，通常样本越大，效应量估计越稳定。var 表示效应量的方差，它与研究权重直接相关。一般来说，方差越小，研究在综合估计中所占权重越大。

这与前面章节的数据逻辑完全不同。前面我们常常关心个体值本身，而在这里，真正参与综合分析的，是“每项研究作为一个整体的估计结果”。对初学者来说，只要把这一点想清楚，元分析就不会显得神秘。它并不是对个体做分析，而是对已经发表或收集到的研究结果进行加权综合。

10.6 使用 Descriptive Statistics 查看效应量分布

在正式做元分析之前，建议先通过 **Statistics → Descriptive Statistics** 对 es、n、var 和 year 做一轮基础描述统计。虽然元分析本身并不依赖这一模块才能运行，但这一步非常有助于帮助用户形成对数据整体结构的直观理解。

例如，用户可以先了解总体效应量的平均水平大致处于什么范围，研究样本量是否差异很大，方差是否集中在某个量级，以及研究年份是否大致分布均匀。若发现某几项研究样本量特别小、方差特别大，就应在后续解释中更加注意它们对综合结果的贡献可能较小。若发现研究年份集中在近几年，也能为后面是否做年份元回归提供初步直觉。

这一步的教学意义在于，它帮助读者先把这份数据当作“有结构的研究样本集合”来理解，而不是一上来就只盯着森林图。

10.7 在 Meta Analysis 中设定 Effect Size Type 与输入列

完成基础检查后，用户可以通过 **Advanced Models → Meta Analysis** 打开元分析子模块。进入之后，第一步是设定 **Effect Size Type**。由于当前案例的核心效应量是 Pearson 相关系数，因此这里最自然的选择是 **Correlation (r)**。

接下来，需要指定输入列。在 **Effect Size Column** 中选择 `es`，在 **Variance Column** 中选择 `var`。同时，也可以在 **Sample Size (n)** 中指定 `n`。虽然当前数据已经提供了方差，因此并不必须依赖样本量计算方差，但保留 `n` 列有助于结果解释，也为某些扩展设定提供信息支持。若界面中存在 **Subgroup / Moderator Column**，则可以根据后续任务选择 `region`、`sample_type` 或 `measurement` 中的某一个。

对初学者而言，这里最重要的不是死记每一个输入框，而是先形成一个概念：元分析真正要告诉软件的，是“哪一列是研究结果，哪一列表示结果的不确定性，哪几列可能解释研究之间为何不同”。

图 10-2 **Meta Analysis** 的 **Input Settings** 页面。

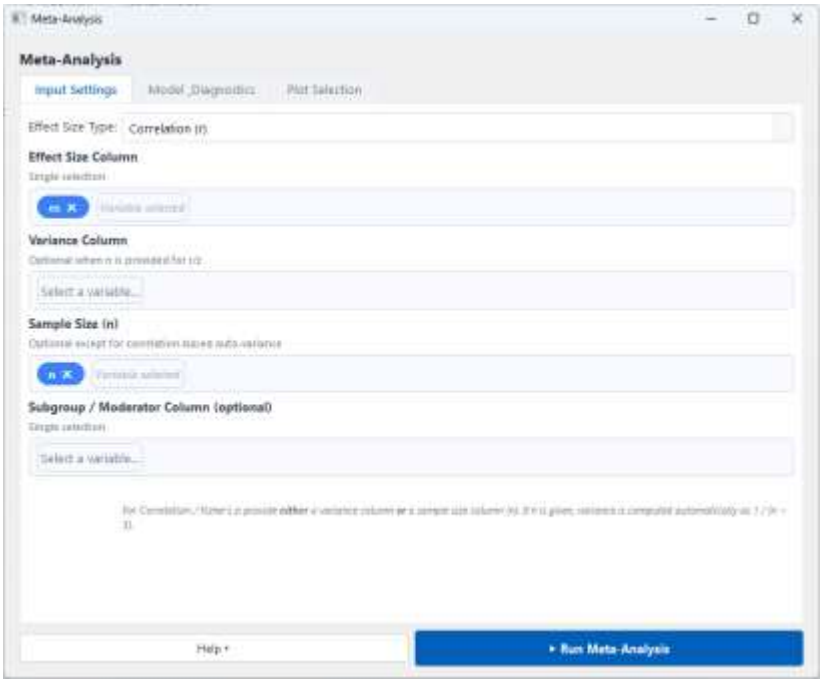

10.8 使用 Fixed Effects 与 Random Effects 比较总体效应

在元分析中，最基础的两类模型通常是固定效应模型和随机效应模型。用户可以在 **Model & Diagnostics** 页中的 **Model Type** 里，分别选择 **Fixed Effects** 和 **Random Effects (REML)** 运行比较。

对本案例而言，随机效应模型通常会更自然。因为这 50 项研究跨不同年份、不同地区、不同样本类型和不同测量工具，本身就很难假设它们共享一个完全相同的真实效应。因此，随机效应模型更符合“不同研究可能存在真实差异”的逻辑。不过，在教学中，先同时跑一次固定效应和随机效应也很有价值，因为它能帮助读者看到：当研究之间存在异质性时，两类模型的综合结果可能并不完全相同。

运行之后，用户应在 **Results Viewer** 中重点关注总体效应量及其置信区间。如果总体相关为正且显著，则通常说明服务质量与游客满意度之间存在较稳定的正向关系。与此同时，还应留意异质性统计量，因为它决定了后面是否有必要进入调节变量分析。

10.9 使用 Forest Plot 阅读研究与总体结果

在元分析中，**Forest Plot** 几乎是最核心的图形输出。用户可以在 **Plot Selection** 中勾选 **Forest Plot**，然后运行模型。结果中通常会显示每项研究的效应量及其置信区间，并在图的底部给出总体合并效应。

对于初学者来说，森林图最重要的阅读顺序是：先看每一项研究的大致方向，再看各研究置信区间的宽窄，最后再看总体合并结果。若大多数研究都集中在正相关区间，总体结果通常也会更稳健。若个别研究方向与大多数研究明显不同，这往往提示存在异质性，后续就更值得进入亚组分析或元回归。

与前面章节中的图表不同，森林图的每一个点并不是一个样本，而是一项研究。因此，在本案例中，森林图也帮助读者再次强化“研究级数据”的视角。

图 10-3 本案例的 **Forest Plot** 结果示例。

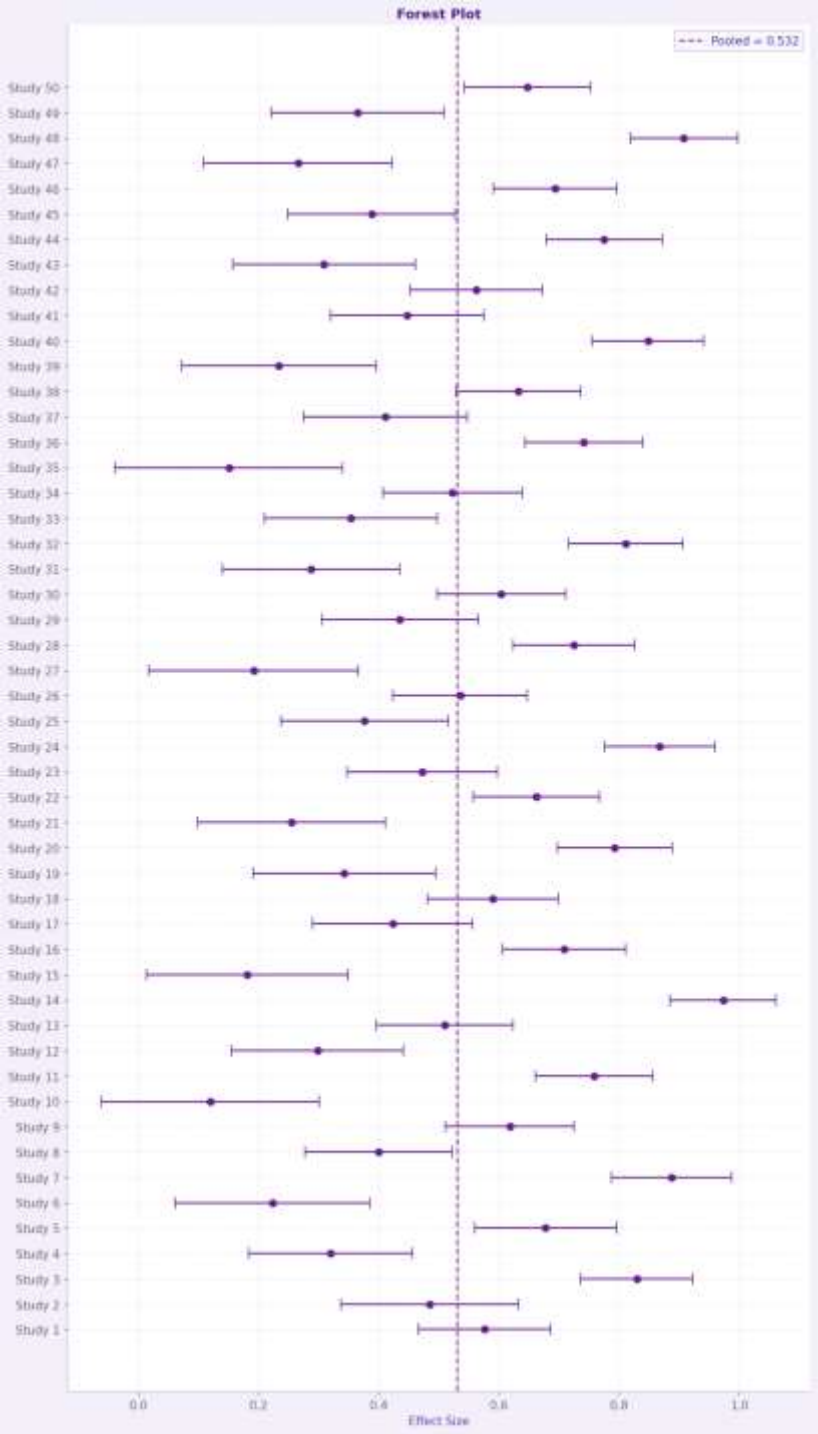

10.10 使用 Funnel Plot 检查发表偏倚

除了看总体效应，元分析中另一个非常重要的问题是发表偏倚。当前案例中已经提供了 `published` 变量，因此本身就很适合结合发表状态思考偏倚问题。在 **Plot Selection** 中勾选 **Funnel Plot (publication bias)** 后，用户可以生成漏斗图，观察研究分布是否大致对称。

如果漏斗图明显不对称，通常意味着发表偏倚、小样本效应或其他系统性偏差的可能性增加。当然，漏斗图本身是一种诊断工具，而不是绝对证明。因此，在解释时应使用较稳妥的语言，例如“图形上存在一定不对称迹象”，而不应简单写成“已经证明存在发表偏倚”。

当前案例中的 `published` 变量还提供了另一个非常自然的扩展方向，也就是比较已发表研究和未发表研究之间的效应量差异。即便不在本章中完全展开，也应让读者意识到：元分析中的偏倚分析并不只是画一张图，它也可以与调节变量和研究状态结合起来讨论。

图 10-4 本案例的 **Funnel Plot** 结果示例。

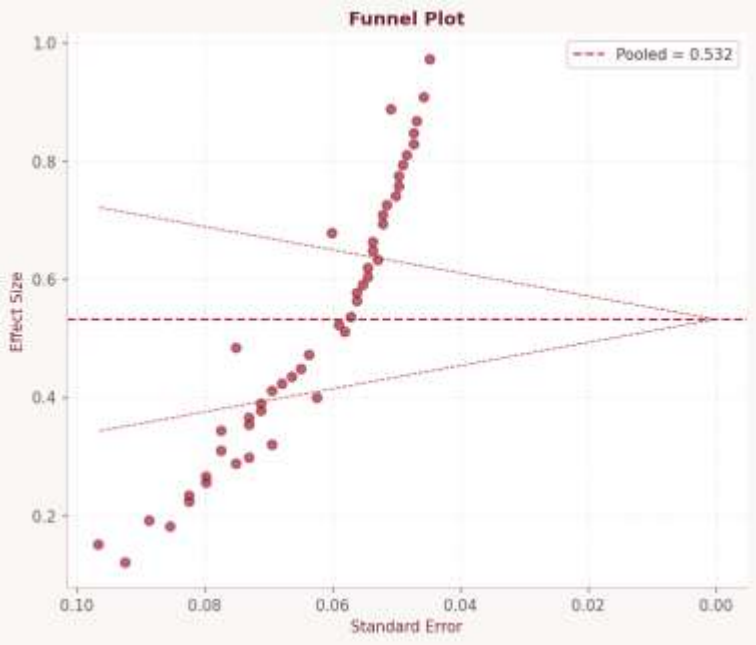

10.11 使用 Leave-One-Out Sensitivity Plot 做敏感性分析

在元分析中，除了总体结果和发表偏倚之外，还应检查综合结论是否过度依赖个别研究。当前版本提供的 **Leave-One-Out Sensitivity Plot** 正是为此服务的。用户在 **Plot Selection** 中勾选这一项后，软件会逐一删除单个研究，重新计算总体效应，并展示综合结果在不同删除条件下的变化。

这一结果对教学非常有帮助，因为它让读者直观地看到：如果去掉某一项研究，总体结论是否仍然稳定。若删除任意单个研究后总体效应都变化不大，则说明结论较稳健。若去掉某一项研究后总体效应明显跳动，则说明该研究在综合结果中具有较强影响力，后续解释时应更谨慎。

图 10-5 本案例的 **Leave-One-Out Sensitivity Plot** 结果示例。

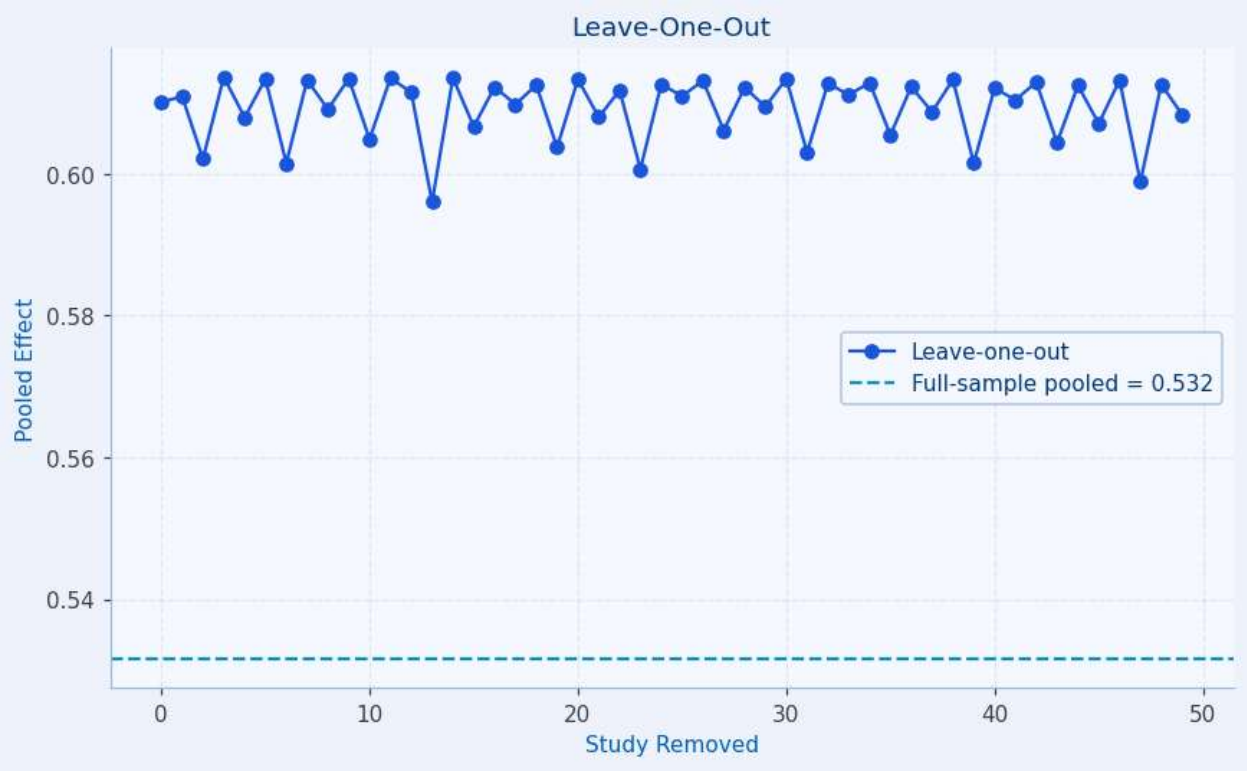

10.12 使用 Subgroup Analysis 比较地区和样本类型差异

由于当前数据中包含 `region` 和 `sample_type` 两个非常清楚的类别型调节变量，因此本案例特别适合做亚组分析。用户可以在 **Subgroup / Moderator Column** 中分别选择 `region` 或 `sample_type`，查看不同组别下总体效应是否存在明显差异。

从研究意义上看，这一步可以帮助回答诸如“亚洲研究与北美研究中的服务质量—满意度关系是否一样强”“酒店样本与航空/交通样本中的相关性是否存在系统差异”等问题。对初学者而言，亚组分析通常比元回归更容易理解，因为它本质上是把研究分成几组，再分别估计每一组的综合效应。

在解释时，用户应特别注意不要只说“哪一组更高”，还应结合样本量、研究数量和异质性情况一起判断。因为某一小组样本很少时，其结果往往不如大组稳定。

图 10-6 本案例的 **Subgroup** 比较结果示例。

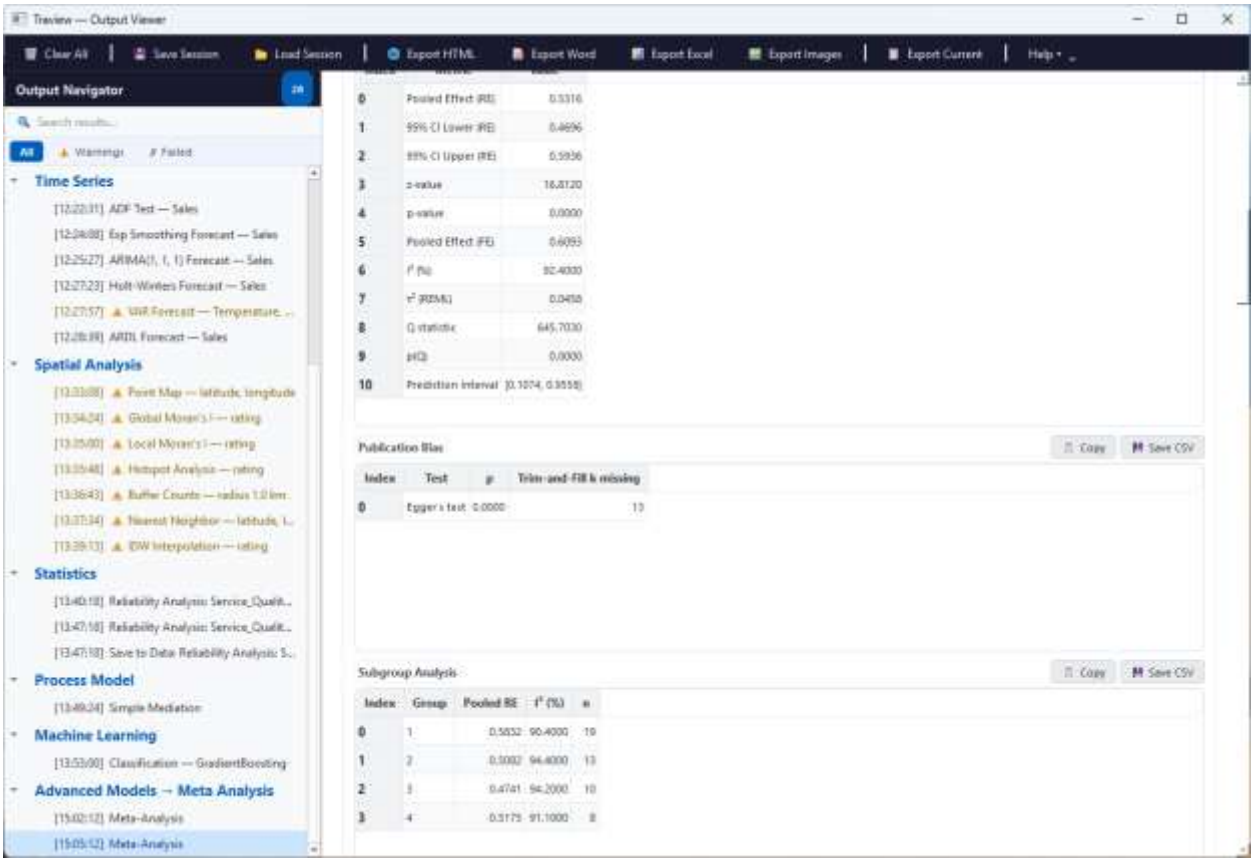

10.13 使用 Meta-Regression 检验年份、测量工具与发表状态的调节作用

当读者已经理解亚组分析后，下一步就非常适合进入 **Meta-Regression**。在当前案例中，`year`、`measurement` 和 `published` 都是很自然的调节变量候选。用户可以在 **Model & Diagnostics** 中启用 **Meta-Regression**，并选择这些变量中的一个或多个作为解释项。

从研究问题上看，这一步可以帮助回答几个非常有代表性的问题。比如，近年的研究中服务质量与游客满意度的相关性是否更强或更弱。使用 SERVQUAL 的研究是否与自定义量表研究得到不同大小的效应。已发表研究是否比未发表研究更容易报告更高的相关性。这些问题不仅具有方法意义，也非常适合在课堂上帮助学生理解“研究之间为什么会不一样”。

需要提醒的是，元回归的解释逻辑与普通个体回归不同。这里的回归单位是研究，而不是游客。因此，结果应被理解为“研究特征是否解释了研究间效应量差异”，而不是“某个个体变量如何影响满意度”。

10.14 使用 published 做发表偏倚与灰色文献比较

当前案例中的 `published` 变量非常适合作为一个专门的扩展分析。用户既可以把它作为元回归中的一个调节变量，也可以把它作为亚组分析分组变量。若已发表研究与未发表研究在总体效应上存在明显差异，那么这将为发表偏倚或灰色文献差异提供一个非常直观的证据方向。

这一步对教学特别有价值，因为很多学生会把“发表偏倚”误解为一个完全抽象的概念。而在当前案例中，`published` 变量正好提供了一个看得见、比得出的入口。通过这一分析，读者就能更清楚地理解：发表偏倚并不只是漏斗图上的形状问题，也可以体现在已发表与未发表研究系统性差异上。

10.15 结果解释：总体效应、异质性与调节变量

在本案例中，元分析结果的解释通常应分成三个层次。第一个层次是总体效应，也就是服务质量与游客满意度之间的综合相关是否为正，大小大约是多少。第二个层次是异质性，也就是这些研究之间是否存在明显差异，是否有必要继续做亚组分析和元回归。第三个层次是调节变量，也就是地区、样本类型、测量工具和发表状态是否能够解释部分研究差异。

这种分层解释方式非常重要，因为很多初学者容易把元分析仅仅理解为“求一个平均相关”。实际上，真正有价值的元分析几乎总是同时关心总体效应和研究差异。尤其在像本案例这样跨地区、跨样本类型、跨测量工具的数据中，异质性和调节效应往往比单一均值更值得讨论。

10.16 本案例中的常见错误与排查

本案例中最常见的问题，首先来自输入列角色混乱。有些用户会把 `n` 误当作效应量列，或把 `var` 忘记指定。正确做法是始终记住：`es` 是效应量，`var` 是方差，`n` 是样本量。第二类常见问题是把调节变量误当成连续变量或误读其编码含义。例如，`region = 1` 并不表示“亚洲比欧洲少 1”，而只是类别编码。

第三类问题是只看森林图底部的总体效应，而忽略异质性和调节分析。对元分析来说，这种阅读方式过于简单。第四类问题是把发表偏倚图上的不对称直接写成绝对结论，而没有保留必要的诊断性表述。最后，若模型运行后没有看到结果，应先查看 **Results Viewer**，若失败则进入 **Syntax & Log**（语法与日志窗口） 查看是输入列设定还是模型参数设定出了问题。

10.17 本章小结

本章围绕一份服务质量与游客满意度相关性的研究级元分析数据，展示了 Traview 中 **Advanced Models → Meta Analysis** 的基本使用路径。读者在本章中首先完成了研究级数据结构检查，然后设定了效应量与方差输入，依次运行了固定效应和随机效应模型，查看了森林图、漏斗图和敏感性分析结果，并进一步通过地区、样本类型、测量工具和发表状态开展了亚组分析与元回归。

从全书结构来看，本章的意义在于把 Traview 的高级分析能力进一步扩展到“研究综合”层面。前面的章节主要围绕原始样本数据展开，而本章则强调如何把多项独立研究的结果整合起来。只要这一章走通，读者就会更清楚地理解：Traview 不仅能做单一数据集分析，也能支持更高层次的证据综合工作流。

第 11 章 案例八：投入—产出效率评价数据

11.1 案例背景与效率评价问题

本案例使用的是一份酒店投入—产出与经营特征数据。与前面几章主要关注相关关系、文本内容、时间变化或空间分布不同，这份数据最重要的特点在于它天然适合回答“谁更有效率”这一问题。也就是说，本案例不再只是问某个变量是否影响另一个变量，而是进一步问：在投入相近或资源有限的条件下，不同酒店把投入转化为收入、客房夜数和满意度的能力是否存在差异。

从研究与教学角度看，这类问题非常典型。因为在酒店经营研究中，光看收入高低往往是不够的。收入高，可能只是因为投入也非常大；成本低，也可能是因为服务水平较低。因此，真正更有价值的问题通常是：不同酒店在综合投入与综合产出的关系上，是否存在相对效率差异。这正是 DEA 和 SFA 这两类方法要解决的问题。

当前文件共有 100 家酒店的观测，覆盖三个区域和不同星级水平。这份数据原本可以同时支持 DEA 和 SFA，并可进一步比较区域差异、酒店星级异质性以及环境因素影响。本章会重点围绕文件中的 9 个字段展开，也就是以 DEA 为主、以 SFA 为扩展思路来组织实操路径。

11.2 数据集结构说明与核心变量介绍

本案例使用的数据文件名为 `dea.csv`。数据共有 100 行和 9 列。每一行代表一家酒店的经营单元。根据实际文件结构，这份数据的变量如下所示。

变量名	含义	类型或取值	可用于的分析
`hotel_id`	酒店编号	当前文件中为字符型代码，如 `H001`	DEA / SFA 标识
`employees`	员工数	连续变量	DEA 输入、SFA 前沿变量
`operating_cost`	年运营成本（万元）	连续变量	DEA 输入、SFA 前沿变量
`rooms`	客房数	连续变量	DEA 输入、SFA 前沿变量
`revenue`	年收入（万元）	连续变量	DEA 输出、SFA 因变量
`guest_nights`	年客房夜数	连续变量	DEA 输出
`satisfaction`	满意度评分	1–5 区间连续变量	DEA 输出
`region`	区域编码	1–3	子组效率比较

hotel_star	星级	3–5	分组分析、异质性比较

从方法设计上看，这份数据最自然的 DEA 路径是把 employees、operating_cost 和 rooms 作为投入变量，把 revenue、guest_nights 和 satisfaction 作为产出变量。这样做的好处是，投入维度同时覆盖人力、成本和容量，产出维度同时覆盖收入、使用规模和服务结果，比较适合做一个教学上完整而平衡的 DEA 示例。对于 SFA，则最自然的设定通常是把 revenue 作为因变量，把 employees、operating_cost 和 rooms 作为前沿生产函数中的投入变量。

11.3 本案例的学习目标

完成本章之后，读者应能够独立完成以下几项操作。首先，能够识别效率分析中“决策单元”“投入变量”和“产出变量”三类核心角色。其次，能够在 **Advanced Models → Efficiency Analysis** 中完成 DEA 的基本设定，并理解 **Input-oriented**、**Output-oriented**、**CRS** 和 **VRS** 这些关键选项的含义。再次，能够阅读效率得分、规模效率以及排序图和分布图。最后，能够把效率得分写回数据表，并进一步结合区域和星级做比较分析。

从教学角度看，本章最重要的不是一开始就让读者掌握所有 DEA 或 SFA 理论细节，而是帮助他们先理解一个最核心的逻辑：效率分析看的不是“谁的收入最高”，而是“谁在给定投入条件下把资源转化为产出的能力更强”。只要这一点真正建立起来，后面的 DEA 和 SFA 结果就会更容易被正确理解。

11.4 导入数据与投入—产出结构检查

本案例的第一步，是通过 **Data → Import CSV** 导入 dea.csv。导入成功后，用户首先应确认数据规模是否正确。当前文件应包含 100 行和 9 列。接下来，最重要的工作不是立刻进入效率模型，而是先确认数据是否真的符合投入—产出分析的逻辑。

在 **Data View** 中浏览时，用户应重点查看 employees、operating_cost 和 rooms 三列。它们应表现为正数连续变量，并且具有一定的规模差异。然后再查看 revenue、guest_nights 和 satisfaction。这些列将作为 DEA 中的产出变量，因此也应具备合理范围。对于当前文件而言，satisfaction 虽然取值在 3 到 5 左右的较窄区间内，但仍可以作为服务质量维度的产出指标使用。与此同时，用户还应确认 region 和 hotel_star 的编码是否合理，因为它们在后续区域差异和星级异质性分析中会用到。

进入 **Variable View** 后，用户应再次确认这些投入与产出列都被识别为数值型变量。这里需要特别提醒的是，效率分析不像普通回归那样可以随意把变量混合放入模型。只要把投入变量误放成产出变量，或者把产出变量误放成投入变量，结果解释就会完全相反。因此，在正式进入 DEA 之前，先把变量角色想清楚，比点击任何按钮都更重要。

图 11-1 导入 `dea.csv` 后的 **Data View**。

	hotel_id	employees	operating_cost	rooms	revenue	guest_nights	satisfaction	region	hotel_star
1	H001	45	320	120	1850	28500	4.2	1	4
2	H002	38	280	95	1420	21800	4.5	1	5
3	H003	52	410	150	920	14200	3.8	1	3
4	H004	29	210	80	1680	25100	4.7	2	4
5	H005	61	480	180	760	11800	3.5	2	3
6	H006	35	250	110	2050	31200	4.6	2	5
7	H007	48	350	130	1340	19700	4.1	2	4
8	H008	42	290	105	980	15300	3.9	3	3
9	H009	55	390	160	1720	26500	4.3	3	4
10	H010	33	240	85	1180	17900	4.0	3	5
11	H011	47	330	125	1960	29800	4.8	1	5
12	H012	39	270	100	890	13700	3.7	1	3
13	H013	58	450	170	1430	22100	4.2	1	4
14	H014	31	220	90	1670	25500	4.4	2	4
15	H015	50	380	140	810	12600	3.6	2	3
16	H016	36	260	115	2120	32400	4.9	2	5

100 rows × 8 columns · 0 missing values

11.5 先用基础统计理解投入与产出的规模差异

虽然本章的重点是效率分析，但在进入 **Efficiency Analysis** 之前，仍建议先通过 **Statistics → Descriptive Statistics** 对 `employees`、`operating_cost`、`rooms`、`revenue`、`guest_nights` 和 `satisfaction` 做一轮基础描述统计。

这样做的意义有三个。第一，它帮助用户了解不同投入与产出变量的大致量级。例如，运营成本和收入是否处于同一个数量级，客房夜数是否与客房数有明显规模对应关系。第二，它帮助识别极端值。若某家酒店收入特别高但投入并不突出，后面很可能会在 DEA 中表现为高效率单元。第三，它帮助用户形成对数据结构的直观认识，也就是这份数据不是简单的“谁高谁低”，而是多投入、多产出并存的经营系统。

这一步虽然不是效率分析本身，但它有助于避免一个常见错误：读者在完全不理解变量尺度的情况下，直接进入 DEA，结果拿到效率值却不知道该如何与原始经营规模联系起来。

11.6 在 Efficiency Analysis 中设定 DEA 模型

完成基础检查之后，用户可以通过 **Advanced Models → Efficiency Analysis** 打开效率分析子模块。在 **Input Settings** 标签页中，首先应在 **Analysis Method** 中选择 **DEA (CCR/BCC)**。然后，在 **DMU Identifier Column** 中选择 `hotel_id`。这是当前文件中最自然的决策单元标识列。

接下来，在 **Input Variables** 中应选择 `employees`、`operating_cost` 和 `rooms`。在 **Output Variables** 中应选择 `revenue`、`guest_nights` 和 `satisfaction`。这一步非常关键，因为 DEA 的本质就是在一组投入和产出之间构建相对效率前沿。如果投入和产出选错，后续所有结果都会失去意义。

在本案例中，这一设定非常适合作为教学入门。原因在于，它把经营中的三类资源投入与三类结果产出自然对应了起来。读者不需要先掌握复杂的数学规划背景，也可以直观理解：员工、成本和客房是资源，收入、客房夜数和满意度是结果。DEA 关注的正是这些资源与结果之间的相对转化能力。

图 11-2 **Efficiency Analysis** 的 **Input Settings** 页面。

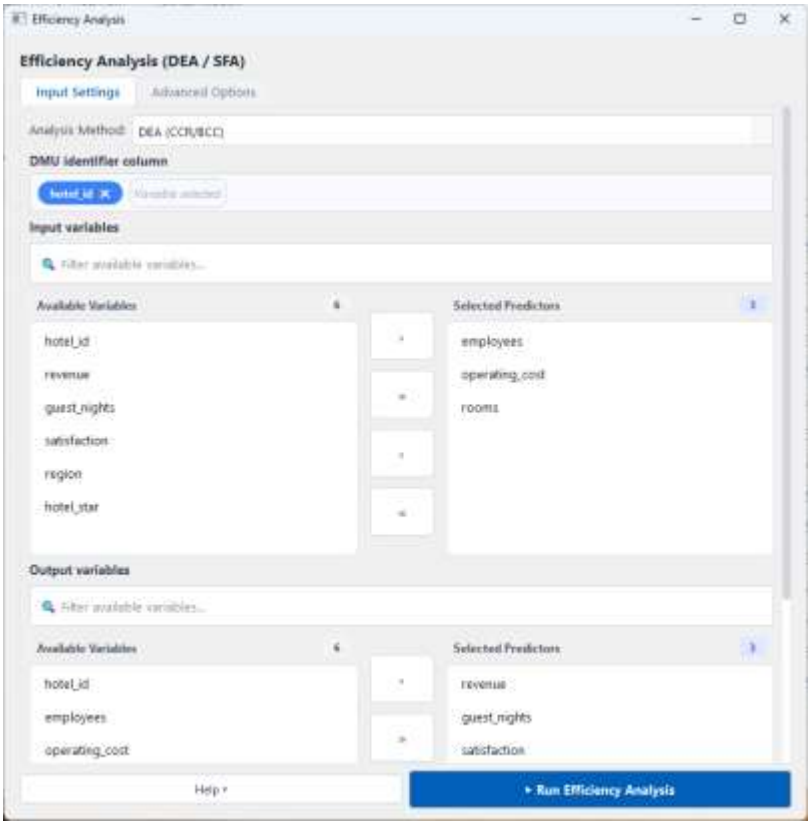

11.7 理解 Input-oriented 与 Output-oriented

在 DEA 中，用户通常还需要选择 **Orientation**，也就是导向方式。当前版本支持 **Input-oriented** 和 **Output-oriented**。对初学者来说，这一选项往往是最容易混淆、但又最值得先讲清楚的地方。

若选择 **Input-oriented**，模型的核心逻辑就是：在既定产出水平下，哪家酒店更能节约投入。换句话说，它更适合回答“谁更省资源”。若选择 **Output-oriented**，模型的逻辑则是：在既定投入条件下，哪家酒店更能扩张产出，也就是“谁更能把资源转化为结果”。

对于酒店经营研究而言，这两种导向其实都说得通。如果研究更关注资源节约，例如在不降低收入和满意度的情况下减少投入，则 **Input-oriented** 更自然。若研究更关注经营扩张，例如在现有资源基础上谁能带来更多收入和客房夜数，则 **Output-oriented** 更自然。作为本案例的第一轮实操，我建议先使用 **Input-oriented**，因为它更容易帮助读者理解“效率”与“资源节约”之间的关系。

11.8 理解 CRS 与 VRS：常数报酬与可变报酬

除了导向方式，DEA 中另一个关键选项是 **Returns to Scale**，当前版本支持 **CRS (Constant Returns)** 和 **VRS (Variable Returns)**。这两个选项决定了效率前沿对规模报酬的假设。

如果选择 **CRS**，意味着模型假设投入和产出之间在比例上是线性的，也就是投入翻倍，产出理论上也应等比例变化。这种设定更严格。若选择 **VRS**，则表示允许不同规模酒店存在规模报酬差异，模型更灵活，也更适合现实中大小酒店在经营模式上不完全一致的情况。

对教学而言，一个非常清楚的理解方式是：**CRS** 更像在问“谁在完全统一的规模逻辑下最有效率”，而 **VRS** 更像在问“在考虑不同规模差异后，谁在自己规模条件下更有效率”。在多数应用场景中，先同时跑一次 CRS 和 VRS，比较两者差异，是非常有价值的做法。因为这样用户不仅能看到综合效率，还能进一步理解纯技术效率和规模效率之间的区别。

11.9 运行 DEA 并阅读效率得分

在设定好 **DMU Identifier Column**、投入变量、产出变量、导向和规模报酬之后，用户就可以点击 ▶ **Run Efficiency Analysis** 运行 DEA。分析成功后，结果会进入 **Results Window**。此时，用户首先应查看效率得分表。

对于初学者来说，效率得分最直观的理解方式是把它看作“相对前沿距离”。得分越接近 1，说明该酒店越接近当前样本中的最佳实践前沿。得分明显低于 1，则说明在当前比较框架下，它还有改善空间。不过，必须特别强调：DEA 效率是相对效率，而不是绝对好坏判断。某家酒店效率低，并不等于它经营差，只意味着它相对于样本中的标杆酒店，在投入—产出转换上还有距离。

如果当前版本同时输出 `dea_crs`、`dea_vrs` 和 `dea_scale_efficiency` 一类指标，则用户应意识到，这些结果分别对应综合效率、纯技术效率和规模效率。也就是说，酒店低效率到底是因为技术性管理不足，还是因为规模条件不理想，可以通过这些结果进一步理解。

图 11-3 本案例的 DEA 结果表示例。

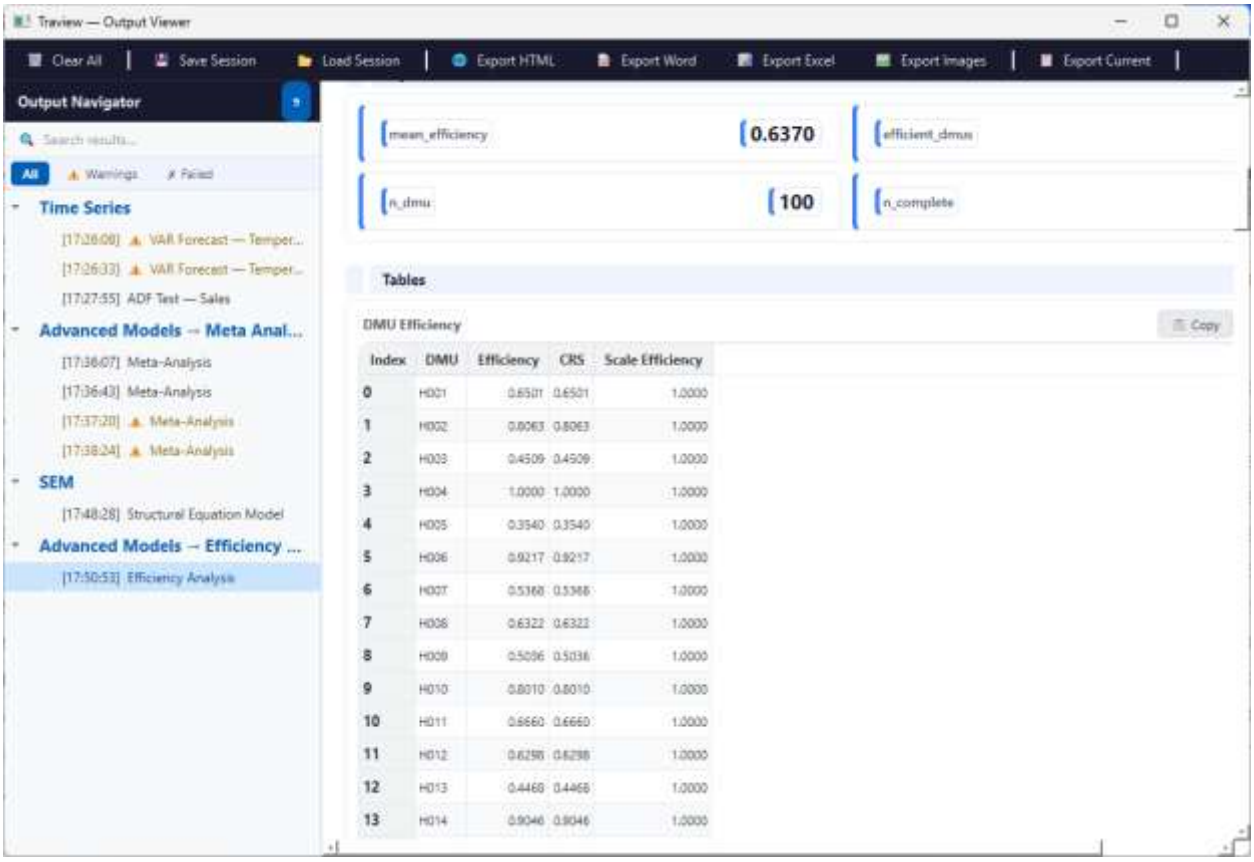

11.10 使用效率分布图与排序图理解结果

当前版本在 **Advanced Options** 中支持两类非常有帮助的图形，即 **Efficiency Distribution (Histogram)** 和 **Efficiency Ranking (Bar Chart, sorted)**。建议用户在 DEA 运行时勾选这两项。

效率分布图有助于回答一个非常重要的问题：样本整体上是多数酒店都接近高效率，还是存在大量中低效率酒店。若分布高度集中在 0.9 以上，说明整体效率较高；若大部分集中在中低区间，则说明样本中存在较大改进空间。排序图则更适合快速识别哪些酒店是前沿酒店，哪些酒店排在后部。对于课堂教学和管理汇报而言，这两张图的可读性通常比单独一张长表格更强。

在解释这类图时，仍应强调相对性。排序靠前并不代表酒店绝对收入最高，而是代表它在当前投入—产出组合下表现更接近效率前沿。这一点是 DEA 最容易被误解的地方之一。

图 11-4 本案例的 **Efficiency Distribution (Histogram)** 结果示例。

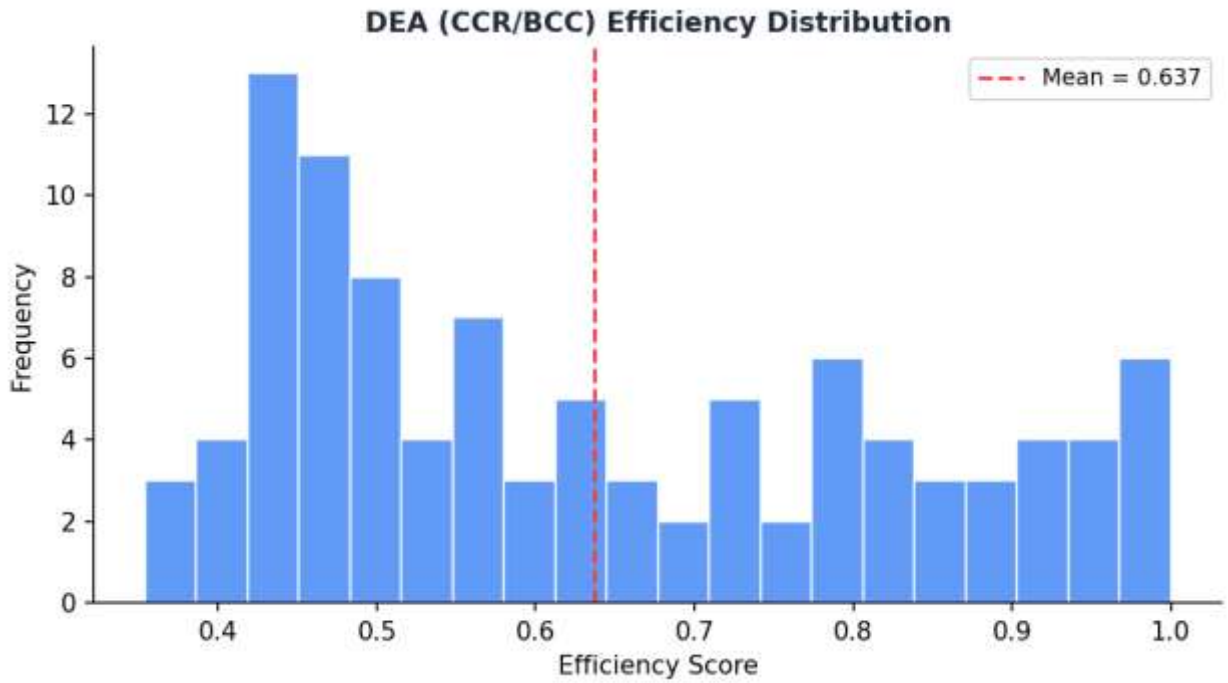

11.11 使用 Write scores back to dataset 写回效率结果

本案例中一个非常值得练习的功能，是将效率得分写回当前数据表。当前版本在 **Advanced Options** 中提供 **Write scores back to dataset**。建议在本案例中保持默认启用。这样，运行 DEA 之后，相应效率得分列会被添加回当前活动数据集。

这一步的意义非常大。因为一旦效率得分成为数据表中的新变量，用户就可以立刻回到 **Statistics** 和 **Visualization** 中继续分析。例如，可以用 **Descriptive Statistics** 查看区域之间效率均值是否不同，可以用 **Box Plot** 比较不同星级酒店的效率分布，也可以把效率值作为因变量，进入后续回归分析思考哪些经营特征与效率更相关。换句话说，DEA 结果不再只是停留在一个单独结果页，而是成为整个分析流程中的新变量。

图 11-5 本案例的 **Write scores back to dataset** 结果示例。

10	**dea_efficiency**	Numeric		8	2	Dea Efficiency			8	Right	Scale	Input
11	**dea_crs**	Numeric		8	2	Dea Crs			8	Right	Scale	Input
12	**dea_vrs**	Numeric		8	2	Dea Vrs			8	Right	Scale	Input
13	**dea_scale_efficiency**	Numeric		8	2	Dea Scale Efficiency			8	Right	Scale	Input

11.12 使用 region 和 hotel_star 比较区域与星级差异

当前文件中还提供了 `region` 和 `hotel_star` 两个非常适合做异质性比较的变量。若效率值已经写回数据表，用户可以进一步通过 **Statistics → Nonparametric** 或 **Statistics → ANOVA** 或 **Visualization → Box Plot** 比较不同区域和不同星级酒店之间的效率差异。

从研究角度看，这一步非常自然。因为效率不仅可能受内部资源配置影响，也可能受到区域市场条件和酒店层级定位影响。比如，华北、华东和华南的经营环境不同，效率分布可能存在差异；三星、四星和五星酒店的投入产出结构也不同，因此在同一效率框架下表现未必一致。对教学来说，这一步非常有帮助，因为它让学生看到 DEA 结果不仅仅是“一个分数”，而是可以进一步进入分组比较和管理解释。

图 11-6 **Statistics → Nonparametric** 的 **Input Settings** 页面。

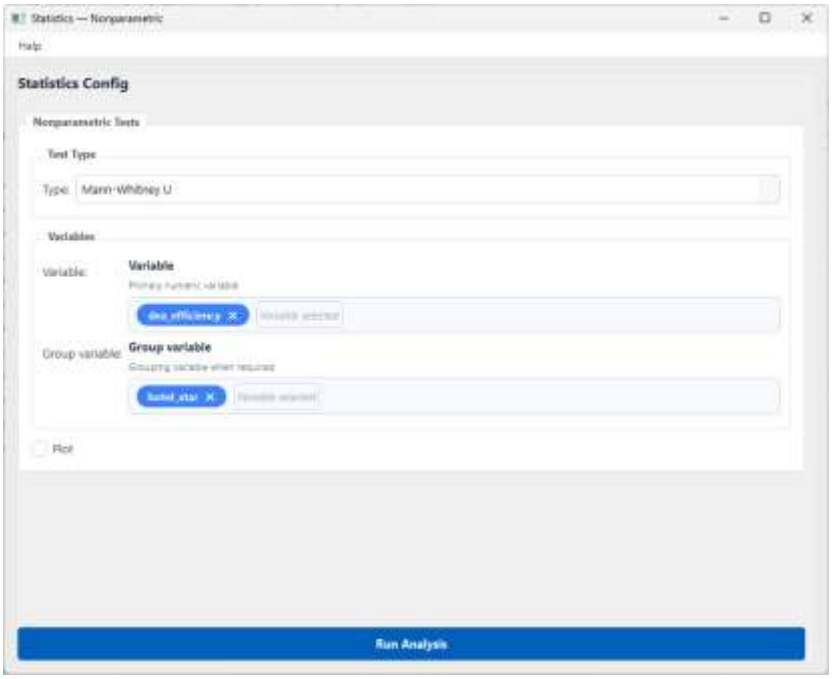

11.13 使用 SFA 作为参数前沿模型扩展

除了 DEA，本案例还适合通过 **Analysis Method → SFA (Cobb-Douglas)** 进入随机前沿分析的基本路径。与 DEA 不同，SFA 是参数化方法，更接近一个带效率分解的生产函数模型。在当前版本中，若用户选择 SFA，通常应把 `revenue` 设为 **Dependent Variable (SFA only)**，把 `employees`、`operating_cost` 和 `rooms` 作为投入变量。

这一步的教学意义在于帮助读者理解：DEA 和 SFA 虽然都在做效率评价，但方法逻辑并不相同。DEA 更强调相对前沿比较，不预设具体函数形式；SFA 则更强调在给定函数形式下，把随机误差与效率损失区分开来。对于本案例而言，由于当前实际文件中没有

`high_speed_rail` 这样的外部环境变量，因此 SFA 的演示将主要停留在最基础的生产函数设定上，而不会扩展到环境变量修正模型。

对新手而言，建议先把 DEA 跑通，再把 SFA 作为扩展练习，而不是一开始就同时深入两条路径。

图 11-7 **SFA** 的 **Input Settings** 页面。

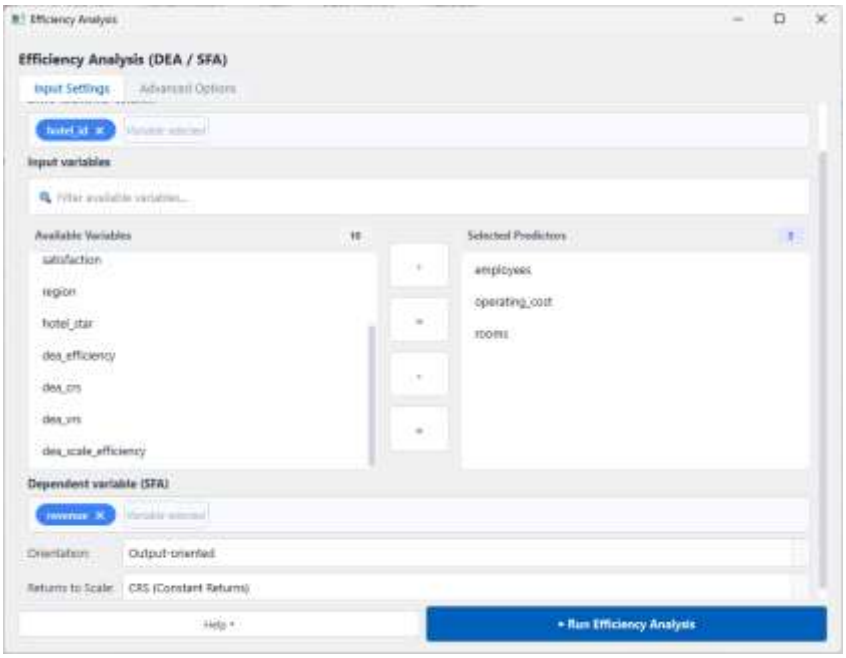

11.14 DEA 与 SFA 的基本区别

在教学中，很多读者会自然问一个问题：既然两者都能算效率，为什么还要分成 DEA 和 SFA？对本案例而言，最简单的回答方式是这样。

DEA 是非参数方法。它不需要先设定明确的生产函数，而是直接根据样本中的最佳实践点构建效率前沿。它特别适合多投入、多产出场景，比如本案例中同时有收入、客房夜数和满意度三个产出。SFA 是参数方法。它需要设定生产函数形式，当前版本中使用的是 Cobb-Douglas。它更适合围绕一个核心产出变量展开，并尝试把随机波动和效率损失区分开来。

因此，若研究更关心多维产出下的相对效率比较，DEA 更自然。若研究更关心单一产出函数和误差分解，SFA 更合适。本案例同时展示两者，正是为了帮助读者建立这种方法比较意识。

图 11-8 **SFA** 与 **DEA** 效率得分的 **Scatterplot**。

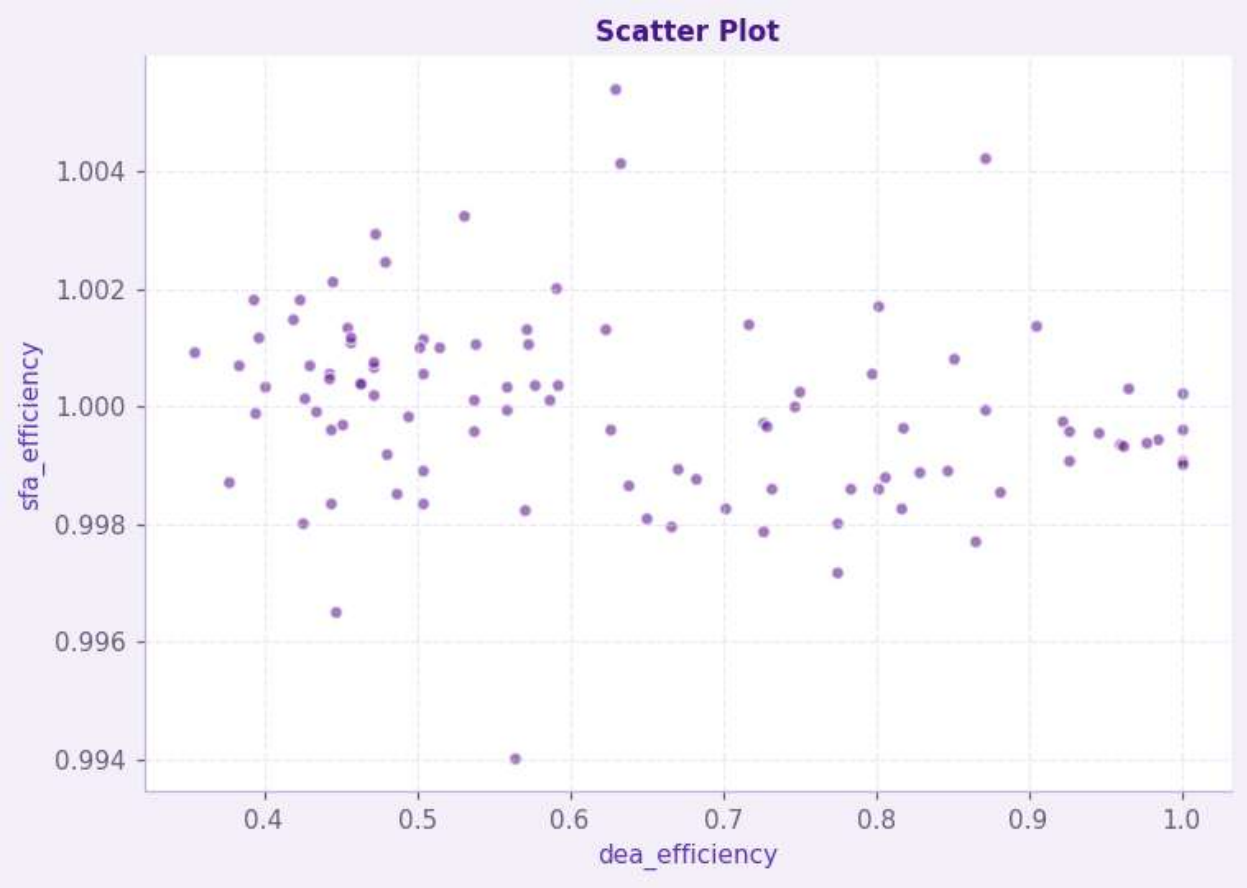

11.15 结果解释：效率不是收入高低，而是资源转化能力

本案例最重要的解释原则，是始终把效率理解为“资源转化能力”，而不是“收入高低”。例如，一家收入很高的酒店，如果投入也非常高，其效率并不一定高。反过来，一家规模不大的酒店，如果以较少员工、较低成本和较少客房创造了相对不错的收入、客房夜数和满意度，它在 DEA 中完全可能表现为高效率单位。

对初学者而言，若只盯着 `revenue` 列，很容易把“赚钱多”误当成“效率高”。本章的目的之一，正是帮助读者走出这种直觉误区。效率分析真正强调的是“投入与产出的对应关系”，而不是产出本身的绝对规模。只要这一点理解到位，DEA 和 SFA 的结果都会变得更有意义。

11.16 本案例中的常见错误与排查

本案例中最常见的问题，首先来自投入与产出角色设错。若把 `revenue` 或 `guest_nights` 放入输入变量，把 `employees` 或 `operating_cost` 放入输出变量，结果解释就会完全反转。第二类问题是没有真正理解 `hotel_id` 在此处承担的就是 DMU 标识角色，因此误以为当前文件少了一个叫 `DMU` 的列就不能做效率分析。实际上，任何能唯一标识决策单元的字段都可以。

第三类问题是拿到效率得分后，立刻把它当成绝对绩效排名，而忘记 DEA 的相对性质。第四类问题是同时试图在第一次练习中把 DEA 和 SFA 的所有细节都做完，结果反而把两种方法混淆。更稳妥的做法是先用 DEA 理解多投入多产出逻辑，再把 SFA 作为扩展比较。最后，若模型运行后没有看到结果，应先查看 **Results Viewer**，必要时再进入 **Syntax & Log（语法与日志窗口）** 查看是变量设定、方法选择还是输出过程出现了问题。

11.17 本章小结

本章围绕一份 100 家酒店的投入—产出与经营特征数据，展示了 Traview 中 **Advanced Models → Efficiency Analysis** 的基本使用路径。读者在本章中首先完成了投入、产出与决策单元结构检查，然后在效率分析模块中设定了 DEA 模型，理解了导向方式和规模报酬假设，运行并解释了效率得分、分布图和排序图，并进一步把效率结果写回数据表，用于区域和星级差异比较。与此同时，本章还说明了如何把 SFA 作为参数前沿模型扩展引入。

从全书结构来看，本章的意义在于把 Traview 的高级方法扩展到效率评价与生产前沿分析领域。前面的章节围绕描述统计、回归、文本、时间、空间和潜变量建模展开，而本章则强调在资源与结果之间寻找相对前沿。通过这一章，读者应能更加清楚地认识到，Traview 并不是一个只擅长传统统计的软件，而是一个能够覆盖多种方法路径的综合分析平台。

第 12 章 结果查看、结果整理与导出

12.1 本章概述

在前面的八个案例中，读者已经分别接触了描述统计、回归分析、文本分析、时间序列、空间分析、潜变量建模、元分析和效率分析等不同类型的输出结果。虽然这些结果来自不同模块、服务于不同研究问题，但在 Traview 的工作流中，它们最终都要经过一个共同的环节，也就是结果查看、结果整理与结果导出。换句话说，分析并不是在点击 **Run Analysis**、**Run Forecast**、**Run SEM** 或 **Run Efficiency Analysis** 的那一刻结束，而是在结果被阅读、整理并输出为正式材料之后，才真正完成。

这一章的目的，就是把前面案例中已经反复出现但尚未系统归纳的那部分内容，集中整理出来。它要回答的问题包括：分析结果通常会去哪里看，如何判断某次分析是否真正成功生成了结果，如何区分表格、文本和图形输出，如何把当前会话中的结果整理成可读的结构，以及如何把这些结果导出成 Word、Excel 或图像文件，用于课堂汇报、作业提交、论文写作或项目存档。

对初学者而言，结果管理往往是最容易被低估的一部分。很多用户会觉得“只要模型跑出来就算结束”，但真正成熟的分析工作从来不仅仅是得到一个结果，而是要知道结果在哪里、怎样读、如何比较不同结果、哪些结果值得保留，以及如何将其组织成可传播、可复用的正式输出。本章的意义，正是在于帮助读者从“会运行分析”进一步过渡到“会管理和使用分析结果”。

12.2 Results Viewer：Traview 的统一结果中心

在 Traview 中，大多数正式分析输出都会进入 **Results Viewer**。这一点在前面的案例中已经多次提到，但在这里有必要把它作为一个整体概念再强调一次。无论用户运行的是 **Statistics**、**Econometrics**、**Text Analysis**、**Time Series**、**Machine Learning**、**Visualization**、**Spatial Analysis**，还是 **Advanced Models** 下的高级方法，最终结果通常都不会长期停留在原分析页面，而是会被统一提交到 **Results Viewer** 中进行集中展示。

这种设计的好处非常明显。首先，它让主分析页面保持相对简洁，不会因为表格、图形和说明文字混杂在同一界面中而显得拥挤。其次，它使不同模块的结果能够在同一个窗口中连续阅读和比较。例如，用户完全可以在同一个结果窗口中先看描述统计表，再看 OLS 回归表，再看文本情感分析结果，最后看一张热点图。第三，它使导出和会话保存更有秩序，因为最终需要整理和输出的内容，本来就已经汇聚在一个地方。

因此，对本书这套八案例实操指南来说，**Results Viewer** 不只是一个附属窗口，而应被看作 Traview 工作流中的正式结果中心。若用户已经能熟练运行各类分析，但还没有养成进

入 **Results Viewer** 查看和整理结果的习惯，那么其实还没有真正完成从“操作软件”到“使用软件”的过渡。

图 12-1 **Results Viewer** 主界面。

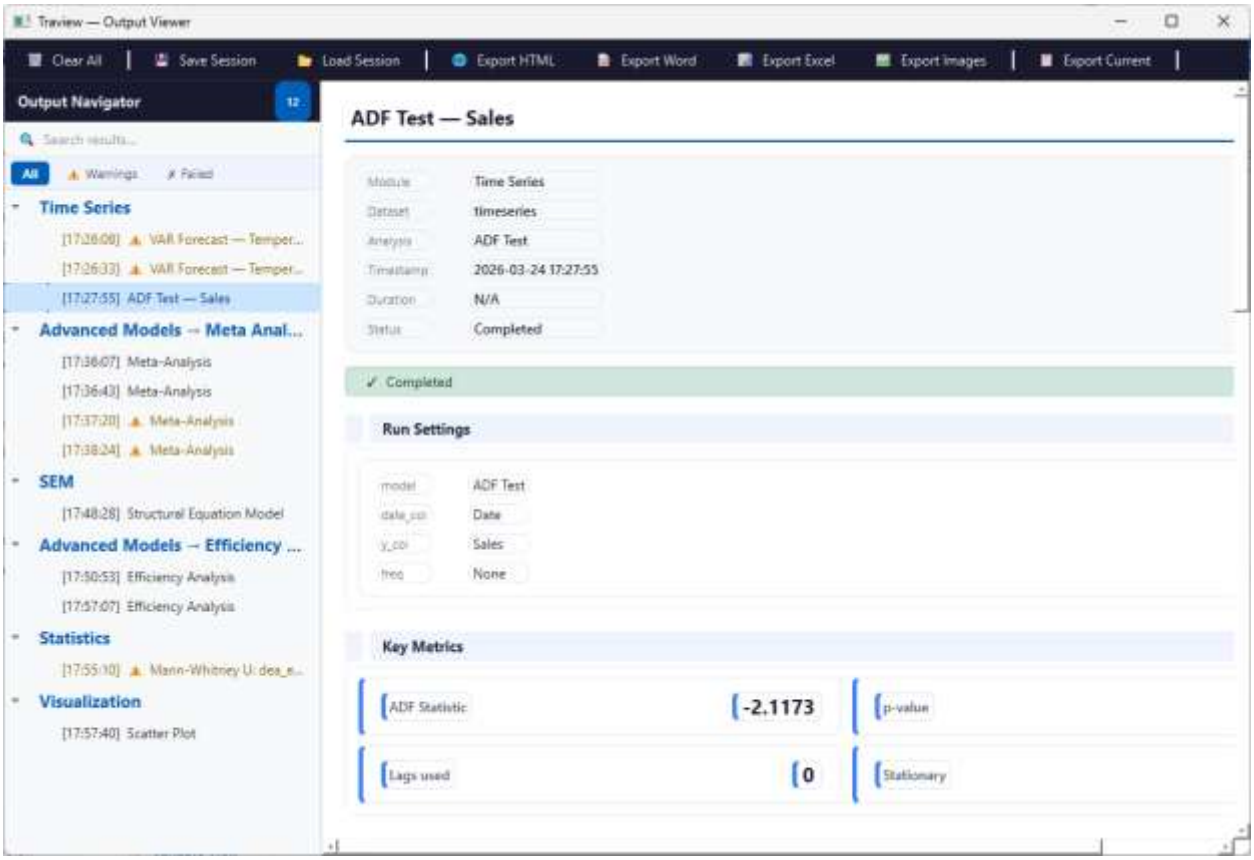

12.3 结果通常会以什么形式出现

在 Traview 中，分析结果通常会以三种基本形式出现，即表格结果、图形结果和文本结果。这三者并不是互相孤立的，而是常常在同一次分析中共同出现。理解这三类结果形式，有助于读者更有条理地阅读和整理输出。

表格结果是最常见的一类输出。描述统计表、频数表、相关矩阵、回归系数表、元分析综合结果表、效率得分表、混淆矩阵等，都属于这一类。它们通常强调数值的结构性和可比较性，适合在正式报告中直接引用。图形结果则更强调模式表达，例如直方图、散点图、折线图、热图、地图、森林图、漏斗图和效率排序图等。它们往往比表格更直观，更适合在课堂讲解、汇报展示和论文插图中使用。文本结果则主要包括模型摘要、拟合指标、日志说明、错误提示和分析解释性输出。它们在高级模型、元分析和 SEM 中尤其常见。

对于读者来说，最重要的并不是死记这三类名称，而是学会在结果窗口中快速判断“我眼前看到的这一块结果，到底是什么类型、应该怎么读”。一旦这种识别能力建立起来，结果整理的效率会显著提高。

12.4 运行分析后为什么要先看结果窗口

在初学 Traview 的过程中，最常见的误解之一，就是认为“如果当前分析页面没有立即出现结果，就说明分析失败了”。实际上，在 Traview 的当前设计中，许多分析运行后不会把结果直接固定在原页面中，而是提交到 **Results Viewer**。因此，运行分析之后的第一反应，通常不应该是反复点击运行按钮，而应该是先打开 **Results Viewer** 看看结果是否已经生成。

这一点之所以如此重要，是因为它体现了 Traview 的整体逻辑。分析模块负责输入参数、发起分析和提供局部设置，而 **Results Viewer** 才是真正承载正式输出的地方。若用户没有形成这种工作习惯，就会经常误判软件状态。例如，明明结果已经成功生成，但因为没有打开结果窗口，就误以为模型没有运行。反过来，如果分析确实失败了，通常也会因为结果窗口没有新增结果，从而形成一个明显信号，提醒用户进一步查看 **Syntax & Log（语法与日志窗口）**。

因此，对本书前面的八个案例而言，一个非常值得固定下来的动作是：每完成一次分析，都去结果窗口看一次。只要这一动作养成习惯，整个软件使用过程就会清晰很多。

12.5 如何判断一次分析是否真正成功

在 Traview 中，判断一次分析是否成功，通常可以从三个层面进行确认。第一个层面是分析页面本身是否提示任务已经开始执行。第二个层面是 **Results Viewer** 中是否出现了新的结果块。第三个层面则是 **Syntax & Log（语法与日志窗口）** 中是否有成功完成或错误中断的明确信息。

其中，最实用的标准通常是第二个。也就是说，如果运行后在结果窗口中出现了新的表格、图形或文本摘要，那么这次分析通常已经成功完成至少主要部分。若结果窗口没有新增任何内容，则应进一步查看日志窗口，确认是分析仍在处理中，还是已经在前置检查、图表生成或模型估计阶段中断。这样，用户就不会陷入“结果没出来但不知道为什么”的模糊状态。

在正式写作、教学或测试中，这种结果确认习惯也非常有价值。因为它可以帮助用户把“看起来像跑过了”和“实际上已经完成并输出了结果”这两种状态清楚区分开来。

12.6 如何阅读表格型结果

表格型结果在 Traview 中出现得最频繁，也是大多数正式报告中最常被直接引用的结果类型。无论是案例一中的描述统计表、案例二中的回归系数表、案例七中的元分析综合结果表，还是案例八中的效率得分表，它们都属于这一类。

阅读表格结果时，最重要的第一步不是盯着某个具体数值，而是先确认表格的整体结构。换句话说，先看这张表到底在回答什么问题。它是一个总体汇总表，还是一个回归结果表，还是一个按组比较表。接着，再看列名和行名分别代表什么。例如，回归表中的行通常代表变量，列通常代表系数、标准误和显著性信息；描述统计表中的行则常常代表变量，列代表均值、标准差、最小值和最大值。

只有当表格结构被读清楚以后，具体数值才真正有意义。很多初学者之所以会“看不懂表”，并不是因为数值太复杂，而是因为他们没有先辨认这是一张什么表。因此，在整理结果时，也应尽量保留表格标题和变量标签，因为这些信息恰恰是结果可读性的基础。

12.7 如何阅读图形型结果

图形结果通常比表格更直观，但也更容易被过度解读。在 Traview 中，常见图形包括直方图、散点图、折线图、热力图、地图、森林图、漏斗图、效率排序图等。每类图形都有自己的用途，因此阅读时也应有不同重点。

例如，直方图最适合看分布形状和偏态，散点图最适合看两个连续变量之间的大致关系，折线图最适合看时间变化趋势，热力图和地图最适合看空间集中区域，森林图最适合看研究效应量及其置信区间，漏斗图则更多用于观察发表偏倚的可能性。若用户不先明确图的功能，就容易把任何图都当成“漂亮展示”，而忽略其真正分析目的。

对初学者而言，阅读图形时最稳妥的顺序通常是：先看标题，再看横轴和纵轴，接着看颜色、分组或图例，最后再解释整体形状。只要养成这一顺序，图形结果通常会比想象中更容易理解。

12.8 如何阅读文本型结果与模型摘要

文本型结果在 Traview 中尤其常见于高级模型模块。例如，SEM、Process Model、Meta Analysis 和部分效率分析结果都可能同时给出一段说明性文本、拟合摘要或技术性输出。对于很多用户来说，这类结果最容易让人感到陌生，因为它不像表格那样整齐，也不像图那样直观。

实际上，阅读文本型结果最重要的技巧，是分层阅读。先看最上方的摘要性句子或小标题，确认这一段文字在说模型是否成功、拟合是否良好，还是在解释某项诊断结果。然后再看其中最关键的数字，例如 CFI、RMSEA、总体效应量、异质性统计量或效率分布摘要。最后，若需要，再进入更细节的技术行文。

换句话说，不应把文本型结果当作从第一行到最后一行逐字阅读的说明书，而应把它当作“有层次的模型摘要”。一旦这样看，文本型结果就不会再显得杂乱无章。

12.9 如何区分正式结果与过程性信息

在 Traview 的使用中，正式结果和过程性信息是两类不同内容。正式结果通常位于 **Results Viewer** 中，适合阅读、引用和导出。过程性信息则更多出现在 **Syntax & Log（语法与日志窗口）** 中，用于说明分析是如何运行的、运行到哪一步、是否遇到警告或错误。

这一区分非常重要。因为在实际使用中，很多用户会把日志中的信息误当作最终结果，或者把结果窗口中的简要说明误当作完整诊断输出。对本书前面的八个案例来说，更成熟的习惯应当是：在结果窗口中寻找正式表格、图形和摘要，在日志窗口中寻找分析过程、警告和报错。只要把这两类信息分清，排错和整理结果都会轻松很多。

12.10 结果的阶段性整理：为什么不要等到最后才处理

对于初学者来说，另一个常见误区是把所有分析都跑完以后，才开始整理结果。实际上，在 Traview 这种统一结果窗口的工作流中，更合理的方式通常是“边分析，边整理”。也就是说，每完成一个阶段性任务，就及时到 **Results Viewer** 查看、确认、筛选和导出关键结果，而不是把几十个表和图堆到最后一起处理。

这样做的好处非常明显。首先，它可以避免结果窗口中积累过多测试性输出，让真正有用的结果被淹没。其次，它能帮助用户在每个阶段就发现问题，例如图表方向不对、变量选错、模型设定不合理，而不至于等所有工作做完才发现前面许多结果都需要重来。再次，它让写作与分析之间的衔接更加自然。因为当某一章或某一案例的关键结果已经整理出来时，后续撰写课堂报告、项目说明或论文段落时会更高效。

因此，在本书的八个案例之后，本章特别强调结果的阶段性整理，就是希望读者逐步养成这种更成熟的工作习惯。

12.11 如何保存当前结果会话

在 Traview 中，除了把结果导出为外部文件之外，通常还可以保存当前结果会话。结果会话的保存意义在于，它不是简单地导出某一张表或某一张图，而是把当前分析阶段在 **Results Viewer** 中已经积累的结果整体保留下来，便于以后重新打开和继续查看。

这类保存尤其适合以下场景。第一，当前案例已经分析到一半，但还没有准备好正式导出全部结果。第二，用户希望保留一个阶段性的“结果快照”，以便后续与另一次分析做比较。第三，课堂演示或测试过程中需要保留完整的分析输出链条，而不仅仅是一两张最终图表。

从本书的案例使用角度看，阶段性保存结果会话是一个非常好的习惯。因为它使“案例一做到哪一步”“案例四已经得到哪些图和表”都可以被保留下来，而不必依赖记忆或重复跑模型。

12.12 如何导出表格结果

在正式写作、教学或提交作业时，表格结果通常需要被导出为外部文件。在 Traview 中，表格型结果通常最适合导出为 **Word (.docx)**或 **Excel (.xlsx)** 。若用户后续还需要继续编辑表格内容，Excel 往往是最方便的选择。若结果需要被直接插入报告正文，Word 通常更自然。

在选择导出格式时，用户应先想清楚“导出以后还要不要改”。如果还要进一步整理、合并或修改，Word 和 Excel 更灵活。对本书的八个案例而言，描述统计表、回归表、元分析汇总表和效率得分表通常都很适合导出为 Excel 或 Word，然后再根据需要进入正式写作环境。

12.13 如何导出图形结果

图形结果的导出在 Traview 中同样非常重要。当前版本通常支持把图形输出为 **PNG**、**SVG** 或 **JPEG** 等格式。对大多数课堂汇报和文档插图来说，**PNG** 是最通用的选择。若用户需要高质量矢量图，用于论文排版或后续图形编辑，则 **SVG** 往往更适合。

在导出图形之前，建议用户先在 **Settings → Output / Files** 中确认默认导出路径和默认图像格式。这样可以避免“明明导出了但找不到文件”的常见问题。对本书中的案例来说，折线图、空间地图、森林图、漏斗图和效率分布图都是非常适合导出的核心图形，尤其适合在课程讲义、案例报告和软件演示中直接使用。

12.14 如何导出完整报告

除了单独导出表格和图形之外，Traview 还支持以较完整的形式导出分析结果，例如 **HTML** 或 **Word** 报告。这种导出的意义在于，用户不需要分别保存每一张图和每一张表，而是可以把当前阶段的重要结果汇总为一个整体文档。

对教学和案例指南而言，完整报告导出尤其有价值。因为一个案例往往不止产生一个结果，而是一组互相关联的结果。例如，案例二可能同时包括描述统计表、折线图和 DID 结果表；案例七可能同时包括总体效应表、森林图、漏斗图和元回归结果。若能把它们按顺序汇总导出，后续阅读和讲解都会方便得多。

不过，在做完整报告导出前，建议用户先对结果窗口做一次整理，确认不需要的测试结果已经移除，真正想保留的表图顺序清楚。否则，一次性导出的报告就会包含过多中间结果，影响可读性。

12.15 结果文件命名与文件夹管理建议

在正式项目中，结果导出不应只是“点保存”，还应有清晰的命名和文件夹管理习惯。最常见的问题之一，就是分析结束后用户得到了一堆 `result1`、`plot2`、`final_new` 之类含义模糊的文件名，过一周以后就很难再分辨它们分别对应什么。

更稳妥的做法，是在项目开始时就建立清楚的文件夹结构，例如 `data`、`results`、`figures`、`tables` 和 `reports`。同时，导出的文件名最好包含案例编号、模块名称和日期信息。例如，可以用“case2_did_result”、“case4_sales_forecast_plot”、“case7_forest_plot”这类命名方式。这样做不仅便于自己后续整理，也很方便他人阅读和复核。

对本书这套八案例实操指南来说，这种命名规范尤其值得强调。因为案例多、模块多、输出类型也多，若不尽早建立命名和分类习惯，结果很容易混乱。

12.16 结果比较：如何在多个案例之间建立联系

随着读者完成本书前面的案例，**Results Viewer** 中会陆续出现来自不同模块的各种输出。在这种情况下，仅仅逐个查看结果已经不够，更有价值的做法通常是比较结果。例如，案例一中的消费均值差异与案例二中的 DID 政策效果是否都反映了需求变化；案例三中的情感得分与案例九中的满意度路径是否都指向服务质量的重要性；案例八中的效率得分与案例二中的经营收入结果之间是否可能形成互补解释。

这种跨案例比较，不一定要在软件里自动完成，但结果窗口的统一管理至少为这种比较提供了基础。对教学而言，这一点特别有价值，因为它能够帮助学生看到：不同方法虽然处理的数据类型不同，但很多时候是在从不同角度回答相关的问题。Traview 之所以把结果集中管理，意义也正在于此。

12.17 清空结果与开始新一轮分析

由于 **Results Viewer** 采用追加式结果积累方式，因此随着案例推进，结果会越来越多。在这种情况下，适时清空结果窗口往往是必要的。清空的目的不是删除有用信息，而是为了让新的分析阶段保持清晰、减少混淆。

不过，在执行清空之前，最重要的是先确认当前需要的结果是否已经保存或导出。否则，一旦结果被清空而又没有外部备份，就可能给后续写作和整理带来麻烦。较稳妥的做法通常是：先保存当前结果会话，或先把关键表格和图形导出，然后再执行清空操作。

这种“整理后再清空”的习惯，对本书的八个案例尤其重要。因为每做完一个案例，最理想的状态都是已经留下该案例的关键结果，而不是让所有案例结果一直堆叠在同一窗口中。

12.18 结果未出现时该怎么办

如果用户完成分析后在 **Results Viewer** 中没有看到新结果，最稳妥的第一反应不是重跑，而是先做三步检查。第一，看当前分析是否真的成功触发。第二，看 **Results Viewer** 是否只是没有置前或排序方式导致新结果不显眼。第三，看 **Syntax & Log**（**语法与日志窗口**） 中是否已经记录了错误信息。

这三步检查之所以重要，是因为它们能帮助用户迅速判断问题到底出在“结果没打开”“分析没完成”还是“过程出错”。若没有这种判断习惯，用户就会很容易陷入反复点击运行按钮的低效循环。对本书的实操教学来说，这也是结果管理和过程管理必须联系起来理解的一个原因。

12.19 本章小结

本章围绕 Traview 中统一的结果管理流程，系统说明了结果查看、结果整理和结果导出的基本逻辑。通过本章，读者应进一步理解：分析本身并不是终点，真正完整的工作流还包括到 **Results Viewer** 中确认输出、区分表格、图形和文本结果、对结果进行阶段性整理、将关键结果保存为会话或导出为正式文件，并在必要时结合 **Syntax & Log**（**语法与日志窗口**） 判断分析是否真正成功。

从整本《Traview 基于 8 个实例数据的实操指南》的角度看，本章承担着一个非常重要的衔接作用。前面的章节教读者如何基于不同数据和问题运行分析，而本章则进一步教读者如何把这些分析结果真正转化为可读、可存、可比、可导出的成果。也正因为如此，结果管理并不是一个附属技能，而是 Traview 使用能力中不可缺少的一部分。

第 13 章 常见问题与上机故障排查

13.1 本章概述

在前面的八个案例中，读者已经接触了结构化调查数据、面板数据、评论文本、时间序列、空间点位、量表题项、元分析数据和效率分析数据。随着数据类型和模型类型不断增加，软件使用中遇到问题的可能性也会自然增加。对初学者而言，这些问题有时会被误以为是“软件坏了”，但实际上，绝大多数问题并不是来自软件本身，而是来自数据结构、变量角色、模型设定、结果查看路径或文件输出环境。

因此，本章的目的不是把所有可能的错误代码逐条列出，而是帮助读者建立一个更有用的排查思路。一般来说，上机故障可以大致分为五类。第一类是数据导入与变量识别问题。第二类是分析设定问题。第三类是结果窗口与日志窗口使用问题。第四类是图表和文件导出问题。第五类是高级模型中特有的收敛、语法和识别问题。只要读者能先判断问题大致属于哪一类，再按合适顺序排查，大多数常见故障都可以较快定位。

在实际教学和软件测试中，一个非常重要的经验是，遇到问题时不要立刻重复点击 **Run Analysis** 或重启软件。更有效的做法通常是先停下来，看看当前数据、变量、结果窗口和日志窗口。Traview 的界面设计本来就包含了结果与日志两个层次，目的正是让用户不要把分析过程当成黑箱。本章将围绕这种思路，系统说明最常见的上机问题及其处理路径。

13.2 数据导入失败或导入后结构异常

在上机过程中，最先出现的问题通常发生在数据导入阶段。如果用户通过 **Data → Import CSV** 或 **Data → Import Excel** 导入文件后，软件提示失败，或导入后表格结构明显不对，那么首先不应急于怀疑分析模块，而应先回到原始文件本身检查结构。

最常见的导入问题包括以下几种情形。第一种是编码不匹配，尤其在包含中文文本或评论数据时最常见。此时，导入后文本可能显示为乱码。更稳妥的处理方式是检查 **Settings → Data → Default file encoding**，在 **UTF-8** 与 **GBK** 等常见编码之间调整后重新导入。第二种是列结构不规则。例如，CSV 中某些文本内容包含额外逗号，或 Excel 文件中存在合并单元格、说明性标题和空白行。这类问题往往会导致列数错位、变量名位置错误或部分数据跑到错误列中。第三种是首行并不是规范变量名，而是说明文字或标题。这样导入后，变量名称通常会非常混乱。

因此，若导入失败或导入后结构异常，最有效的第一步通常不是继续在 Traview 中勉强处理，而是先把原始文件整理成标准表格，即每列一个变量、每行一个观测、首行是变量名、不要混入多余说明。对教学来说，这一点非常值得强调，因为很多初学者的问题其实在文件进入软件之前就已经埋下了。

13.3 变量名正确，但变量类型不合理

数据成功导入并不意味着已经可以直接开始分析。一个非常常见的问题是，变量虽然被读进来了，但类型识别并不符合实际用途。例如，某些本应作为分类变量使用的编码列被读作连续数值，某些日期列只是普通字符串，某些数值列因为夹杂符号而被当作文本。对 Traview 来说，这类问题不会总在导入时自动报错，但却会在后面的统计分析或模型运行中逐渐暴露出来。

处理这一类问题时，读者应首先进入 **Variable View**，再结合 **Data View** 一起看。判断变量类型是否合理，关键不是只看它“是不是数字”，而是看这个数字在研究中代表什么。比如，`region = 1, 2, 3` 看起来是数字，但本质上是类别变量。`review_month = 2025-04` 看起来是字符串，但在时间分析中它承担时间索引作用。`sentiment_label = positive, neutral, negative` 虽然是文本，但本质上是分类标签，而不是普通自由文本。只要这种“功能性理解”建立起来，变量类型判断就会清楚很多。

对上机训练来说，一个很实用的原则是：每次进入分析模块之前，先问自己一句话，这一列在当前模型中到底扮演什么角色。只要这个问题想清楚了，很多类型错误都会在进入模型之前就被发现。

13.4 运行分析后没有看到结果

这是 Traview 使用中最常见、也最容易被误解的问题之一。很多用户在完成参数设置并点击 **Run Analysis**、**Run Forecast**、**Run SEM** 或 **Run Efficiency Analysis** 后，如果当前页面没有立即展示大段输出，就会误以为软件没有成功运行。实际上，在 Traview 的当前设计中，大多数正式结果都会进入 **Results Viewer**，而不是长期停留在原分析页面上。

因此，当用户觉得“好像没出结果”时，最应该先做的事情是打开 **Results Viewer**。如果结果窗口中已经出现了新的表格、图形或文本块，那么分析通常已经成功完成。若结果窗口中没有新增内容，再去看 **Syntax & Log（语法与日志窗口）**，确认分析到底是没有开始、运行中断，还是只是当前结果没有置前显示。

这一点在本书八个案例中都非常重要。无论是案例一的描述统计，案例三的情感分析，案例七的森林图，还是案例八的 DEA 效率结果，都遵循相同逻辑。也就是说，“结果没出现在当前页面”并不等于“分析失败”。只要养成“先看结果窗口，再看日志窗口”的习惯，这类误判就会大幅减少。

13.5 Results Viewer 中结果太多，看不清当前分析结果

随着案例练习的推进，**Results Viewer** 中往往会积累越来越多的结果。有时用户并不是“没有结果”，而是“结果太多，不知道哪一块是刚刚那次分析产生的”。这类问题在教学环境中尤其常见，因为学生常常会连续尝试多次模型或图表，而不清理旧结果。

处理这一类问题时，最稳妥的方法是先看结果排序方式，然后根据最新时间或模块顺序定位结果。如果窗口中仍然很混乱，则建议在开始新一轮案例前，先保存当前重要结果，再适当清空结果窗口。这样做并不是为了删除信息，而是为了保持当前分析上下文清晰。尤其在八个案例连续进行时，更应养成“一个案例一轮整理”的习惯，而不要把所有结果一直堆在同一个窗口里。

换句话说，结果太多并不是软件错误，而是一种结果管理问题。解决它的关键不在模型，而在使用习惯。

13.6 Syntax & Log 太多技术信息，不知道该看哪一行

很多初学者第一次打开 **Syntax & Log**（**语法与日志窗口**） 时，会因为里面的消息过多而感到不知所措。实际上，日志窗口并不要求用户把每一行都看懂。更有效的做法，是学会找到“和刚刚那次分析有关的那一段”，再从里面抓住第一条真正关键的警告或错误信息。

一般来说，较合理的阅读顺序是这样的。先找到与当前分析相关的开始提示，例如正在运行哪一个模型、正在生成哪一种图或正在提交什么结果。然后继续往后看，寻找第一条包含 **error**、**warning**、**invalid**、**failed**、**not found** 之类提示的记录。通常，真正的问题就出现在那里，而不是最后一行。最后，再把这一条错误信息和当前的数据字段、模型设定联系起来，看它是在说变量、路径、类型还是收敛问题。

因此，日志窗口的正确用法并不是“逐字阅读”，而是“快速定位与本次分析有关的第一条关键问题信息”。一旦读者掌握这个习惯，日志窗口就会从令人紧张的技术文本，变成非常实用的排错工具。

13.7 描述统计、相关分析或频数分析结果异常

在案例一、案例三以及其他多个案例中，用户都经常会用到描述统计、相关分析和频数分析。如果这些基础统计结果看起来明显不合理，例如均值极端异常、分类变量类别数量不对、相关方向完全反常，那么最应该先怀疑的通常不是统计方法，而是变量本身。

例如，某个评分变量若均值接近 100，而它理论上应该是 1 到 5 的量表，那么很可能导入时混入了错误编码。某个分类变量若频数表中出现大量看不懂的新类别，则可能是原始文本中空格、拼写或编码不一致造成的。相关分析若显示几乎所有变量都极强相关，也应先检查是否有重复列或同一个变量被多次计算后重复导入。

因此，基础统计结果异常往往是非常有价值的预警信号。它提醒用户回到数据工作区，重新检查变量定义和原始值，而不要急着继续更复杂的分析。

13.8 回归模型无法运行或结果明显反常

在案例二及其他扩展分析中，回归问题是最常见的。若 OLS、Logit、Panel Models 或 DID 无法运行，首先应检查因变量和自变量的角色是否合理。例如，连续型结果变量更适合 OLS，二元结果变量更适合 Logit，面板模型则必须明确指定个体和时间维度。若这些基础设定有误，模型通常就会在预检查阶段失败。

若模型运行成功但结果明显反常，例如系数方向完全不符合常识，或所有变量都高度不显著，也不应立刻判断为软件错误。更稳妥的做法是先检查变量定义、样本量、缺失值和变量间共线性。例如，把类别编码变量直接按连续变量解释，就很容易得到难以解释的系数。又例如，控制变量选错或交互项定义不清，也会让 DID 结果显得奇怪。

对本书这类案例指南而言，最重要的一点是：回归结果是否“好看”，并不是判断分析是否成功的唯一标准。真正需要先判断的是，模型设定是否与研究问题一致。

13.9 文本分析结果为空或几乎没有有意义词项

在案例三中，最常见的问题之一是文本分析结果看起来“太空”，例如高频词极少、主题模型几乎无结构、情感分析结果很单薄。出现这种情况时，最常见原因通常不是算法坏了，而是文本本身或预处理设置存在问题。

首先，应确认所选的 **Text column** 是否真的是 `review_comment`、`review_title` 或 `manager_response` 这类自由文本列，而不是 `review_id`、`city` 或其他结构化字段。其次，应检查预处理是否过强。例如同时去掉标点、数字、停用词，并把最小词长设得过高，往往会把短文本中本来就有限的有效词进一步压缩掉。再次，应看文本本身是否确实太短或缺失过多。若选择的是回复文本列，而很多评论本来就没有回复，那么结果当然会显得稀疏。

因此，文本分析“结果空”通常不是因为软件不会做，而是因为输入列或预处理逻辑不合适。只要回到文本列本身看一眼，多数问题都会变得容易理解。

13.10 时间序列结果异常或预测线看起来不合理

在案例四中，时间序列问题最常见的表现是：模型能运行，但预测线非常奇怪，或者趋势图与原始数据明显脱节。遇到这种情况时，最应先检查的是时间列和数据频率，而不是立刻怪模型。

例如，若 `Date` 没有被真正当作时间索引，而只是普通文本，模型就可能无法正确理解顺序。若本来是周度数据，却被误当成日度或月度，预测步数和趋势解释都会出问题。若序列长度较短却选择过于复杂的模型，也容易导致结果不稳定。再如，若销售序列本身有明显趋势却没有考虑差分或平稳性检查，则 ARIMA 的表现也可能反常。

因此，时间序列故障排查的顺序通常应是：先看原始折线图，再看时间索引设定，再看 ADF 检验结果，最后才调整模型参数。只要顺序正确，很多“奇怪的预测图”都能找到原因。

13.11 空间分析地图不对、点位跑偏或结果全不显著

在案例五中，最常见的问题通常都和坐标有关。若点位图显示所有酒店跑到了奇怪位置，首先应检查 `latitude` 和 `longitude` 是否选反。若点位全部聚在一个角落，也应怀疑是否误把别的数值列当成了坐标列。若点位图本身都不合理，则后续 **Global Moran's I**、**Local Moran's I** 和 **Hotspot Analysis** 的结果自然也无法解释。

另一类常见问题是空间统计“全都不显著”。这种情况并不必然表示软件出错。它也可能只是意味着当前变量在空间上本来就没有强烈结构。例如，酒店评分若在空间上分布较为随机，Moran’s I 不显著本来就是合理结果。此时不应急着反复更换参数，而应先接受“该变量可能没有明显空间聚集”这一可能性。

总的来说，空间分析故障排查的第一原则是：先看地图，再看统计量。只要地图不对，统计量就不值得解释。

13.12 SEM、Process Model 和高级模型运行失败

在案例六、案例七和案例八中，读者开始接触更高级的方法。这类模块最常见的问题是模型运行失败、语法错误或不收敛。对 SEM 来说，最常见的原因包括潜变量与观测变量命名冲突、观测变量名称与数据字段不一致、量表项不是数值型，以及路径设定过于复杂。当前 Traview 已经提供 **Validate**，因此在正式运行之前一定应先做验证。只要 **Validate** 没有通过，就不应急着点击 **Run SEM**。

对 **Process Model** 来说，最常见的问题是变量角色设置不清。例如，中介模型却没有中介变量，调节模型却没有调节变量，或者把同一个变量同时放在 `X` 和 `M` 中。对 **Meta Analysis** 来说，最常见的错误则是把 `es`、`n` 和 `var` 的角色搞混。对 **Efficiency Analysis** 来说，则通常是投入与产出放反，或者没有真正提供唯一的决策单元标识列。

这类高级模型排查时最有效的做法，通常不是一味重跑，而是先回到模型逻辑本身，重新确认每个变量在理论上扮演的角色是否明确。

13.13 效率分析结果看不懂，或感觉和收入高低不一致

在案例八中，一个非常常见的误区是：用户看到某家酒店收入很高，却在 DEA 中效率并不特别高，于是怀疑结果是不是错了。实际上，这恰恰说明用户还没有完全理解效率分析的逻辑。DEA 和 SFA 看的是投入—产出关系，而不是产出绝对规模。收入高不等于效率高，正如成本低也不一定代表效率高。

若读者觉得结果“怪”，更稳妥的第一步是先回头看看投入变量和产出变量是否放对。若 `employees`、`operating_cost` 和 `rooms` 已经作为投入，而 `revenue`、`guest_nights` 和 `satisfaction` 已作为产出，那么结果就应从相对前沿角度去理解，而不是从单一收入排序角度去理解。

也就是说，这类“看不懂”的问题很多时候并不是技术问题，而是概念问题。只要重新回到效率分析的基本逻辑，结果通常就会更容易接受。

13.14 导出文件失败或导出后找不到文件

在本书八个案例中，最终都需要把结果导出为图像、表格或报告。因此，导出问题也非常常见。若导出失败，最先应检查的不是模型，而是导出路径和文件权限。用户应打开 **Settings → Output / Files**，确认默认导出目录是否存在、是否可写，以及是否容易找到。若默认路径指向受限目录，系统就可能阻止写入。

另一种常见情况是文件其实已经成功导出，只是用户忘记保存到了哪里。因此，在正式项目中，强烈建议尽早设置一个固定的 `results` 或 `exports` 文件夹。这样既能避免找不到文件，也能减少不同案例结果混在一起的情况。

若导出时提示文件被占用，则应检查目标文件是否已经在 Excel、Word 或其他程序中打开。很多时候，关闭已打开的同名文件后，重新导出即可解决。

13.15 设置修改后没有生效

Traview 中有些设置会立即影响后续分析，例如默认导出路径、图表尺寸和结果窗口行为；但也有一些设置，尤其是界面语言和某些主题设置，可能需要在重新打开软件后才会完全生效。因此，若用户修改设置后发现界面没有立刻变化，不应急着判断为设置失败，而应先判断该设置属于哪一类。

例如，**Interface language** 通常就不是即时变化型设置，而更接近“下次启动生效”的系统级设置。相比之下，导出路径和结果行为往往更容易在下一次操作中立即体现。若用户反复修改后行为仍明显异常，则可以考虑在 **Settings → Advanced** 中使用恢复默认设置或清理临时文件的功能，以排除旧配置残留问题。

13.16 图表显示正常，但结果解释写不出来

还有一种非常常见但容易被忽略的问题，是软件本身运行正常，图和表也都出来了，但用户却不知道结果到底该怎么解释。严格来说，这并不是“软件故障”，但在教学上它仍然是一种非常重要的“上机问题”。因为很多学生和初学者会把“会点按钮”和“会读结果”混为一谈。

处理这种问题时，最有效的方法通常不是再去点更多模型，而是先回到该案例的研究问题。也就是说，先问自己：这一章想回答什么问题？如果是案例一，就回到消费与满意度差异；如果是案例二，就回到政策是否改变旅游收入；如果是案例三，就回到评论情感和回复行为；如果是案例七，就回到服务质量与满意度的总体相关有多强。只要把研究问题重新抓住，结果解释通常就会清晰很多。

因此，本书之所以坚持案例驱动写法，其实也正是在帮助读者避免“只会操作不会解释”的问题。

13.17 一个更有效的排查顺序

当读者在 Traview 中遇到问题，而又一时说不清问题出在哪里时，最有效的办法通常不是随意尝试，而是按一个固定顺序排查。这个顺序可以概括为五步。

第一，先看数据。确认文件已正确导入，变量名和变量类型合理。第二，先看当前分析设定。确认因变量、自变量、文本列、时间列、坐标列或输入输出变量角色没有搞错。第三，先看 **Results Viewer**。确认结果是不是其实已经生成，只是你还没去看。第四，再看 **Syntax & Log**（语法与日志窗口），定位最早出现的关键警告或错误。第五，最后再检查设置、输出路径、临时文件和软件环境。

这个顺序之所以有效，是因为它把最常见的问题放在最前面处理，而把真正属于环境层面的问题放到后面。对初学者来说，只要形成这种排查顺序，大多数上机问题都会比想象中更容易解决。

13.18 本章小结

本章围绕 Traview 在八个案例实操中最常见的上机问题，系统说明了数据导入、变量识别、结果查看、日志阅读、图表输出、模型运行和文件导出等方面的常见故障与排查方法。通过本章，读者应逐步建立一种更成熟的使用方式，也就是遇到问题时先看数据、再看模型设定、再看 **Results Viewer**、再看 **Syntax & Log**，最后再检查设置和环境，而不是一开始就重复点击按钮或匆忙重装软件。

从整本《Traview 基于 8 个实例数据的实操指南》的角度看，本章承担着一个非常重要的收尾作用。前面的章节教读者如何基于不同案例运行分析，而本章则进一步帮助读者在遇到问题时保持清晰思路，不把错误简单归结为“软件不行”。只要这种排查意识真正建立起来，Traview 的使用效率和学习体验都会明显提高。

附录 A 八个案例核心变量总表

A.1 附录说明

本附录用于把本书八个案例中最关键的数据文件、核心变量和推荐分析路径集中整理出来。它的作用并不是替代正文，而是为读者提供一个快速查阅的总览工具。无论是上机前准备、课堂教学、案例复习还是软件测试，只要需要快速确认“这个案例的核心变量是什么”“该用哪个模块练习”，本附录都会非常有用。

在阅读本附录时，读者应注意一件事。这里所列的是“核心变量”和“典型路径”，并不意味着其他变量不重要，也不意味着只能按表中方式使用。相反，它的目的，是帮助读者在第一次接触案例时先抓住最主要的变量角色和分析方向，再在正文中逐步扩展。

A.2 八个案例核心变量总表

案例	数据文件	数据类型	核心结果变量	关键解释变量 / 分组变量	特殊字段	推荐练习模块
案例一 基础调查与服务评价数据	demand.csv	游客个体横截面数据	daily_spending_yuan、satisfaction_score	region、purpose、trip_duration_days、hotel_star、promo_used、post_covid、high_speed_rail	airport_distance_km 可作扩展 IV 思路	**Statistics、Visualization、Econometrics**
案例二 酒店经营与市场表现数据	panel_data.csv	城市年度面板数据	tourism_revenue	treated、post、treat_post、population、gdp_per_capita、hotel_count	city_id 与 year 构成面板结构	**Econometrics、Visualization**
案例三 评论文本与平台反馈数据	review.csv	评论文本 + 结构化行为数据	rating_overall、would_recommend、response_given	city、hotel_segment、traveler_type、booking_channel、sentiment_label、response_delay_days	review_title、review_comment、manager_response 为文本列	**Text Analysis、Statistics、Econometrics**
案例四 时间序列预测数据	timeseries.csv	单一对象按周记录的时间序列	Sales	Temperature、Promotion	Date 为时间索引列	**Time Series、Visualization**
案例五 空间点位与空间属性数据	spatial.csv	酒店空间点位数据	rating、visitor_count	price、region	latitude、longitude 为坐标列	**Spatial Analysis、Visualization、Statistics**
案例六 量表题项与潜变量建模数据	survey.csv	游客问卷与量表数据	Overall_Satisfaction、Loyalty_Score、Booking_Success	Age、Female、Income_Level、Region、Trip_Purpose、Duration_Days	Service_Quality_Item1–3 等为潜变量题项	**Statistics、SEM Workspace、Process Model、Machine Learning**
案例七 元分析效应量数据	meta.csv	研究级元分析数据	es	year、region、sample_type、measurement、published	var 与 n 是元分析关键输入列	**Meta Analysis**
案例八 投入—产出效率评价数据	dea.csv	酒店投入—产出效率数据	DEA 中无单一结果变量；SFA 中 revenue 为因变量	employees、operating_cost、rooms、guest_nights、satisfaction、region、hotel_star	hotel_id 为 DMU 标识列	**Efficiency Analysis、Statistics、Visualization**

A.3 按变量角色理解八个案例

若从变量角色角度重新看这八个案例，可以发现它们实际上覆盖了 Traview 中最重要的几类数据结构。案例一和案例二最适合帮助读者理解“结果变量—解释变量—控制变量”的基本框架。案例三则把文本列加入了这一框架，使用户第一次接触“文本变量与结构化变量并存”的情形。案例四进一步引入时间索引，使所有变量都必须放在时间顺序下解释。案例五再加入空间坐标，使变量不再只是表格中的数值，而成为地图上的点位属性。案例六、案例七和案例八则分别对应潜变量、研究级效应量和效率前沿，这些都属于高级但非常典型的数据角色结构。

从教学角度看，读者如果能够熟练识别这几类角色，就已经不仅是在“会点按钮”，而是在真正理解不同案例的数据逻辑。

A.4 按模块快速反查案例

如果读者不是从案例出发，而是想从模块反查“哪个案例最适合练习这个模块”，也可以参考下面的对应关系。

Statistics 最适合案例一、案例三、案例六和案例八。
Econometrics 最适合案例一、案例二和案例三。
Text Analysis 最适合案例三。
Time Series 最适合案例四。
Spatial Analysis 最适合案例五。
SEM Workspace 和 **Process Model** 最适合案例六。
Meta Analysis 最适合案例七。
Efficiency Analysis 最适合案例八。

这种反查方式尤其适合课堂教学和软件测试，因为它能帮助教师或测试者快速找到最适合某个模块的演示数据。

A.5 本附录小结

本附录把八个案例的文件名、数据类型、核心变量和推荐模块集中整理在一起，目的在于为读者提供一张全书的变量与模块总览图。对初学者而言，它有助于快速回忆每个案例最重要的变量是什么。对教师和测试者而言，它有助于快速决定某次上机或演示应从哪个案例切入。

附录 B 各案例常见报错速查表

B.1 附录说明

本附录并不是要替代第 13 章的完整故障排查说明，而是提供一个更短、更快、更适合上机现场翻阅的速查表。换句话说，如果第 13 章像“故障排查教材”，那么本附录更像“上机时可以迅速翻到的备忘录”。

读者在使用本附录时，最重要的不是记住每一条，而是学会一个固定顺序：先看数据，再看变量角色，再看 **Results Viewer**，最后看 **Syntax & Log**（语法与日志窗口）。只要这个顺序不乱，多数问题都不会太难定位。

B.2 通用问题速查表

问题现象	最常见原因	首先检查什么
导入后乱码	编码不匹配	Settings → Data → Default file encoding
导入后列数不对	原始文件分隔符或表头结构异常	原始 CSV / Excel 文件
点了运行但没看到结果	结果被发送到结果窗口	Results Viewer
结果窗口没有新增结果	分析未真正完成或中途失败	Syntax & Log
图表出不来	输出路径不可写或变量选错	导出路径、图表变量
模型报错	因变量 / 自变量 / 输入输出角色设错	当前模块变量设定
结果很奇怪	变量类型、编码或模型逻辑不对	Variable View 与研究问题
导出失败	文件被占用或路径无权限	默认导出目录、目标文件是否打开

B.3 案例一常见问题：基础调查与服务评价数据

问题现象	典型原因	处理建议
region、purpose 回归结果难以解释	把类别编码当成连续变量用了	先做分组比较，后续再做虚拟变量处理
描述统计均值明显异常	原始数据中有错误编码或异常值	回到 **Data View** 检查原始值

t 检验结果不合理	分组变量和结果变量放反	确认数值变量是目标变量，0/1 变量是分组变量
OLS 没结果	结果其实在 **Results Viewer** 中	先看结果窗口，再看日志

B.4 案例二常见问题：酒店经营与市场表现数据

问题现象	典型原因	处理建议
Panel Models 结果像普通回归	没有正确设置 `city_id` 和 `year`	在面板模型中明确设定个体和时间维度
DID 结果读不懂	混淆了 `treated`、`post` 和 `treat_post`	重新回到三者含义：组别、时期、交互项
时间趋势图不对	没有按年份排序或分组方式错误	先检查数据顺序和图形设定
`treat_post` 不显著就以为政策无效	过度简化解释	结合样本、控制变量和图形一起看

B.5 案例三常见问题：评论文本与平台反馈数据

问题现象	典型原因	处理建议
词频结果几乎为空	选错文本列或预处理过强	确认选择的是 `review_comment` 等文本列
主题结果没有结构	文本太短或有效词项不足	放宽预处理，减少过滤强度
回复文本缺失很多	`response_given = 0` 的自然缺失	不把它当作错误数据
情感分析和评分不一致	文本表达与结构化评分本就不完全等同	先做相关分析再解释

B.6 案例四常见问题：时间序列预测数据

问题现象	典型原因	处理建议
预测线很奇怪	`Date` 没被正确设为时间索引	重新设置 **Date column**
把周度数据当日度解释	时间频率理解错了	先看日期间隔，再解释预测步数
ARIMA 表现很差	没先做平稳性检查	先跑 **ADF Test**
外生变量效果看不懂	把 `Temperature` 和 `Promotion` 当成目标变量	明确它们是外生解释条件

B.7 案例五常见问题：空间点位与空间属性数据

问题现象	典型原因	处理建议
地图点位全部跑偏	`latitude` 和 `longitude` 选反或选错	回到 **Spatial Analysis** 重新设坐标列
热图看起来“热”，但统计不显著	把可视化误当统计显著性	继续看 Moran’s I 或热点分析
Moran’s I 不显著	变量本身空间结构弱	不一定是错误，先接受“可能随机”
缓冲区结果几乎全是 0	半径设置太小或坐标类型理解错	调整缓冲半径并检查坐标

B.8 案例六常见问题：量表题项与潜变量建模数据

问题现象	典型原因	处理建议
信度很低	题项不属于同一构念或误选了结果变量	重新检查题项组合
因子结构混乱	题项加载不清晰或变量组合不合理	从更小范围题项开始做因子分析
SEM 无法运行	字段名拼写错误或模型语法问题	先用 **Validate** 检查
中介路径解释不清	没分清直接效应和间接效应	回到路径图重新理解变量角色

B.9 案例七常见问题：元分析效应量数据

问题现象	典型原因	处理建议
元分析运行失败	`es`、`var`、`n` 列设错	明确效应量、方差和样本量角色
亚组分析结果奇怪	把类别编码当连续量解释	`region`、`sample_type`、`measurement` 应按类别解释
漏斗图不对称就直接下结论	过度解释发表偏倚	用“存在迹象”而非“已证明”
森林图看不懂	仍按个体样本思维理解结果	记住每一行代表一项研究

B.10 案例八常见问题：投入—产出效率评价数据

问题现象	典型原因	处理建议

DEA 结果与收入高低不一致	把效率误当收入排序	重新理解投入—产出转化关系
效率值很低或很高看不懂	投入、产出变量角色没想清楚	先核对输入输出设定
找不到 DMU 列	实际标识列叫 `hotel_id`	任何唯一标识列都可作 DMU
SFA 和 DEA 结果差异大	两类方法逻辑不同	不要直接把两者视为同一模型

B.11 一条最实用的排查口诀

对于本书全部八个案例，都可以使用同一条排查口诀：

先导入，后检查；先看结果，再看日志；先核对变量角色，再怀疑模型本身。

只要这个顺序不乱，绝大多数上机问题都会比想象中更容易解决。

B.12 本附录小结

本附录以速查表形式，把八个案例中最常见的报错和误区集中整理出来，目的在于让读者在上机现场能够快速定位问题，而不必在正文中反复翻找。它最适合与第 13 章配合使用：第 13 章负责系统讲思路，本附录负责快速查定位。

附录 C 教学练习与课堂任务建议

C.1 附录说明

本附录的目的，是把本书前面的八个案例进一步转化为可直接用于课堂教学、实验训练和作业设计的任务素材。也就是说，它不再只是告诉读者“怎么做”，而是开始引导教师和学生进一步思考“做完以后可以问什么、写什么、比较什么”。

从教学角度看，一个好的实操案例不应只让学生照着点按钮，而应让学生在操作中逐渐形成问题意识和解释能力。因此，本附录中的任务设计会尽量遵循三个层次。第一层是基础操作型任务，目的是帮助学生把软件跑通。第二层是结果解释型任务，目的是帮助学生学会读表、读图和读模型。第三层是扩展思考型任务，目的是帮助学生从“完成一次分析”走向“提出自己的分析问题”。

C.2 案例一教学任务：基础调查与服务评价数据

课堂任务建议

案例一最适合用作第一次上机训练。教师可以先要求学生导入 `demand.csv`，完成 `daily_spending_yuan`、`satisfaction_score` 和 `trip_duration_days` 的描述统计，并在 **Results Viewer** 中找到对应结果。接着，让学生分别对 `promo_used` 和 `post_covid` 做组间比较，并解释两组均值差异方向。

可布置的练习题

1. 请使用 **Descriptive Statistics** 比较游客消费、满意度和停留天数的分布特征。
2. 请比较使用促销和未使用促销游客的日均消费是否存在差异。
3. 请比较疫情前后游客满意度是否存在变化。
4. 请解释 `airport_distance_km` 在理论上为什么可能与游客消费有关。

扩展任务

请建立一个以 `daily_spending_yuan` 为因变量的基础 OLS 模型，并解释 `trip_duration_days`、`hotel_star` 和 `promo_used` 的系数方向。

C.3 案例二教学任务：酒店经营与市场表现数据

课堂任务建议

案例二最适合用来讲解面板数据和 DID。教师可以先让学生画出 `tourism_revenue` 的时间趋势图，然后要求他们分别运行基础 OLS、固定效应模型和 DID，比较三类结果在解释上的差异。

可布置的练习题

1. 请说明 `city_id` 和 `year` 分别在面板模型中起什么作用。
2. 请解释 `treated`、`post` 和 `treat_post` 三个变量的含义。
3. 请比较 OLS 与固定效应模型结果的主要差异。
4. 请结合 DID 结果解释政策是否提高了旅游收入。

扩展任务

请围绕“平行趋势”概念，说明为什么在做 DID 时应该先看处理组和对照组的时间趋势图。

C.4 案例三教学任务：评论文本与平台反馈数据

课堂任务建议

案例三非常适合让学生第一次接触“文本分析不是只看词云”。教学时可以先让学生对 `review_comment` 做词频和情感分析，再把情感得分写回数据表，最后比较不同情感评论在 `response_given` 或 `would_recommend` 上的差异。

可布置的练习题

1. 请找出评论正文中最常见的 20 个高频词，并解释它们反映了哪些核心服务维度。
2. 请比较正向、负向和中性评论的总体评分分布。
3. 请检验酒店是否更倾向于回复负面评论。
4. 请解释为什么 `manager_response` 中的缺失值并不一定表示数据错误。

扩展任务

请将 `sentiment_score` 写回数据表，并建立一个模型解释 `would_recommend` 或 `response_given`。

C.5 案例四教学任务：时间序列预测数据

课堂任务建议

案例四最适合讲“时间索引”和“预测”这两个概念。教师可以先要求学生用折线图观察 `Sales` 的变化，再运行 **ADF Test**，最后分别使用 **Exponential Smoothing** 和 **ARIMA** 做短期预测。

可布置的练习题

1. 请说明为什么 `Date` 在本案例中不能只当作普通文本列。
2. 请比较指数平滑与 ARIMA 的预测图有何差异。
3. 请解释 `Promotion` 为什么可以被视为外生干预变量。
4. 请说明本案例是日度、周度还是月度数据，并解释你的判断依据。

扩展任务

请尝试用 `Temperature` 和 `Promotion` 作为外部解释变量，讨论它们对销售变化可能产生的影响。

C.6 案例五教学任务：空间点位与空间属性数据

课堂任务建议

案例五最适合做地图展示和空间直觉训练。教师可以先让学生画出 **Point Map** 和 **Heatmap**，再要求他们分别对 `rating` 和 `visitor_count` 做空间统计分析。

可布置的练习题

1. 请说明为什么空间分析中必须先检查 `latitude` 和 `longitude`。
2. 请解释热力图和热点分析在含义上有什么不同。
3. 请对 `rating` 运行 **Global Moran's I**，并解释结果是否支持空间聚集。
4. 请比较热点酒店和非热点酒店在 `price` 或 `visitor_count` 上的差异。

扩展任务

请把局部空间聚类标签写回数据表，并进一步做区域或价格比较。

C.7 案例六教学任务：量表题项与潜变量建模数据

课堂任务建议

案例六非常适合用于讲“量表不是简单平均分”。教师可以先让学生完成 `Service_Quality_Item1-Item3` 的信度分析，再做因子分析，最后用 **SEM Workspace** 建立一个最基础的服务质量—满意度—忠诚路径模型。

可布置的练习题

1. 请解释为什么在做 SEM 之前通常要先做信度分析。
2. 请说明 `Service_Quality_Item1-Item3` 为什么适合作为一个潜变量的测量项。
3. 请建立 `ServiceQuality → Overall_Satisfaction → Loyalty_Score` 的路径，并解释其含义。
4. 请讨论 `Recommend` 和 `Return_Intention` 是否可以作为忠诚结果变量。

扩展任务

请用 **Process Model** 把满意度作为中介变量，比较 SEM 与 Process 模型在解释路径时的不同。

C.8 案例七教学任务：元分析效应量数据

课堂任务建议

案例七最适合讲“研究的研究”。教师可以先让学生运行固定效应与随机效应模型，再观察森林图和漏斗图，最后让他们尝试按 `region` 或 `sample_type` 做亚组分析。

可布置的练习题

1. 请解释为什么元分析中的每一行不是一个游客样本，而是一项研究。
2. 请比较固定效应模型与随机效应模型的结果，并说明你更倾向于哪一个。
3. 请解释森林图中每一个点和底部综合效应的含义。
4. 请根据漏斗图和 `published` 变量讨论发表偏倚的可能性。

扩展任务

请把 `year`、`measurement` 或 `published` 作为调节变量进行元回归，并解释结果。

C.9 案例八教学任务：投入—产出效率评价数据

课堂任务建议

案例八最适合帮助学生跳出“收入高就是好”的直觉。教师可以先让学生用 DEA 设定投入和产出，再比较 CRS 和 VRS 结果，最后让学生把效率值写回数据表并按区域或星级比较。

可布置的练习题

1. 请说明为什么 `employees`、`operating_cost` 和 `rooms` 更适合做投入变量。
2. 请说明为什么 `revenue`、`guest_nights` 和 `satisfaction` 可以共同构成产出。
3. 请比较 CRS 与 VRS 效率结果的差异，并解释规模效率的含义。
4. 请说明为什么效率高并不等于收入最高。

扩展任务

请把 DEA 得分写回数据表，并比较不同 `region` 或 `hotel_star` 之间的效率差异。

C.10 一份可直接使用的上机考核结构

如果教师希望把本书用于课程实验考核，可以采用一个非常清楚的三段式结构。第一段是基础操作题，例如要求学生导入数据、指定核心变量并运行一种基础分析。第二段是结果解释题，例如要求学生对某张图或某张表写出两到三句解释。第三段是扩展思考题，例如要求学生说明另一个模块还能如何继续分析当前数据。

这种结构的好处在于，它既能考查学生是否会操作软件，也能考查他们是否真正理解结果和研究问题，而不只是机械点按钮。

C.11 课堂讨论建议

除了上机任务，本书还很适合用于课堂讨论。例如，教师可以让学生比较案例二中的 DID 与案例七中的元回归在“解释差异”上的不同逻辑；也可以比较案例三中的情感分析与案例六中的满意度路径在“服务质量影响结果变量”上的不同视角。这样做有助于学生理解不同方法之间并非彼此割裂，而是在从不同层面研究旅游与酒店管理中的类似问题。

C.12 本附录小结

本附录将八个案例进一步转化为可教学、可上机、可考核的任务框架，目的在于让这本实操指南不仅能“教会软件怎么用”，还能直接进入课堂、实验和作业设计。对教师而言，它提供了现成的任务思路。对学生而言，它则帮助他们从“照着做”进一步走向“会解释、会比较、会扩展”。